UNIVERSITAT
Carlemany

ANÁLISIS Y PREDICCIÓN DEL RIESGO DE ENFERMEDADES DENTALES MEDIANTE TÉCNICAS DE APRENDIZAJE AUTOMÁTICO:

UN ESTUDIO BASADO EN VARIABLES SOCIOECONÓMICAS Y HÁBITOS DE SALUD

ANEXO

Titulación:	Bàtxelor en Ciencias de Datos
Estudiante:	Basaldella, Nazaret.
Tutor:	Gerardo Albà Soler
Dirección:	Gerardo Albà Soler
Fecha de depósito:	14 de septiembre de 2026.

Anexo

ANEXO A. DICCIONARIO DE VARIABLES

Tabla A1. Diccionario de variables del conjunto de datos final

VARIABLE	DESCRIPCIÓN	TIPO	PROCEDENCIA	USO
SEQN	Identificador único del participante	Numérica	NHANES	Identificación e integración
RIDAGEYR	Edad del participante	Numérica	DEMO_G	Predictora
RIAGENDR	Sexo del participante	Categórica binaria	DEMO_G	Predictora
RIDRETH1	Grupo étnico	Categórica nominal	DEMO_G	Predictora
DMDEDUC2	Nivel educativo	Categórica ordinal	DEMO_G	Predictora
INDFMPIR	Índice ingreso-pobreza (PIR)	Numérica continua	DEMO_G	Predictora
CARIES	Presencia o ausencia de caries dental	Binaria	OHXDEN_G	Construcción de la variable objetivo
PERIODONTITIS	Presencia o ausencia de periodontitis	Binaria	OHXPER_G	Construcción de la variable objetivo
ENFERMEDAD_ BUCODENTAL	Presencia de caries, periodontitis o ambas	Binaria	Variable construida	Variable objetivo
SMOKER_STATUS	Estado tabáquico del participante	Categórica nominal	SMQ_G	Predictora
ALCOHOL_USE	Consumo de alcohol	Categórica binaria	ALQ_G	Predictora
LAST_DENTAL_VISIT	Tiempo transcurrido desde la última visita al dentista	Categórica	OHQ_G	Análisis exploratorio
ORAL_HEALTH_RATING	Autopercepción del estado de salud oral	Categórica	OHQ_G	Análisis exploratorio
GUM_TREATMENT	Antecedente de tratamiento de encías	Categórica binaria	OHQ_G	Análisis exploratorio
LOOSE_TEETH	Antecedente o presencia de dientes flojos	Categórica binaria	OHQ_G	Análisis exploratorio
BONE_LOSS	Antecedente de pérdida ósea alrededor de los dientes	Categórica binaria	OHQ_G	Análisis exploratorio
PHYSICALLY_ACTIVE	Realización de actividad física	Categórica binaria	PAQ_G	Predictora

Fuente: Elaboración propia a partir de los módulos de NHANES 2011–2012 y del proceso de preparación desarrollado mediante Python.

ANEXO B. TABLAS COMPLEMENTARIAS DEL ANÁLISIS EXPLORATORIO Y DE ASOCIACIÓN

Tabla B1. Valores Faltantes

VARIABLE	VALORES FALTANTES	PORCENTAJE (%)
ALCOHOL_USE	313	9.47
INDFMPIR	265	8.02
BONE_LOSS	16	0.48
GUM_TREATMENT	13	0.39
LAST_DENTAL_VISIT	4	0.12
SMOKER_STATUS	3	0.09
ORAL_HEALTH_RATING	3	0.09
LOOSE_TEETH	2	0.06
SEQN	0	0.00
ENFERMEDAD_BUCODENTAL	0	0.00

VARIABLE	VALORES FALTANTES	PORCENTAJE (%)
PERIODONTITIS	0	0.00
CARIES	0	0.00
DMDEDUC2	0	0.00
RIAGENDR	0	0.00
RIDRETH1	0	0.00
RIDAGEYR	0	0.00
PHYSICALLY_ACTIVE	0	0.00

ANEXO C. RESULTADOS COMPLEMENTARIOS DEL MODELADO

Figura C1. Matriz de confusión de la Regresión Logística balanceada.

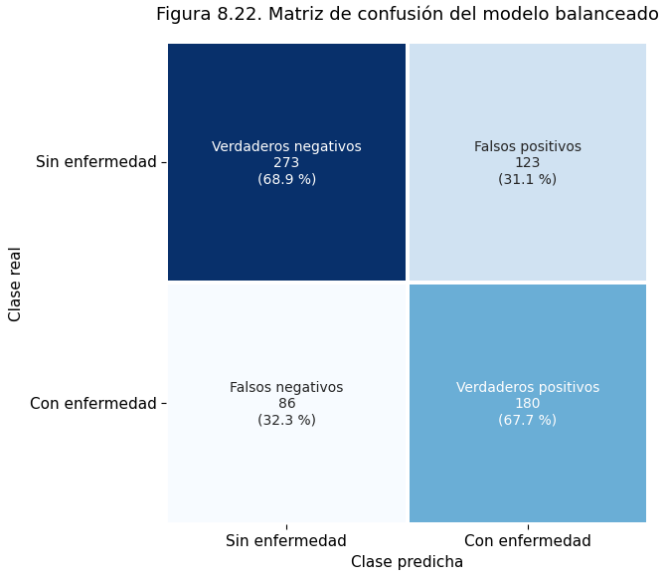
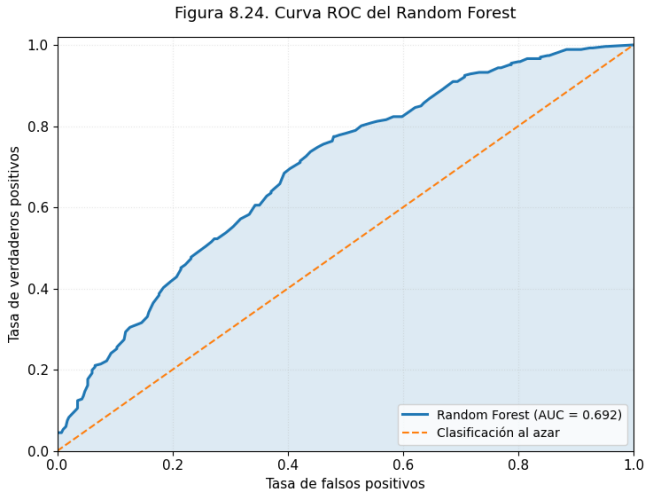
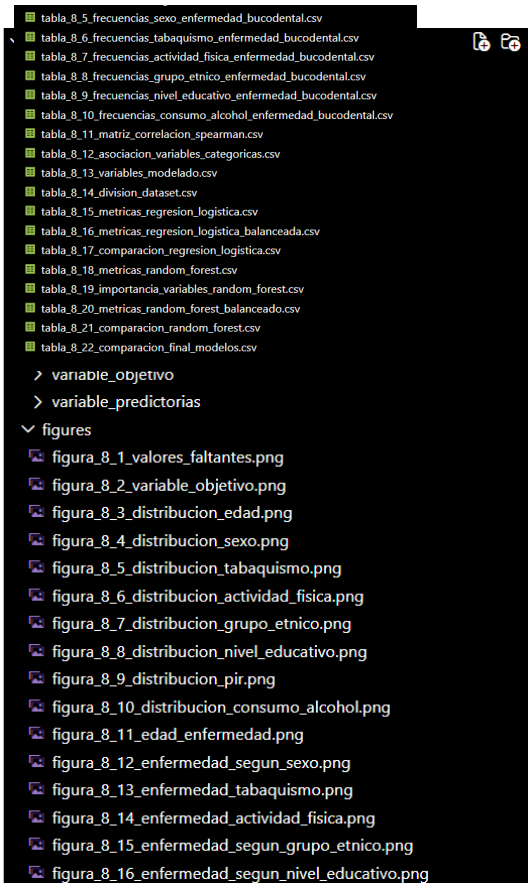


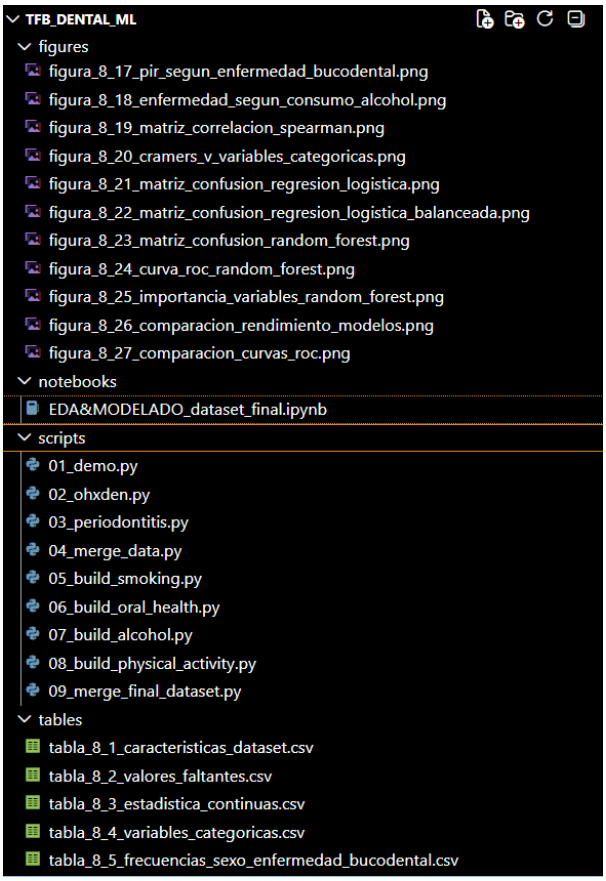
Figura C2. Curva ROC del modelo Random Forest base.



ANEXO D. ESTRUCTURA TÉCNICA Y REPRODUCIBILIDAD DEL PROYECTO

Con el objetivo de mantener la organización, trazabilidad y reproducibilidad del proceso de análisis, los archivos utilizados y generados durante el desarrollo del proyecto se organizaron en diferentes directorios según su función. Esta estructura permitió separar los datos originales descargados de NHANES, los conjuntos de datos procesados, los scripts utilizados para su preparación, el notebook empleado para el análisis exploratorio y modelado, y los resultados gráficos y tabulares generados durante el estudio. La estructura general del proyecto se presenta a continuación.





D.2 SCRIPTS DE PREPARACIÓN DE LOS DATOS

Tabla D1. Scripts utilizados para la preparación del conjunto de datos

SCRIPT	FUNCIÓN PRINCIPAL	ARCHIVO GENERADO
01_demo.py	Preparación de variables demográficas y socioeconómicas	demo_clean.csv
02_ohxden.py	Procesamiento del examen dental y construcción de la variable de caries	caries_final.csv
03_periodontitis.py	Procesamiento de las mediciones periodontales y construcción de periodontitis	periodontitis_final.csv
04_merge_data.py	Integración inicial de los principales conjuntos procesados	dataset_master.csv
05_build_smoking.py	Preparación y recodificación de las variables de tabaquismo	smoking_final.csv
06_build_oral_health.py	Preparación de las variables procedentes del cuestionario de salud oral	oral_health_final.csv
07_build_alcohol.py	Preparación de la variable de consumo de alcohol	alcohol_final.csv
08_build_physical_ activity.py	Preparación de la variable de actividad física	physical_activity_final.csv
09_merge_final_dataset.py	Integración de los conjuntos procesados y generación de la base utilizada en el análisis	dataset_final.csv