UNIVERSITAT
Carlemany

ANÁLISIS Y PREDICCIÓN DEL RIESGO DE ENFERMEDADES DENTALES MEDIANTE TÉCNICAS DE APRENDIZAJE AUTOMÁTICO:

UN ESTUDIO BASADO EN VARIABLES SOCIOECONÓMICAS Y HÁBITOS DE SALUD

Titulación:	Bàtxelor en Ciencias de Datos
Estudiante:	Basaldella, Nazaret.
Tutor:	Gerardo Albà Soler
Dirección:	Gerardo Albà Soler
Fecha de depósito:	14 de septiembre de 2026.

Abstract

The increasing availability of open data for health has encouraged the use of Data Science methods to tackle public health problems. In this scenario, oral diseases have been considered relevant health problems because of their frequency and their connections with many different socio-economic and behavioral variables.

The purpose of this work is to identify the relations between socioeconomic variables, health habits and the occurrence of oral disease by means of data analysis and machine learning techniques. To conclude, open data from the National Health and Nutrition Examination Survey (NHANES) 2011-2012, consisting of demographic, socio-economic, behavioral and oral health variables, are considered.

The proposed methodology includes the main steps of a Data Science project, that is data collection and preparation, exploratory data analysis, data management and storage, predictive modeling, model assessment and data visualization. The goal of the comparison between Logistic Regression and Random Forest is to measure the effectiveness of the two approaches in classifying the occurrence of oral disease based on socioeconomic and health habits variables.

This research wants to provide useful insights about the variables related to the occurrence of oral disease and to show the usefulness of Data Science techniques as decision-making support systems.

Keywords: Data Science, Machine Learning, Oral Health, Predictive Modelling, NHANES.

Índice

Contenido

1. Introducción 5
2. Justificación 6
3. Contextualización del trabajo 7
4. Objetivos 8
4.1 Generales 8
4.2 Específicos 8
5. Marco Teórico 9
5.1 Ciencia de Datos y toma de decisiones basada en datos 9
5.1.1 Qué es la Ciencia de Datos 9
5.1.2 Evolución de la disciplina 10
5.1.3 Aplicaciones en distintos sectores 10-11
5.1.4 Importancia de los datos abiertos 11
5.1.5 Ciencia de Datos en salud 12
5.2 Aprendizaje automático y modelos predictivos 13
5.2.1 ¿Qué es el aprendizaje automático? 13
5.2.2 Aprendizaje supervisado 13-14
5.2.3 Problemas de clasificación 14
5.2.4 Regresión logística 15-16
5.2.5 Árboles de decisión 16-17
5.2.6 Random Forest 17-18
5.3 Aplicaciones del aprendizaje automático en el ámbito sanitario 18
5.3.1 IA y salud pública 18-19
5.3.2 Modelos predictivos en salud: aplicaciones y limitaciones 19-20
5.4 Salud bucodental como problema de salud pública 20
5.4.1 Salud bucodental como componente de la salud general 20-21
5.4.2 Caries dental 21-22
5.4.3 Enfermedad periodontal 22
5.4.4 Factores de riesgo asociados 23
5.5 Estado del arte 24
6. Metodología 25
6.1 Diseño de la investigación 25-26
6.2 Materiales 26
6.2.1 Fuente de datos 26-27
6.2.2 Archivos de NHANES utilizados 27-28
6.3 Instrumentos computacionales 28-29
6.4 Preparación metodológica de los datos 30
6.5 Modelos de aprendizaje automático empleados 30-31
6.6 Visualización de los resultados 32
7. Desarrollo sostenible e impacto del proyecto 33
7.1 Temporalización e hitos 33
7.2 Contribución a los Objetivos de Desarrollo Sostenible (ODS) 33-34
7.3 Impacto ambiental, social y económico 34
8. Procesos y resultados 35
8.1 Fuentes de datos y recopilación 35-36
8.2 Exploración y preparación de datos 36-39
8.3 Análisis exploratorio 39
8.3.1 Descripción general del conjunto de datos 39
8.3.2 Calidad de los datos 39-40

8.3.3 Estadística descriptiva 40-41
8.3.4 Distribución de la variable objetivo 41-42
8.3.5 Análisis de las variables predictoras 42-45
8.3.6 Relación entre variables predictoras y enfermedad bucodental 46-49
8.3.7 Asociación entre variables 49-52
8.4 Modelado 53
8.4.1 Preparación de los datos para el modelado 53-55
8.4.2 Regresión Logística 55-56
8.4.3 Random Forest 56-58
8.4.4 Comparación final de los modelos 59-60
8.4.5 Selección del modelo final 60-61
8.5 Visualización 61
8.5.1 Resumen general 61-62
8.5.2 Factores asociados con la enfermedad bucodental 62-63
8.5.3 Resultados del modelo predictivo 63-64
9. Discusión y limitaciones 65
9.1 Discusión de los principales resultados 65-66
9.2 Comparación con estudios previos 66-67
9.3 Alcance y potencial de los modelos desarrollados 67-68
9.4 Limitaciones del estudio 68-69
10. Conclusiones y líneas futuras 70
10.1 Conclusiones 70-71
10.2 Líneas futuras 71-72
11. Referencias Bibliográficas 73-72

1. Introducción

La capacidad de generar, almacenar y procesar grandes cantidades de datos ha transformado la forma en que las organizaciones enfrentan situaciones complejas y toman decisiones. En este sentido, la Ciencia de Datos se ha convertido en una herramienta clave para extraer conocimiento de los datos basados en análisis estadísticos, la computación y el aprendizaje automático. Su aplicación hoy en día abarca múltiples campos entre ellos la industria de la salud debido al creciente número de información proporcionada por encuestas de la población, registros clínicos y sistemas de información de la salud (Provost y Fawcett,2013).

La importancia de la Ciencia de Datos en el sector de la salud surge de las posibilidades de identificar patrones, las relaciones entre variables y la construcción de modelos predictivos que ayuden a estimar la probabilidad de que ciertos eventos ocurran. Estas técnicas permiten integrar varias variables en la investigación y analizar al mismo tiempo factores demográficos, socioeconómicos y de comportamiento.

En este sentido las enfermedades orales se han convertido en un campo interesante de aplicación de este enfoque. Las enfermedades orales afectan a un gran porcentaje de la población y existen muchos factores relacionados con su aparición además de los clínicos (Organización Mundial de la Salud [OMS],2022). La complejidad de este tema ofrece la posibilidad de explorar las capacidades del análisis de datos y el aprendizaje automático como herramientas para generar conocimiento basado en la evidencia.

Por esta razón este estudio tiene como objetivo investigar las enfermedades orales desde la perspectiva de la Ciencia de Datos a través del uso de información de código abierto con el fin de evaluar el poder predictivo de las variables socioeconómicas y los hábitos de salud con respecto a la presencia de enfermedades orales. Además de analizar la relación entre las variables consideradas en este estudio el objetivo también es comparar las capacidades de diferentes métodos de aprendizaje automático en el desarrollo de modelos predictivos y la búsqueda de variables relevantes para la clasificación de la presencia de enfermedades orales.

2. Justificación

Un número creciente de datos abiertos en el campo de la salud brinda numerosas oportunidades asociadas al uso de los métodos de la Ciencia de Datos para resolver diversos problemas de salud pública. Sin embargo, aunque la tecnología continúa desarrollándose y surgen nuevos instrumentos avanzados para el análisis y modelado de datos todavía quedan muchas oportunidades por investigar el potencial de estas tecnologías en algunas áreas particulares de la prevención y la detección de problemas de salud.

Las enfermedades orales y dentales pueden servir como un buen ejemplo de este tipo de problemas. Existen evidencias de que el estado socioeconómico, la higiene personal, la actividad física, el tabaquismo y la nutrición están asociados con la aparición y el desarrollo de estos problemas. Sin embargo, la complejidad de estos procesos hace imposible analizar todos estos factores al mismo tiempo utilizando métodos tradicionales lo cual hace justificado el uso de técnicas basadas en datos capaces de analizar múltiples factores predictivos y su compleja interacción.

En este sentido las técnicas de análisis de datos y el aprendizaje automático pueden considerarse la forma más apropiada de abordar el problema mencionado. Estas herramientas son capaces de detectar interacciones complicadas entre variables y patrones de datos, así como de calcular probabilidades y construir modelos que permitan obtener conocimientos significativos basados en una gran cantidad de datos. Por consiguiente, la aplicación de estas técnicas puede proporcionar un conocimiento valioso acerca de los factores que contribuyen al desarrollo de enfermedades orales y ser una fuente significativa de evidencia en futuras investigaciones en este campo. El principal valor científico de este trabajo consiste en la aplicación de las habilidades de la Ciencia de Datos para resolver un problema del mundo real.

3. Contextualización del Trabajo

Este Trabajo Final de Bachelor ha sido elaborado en el contexto del Análisis de Datos (1209.03) y el Aprendizaje Automático (1207.94), específicamente con respecto a la aplicación de los métodos de la Ciencia de Datos a un problema de salud y social. En particular este trabajo estudia la correlación de las variables socioeconómicas, el comportamiento de la salud y la enfermedad oral con el fin de evaluar las capacidades de diferentes modelos predictivos en la clasificación de la condición estudiada.

Para llevar a cabo el desarrollo de este proyecto se ha utilizado la información de la *National Health and Nutrition Examination Survey (NHANES*), un programa de vigilancia epidemiológica elaborado por el *National Center for Health Statistics de los Centers for Disease Control and Prevention* de los Estados Unidos. NHANES es una de las bases de datos más populares de salud para la investigación epidemiológica y poblacional debido a la riqueza de las variables demográficas, socioeconómicas, de comportamiento y de salud que proporciona. El uso de tales fuentes proporciona datos recolectados de acuerdo con los procedimientos estandarizados para la epidemiología.

El proceso de desarrollo de este trabajo se alineó con las etapas típicas de un proyecto de Ciencia de Datos. Primero se realizó la recolección, integración y preparación de los datos para asegurar su calidad. Posteriormente se realizó un análisis exploratorio para comprender las características de la base de datos y encontrar posibles correlaciones entre las variables estudiadas. Esto sirvió como base para implementar modelos de aprendizaje automático supervisado con el fin de clasificar la presencia de la enfermedad oral y estimar la probabilidad asociada.

Finalmente, los resultados obtenidos fueron interpretados y comunicados utilizando métodos de visualización los cuales permitieron comprender los patrones revelados, las correlaciones entre las variables y la presencia de la enfermedad oral y su influencia en el comportamiento de los modelos predictivos. Así este proyecto ilustra las posibilidades de utilizar la metodología de la Ciencia de Datos para crear modelos predictivos que puedan ser útiles para la toma de decisiones y la generación de evidencia cuantitativa acerca de las variables asociadas a la enfermedad oral.

4. Objetivos

4.1 GENERAL

Evaluar las capacidades de los algoritmos de aprendizaje automático para predecir el riesgo de una enfermedad oral en relación con factores socioeconómicos y al comportamiento usando datos de salud abiertos para poder juzgar su eficacia como una herramienta de apoyo a la prevención y a la toma de decisiones basadas en datos.

4.2 ESPECÍFICOS

i. Identificar y seleccionar conjuntos de datos abiertos que contengan información relevante sobre variables socioeconómicas, hábitos de salud y enfermedades bucodentales.

ii. Preparar y estructurar los datos mediante procesos de limpieza, transformación e integración, garantizando su calidad y adecuación para el análisis.

iii. Analizar las características del conjunto de datos mediante técnicas de estadística descriptiva y análisis exploratorio, con el fin de identificar patrones, tendencias y posibles relaciones entre las variables estudiadas.

iv. Diseñar una estrategia de gestión y almacenamiento de los datos que asegure la organización, trazabilidad y reproducibilidad del proyecto.

v. Desarrollar y entrenar modelos de aprendizaje automático para la estimación de la probabilidad de presentar enfermedad bucodental a partir de variables socioeconómicas y hábitos de salud.

vi. Evaluar y comparar el desempeño de los modelos desarrollados mediante métricas adecuadas de clasificación, identificando las técnicas con mayor capacidad predictiva.

vii. Interpretar y visualizar los resultados obtenidos para determinar la relevancia de las variables analizadas y facilitar la comprensión de los patrones identificados.

viii. Analizar el potencial de los modelos predictivos desarrollados como herramientas de apoyo para la identificación temprana de grupos poblacionales con mayor riesgo de desarrollar enfermedades bucodentales.

ix. Reflexionar sobre la aplicabilidad de la metodología propuesta a otros ámbitos de la salud pública en los que intervengan factores socioeconómicos y conductuales, identificando posibles líneas futuras de investigación y desarrollo.

5. Marco Teórico

5.1 CIENCIA DE DATOS Y TOMA DE DECISIONES BASADA EN DATOS

5.1.1 Qué es la Ciencia de Datos

La Ciencia de Datos es un área interdisciplinaria que implica combinar el conocimiento de las estadísticas, la informática, las matemáticas y el aprendizaje automático para obtener conocimiento del análisis de grandes cantidades de datos. El principal objetivo de esta disciplina es transformar los datos en evidencia que nos ayude a comprender los fenómenos y a resolver problemas (Provost y Fawcett,2013).

Provost y Fawcett (2013) definen la Ciencia de Datos como *"principles, processes, and techniques for understanding phenomena via the (automated) analysis of data"* (p. 4). Por lo tanto, la definición revela que el campo no se limita al uso de la tecnología informática y/o algoritmos de análisis. Incluye el conjunto completo de principios, procesos y técnicas dedicadas a la comprensión de los fenómenos a través del análisis de datos.

Por lo tanto, la Ciencia de Datos incluye todas las etapas del proceso de análisis desde el reconocimiento del problema y la recolección de información hasta el procesamiento de datos, el análisis y la interpretación. El verdadero valor de los datos no consiste solamente en su cantidad sino en su transformación en conocimiento que nos ayude a tomar decisiones y a resolver problemas (Provost y Fawcett, 2013).

Figura 1. Proceso general de la Ciencia de Datos.



Fuente: Elaboración propia.

5.1.2 Evolución de la disciplina

El surgimiento de la Ciencia de Datos está intrínsecamente ligado al aumento exponencial de la cantidad de datos producidos por los seres humanos, las instituciones y los sistemas digitales. Durante los últimos decenios el auge de Internet, el proceso de la digitalización y el aumento de las capacidades de almacenamiento han dado como resultado enormes volúmenes de datos que requieren el diseño de métodos capaces de analizar dichos datos de manera eficaz (Provost y Fawcett,2013).

Paralelamente el aumento del poder de cómputo, las mejoras en las comunicaciones y los algoritmos han facilitado el procesamiento de conjuntos de datos más complejos. Así la Ciencia de Datos, inicialmente compuesta por métodos utilizados exclusivamente con fines académicos, ha evolucionado a un área estratégica aplicable a la mayoría de los sectores económicos y sociales (Provost y Fawcett,2013).

Como señalan Provost y Fawcett (2013), *"with vast amounts of data now available, companies in almost every industry are focused on exploiting data for competitive advantage" (p. 6).* Como consecuencia de esta tendencia han surgido nuevas áreas como el Aprendizaje Automático, la Inteligencia Artificial y el Análisis Predictivo que han contribuido a ampliar aún más las aplicaciones de la Ciencia de Datos.

5.1.3 Aplicaciones en distintos sectores

Las aplicaciones de la Ciencia de Datos se extienden a muchos diferentes sectores debido a que la Ciencia de Datos tiene el potencial de convertir los datos en información valiosa. En el sector financiero se puede aplicar en la evaluación del riesgo de crédito, la detección de fraudes e inversiones.

En el marketing puede ayudar a comprender el comportamiento del consumidor, el marketing personalizado y mejorar la segmentación de los consumidores. En la industria se puede aplicar en la predicción de fallas de equipos, la optimización de procesos de producción y aumentar la eficiencia (Provost y Fawcett,2013).

De la misma manera en el área del comercio electrónico es posible desarrollar motores de recomendación que sugieran productos de acuerdo con las preferencias y hábitos de los usuarios. Las organizaciones públicas también hacen uso de las técnicas de la Ciencia de Datos para diseñar la política pública y gestionar los recursos (Provost y Fawcett,2013).

Tabla 1. Principales aplicaciones de la Ciencia de Datos en diferentes sectores.

Sector	Aplicaciones principales
Finanzas	Detección de fraude, análisis del riesgo crediticio, predicción financiera
Marketing	Segmentación de clientes, sistemas de recomendación, análisis de comportamiento
Industria	Mantenimiento predictivo, optimización de procesos, control de calidad
Sector público	Gestión de recursos, políticas públicas, análisis demográfico
Salud	Diagnóstico asistido, predicción de enfermedades, medicina personalizada

Fuente: Elaboración propia a partir de Provost y Fawcett (2013).

5.1.4 Importancia de los datos abiertos

Los datos abiertos son información que es de acceso libre, reutilizable y distribuible por cualquier persona sin limitaciones en cuanto a la legislación y la economía (Gurin,2014).

La presencia de los datos abiertos contribuye a la transparencia de las instituciones, las innovaciones tecnológicas y la realización de investigaciones científicas basadas en un enfoque basado en la evidencia. Además los datos abiertos permiten que científicos, empresas y organismos gubernamentales cooperen en el proceso de crear conocimiento científico y resolver problemas sociales (Gurin,2014).

En la ciencia los datos abiertos significan una oportunidad para realizar investigaciones reproducibles y comparables que permitan validar los resultados de la investigación y generar nuevos conocimientos. La disponibilidad de bases de datos a gran escala como NHANES ha tenido un gran impacto en el desarrollo de la investigación en salud pública, la epidemiología y la medicina preventiva debido a la alta calidad y los estándares de la información recolectada (Centros para el Control y la Prevención de Enfermedades [CDC],2024).

Sin embargo, los datos abiertos no pueden solucionar las limitaciones que ya están incorporadas al diseño original de la base de datos. Aspectos como la calidad de la información, el sesgo que resulta del diseño de la muestra, las variables disponibles y las limitaciones de cada conjunto de datos en particular deben ser considerados en el curso del análisis. Al mismo tiempo a pesar de estar disponibles para fines de investigación la publicación de los datos debe hacerse de forma anónima (CDC,2024).

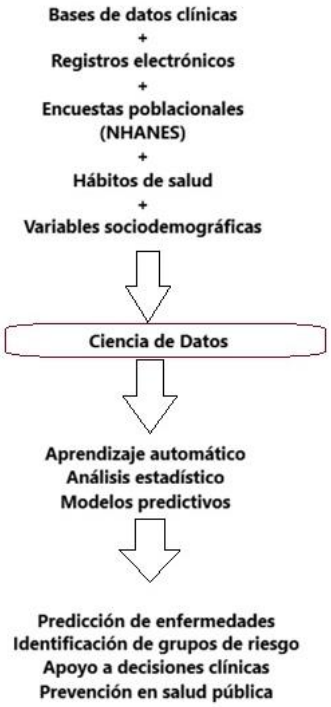
5.1.5 Ciencia de Datos en salud

El uso de la Ciencia de Datos en la industria de la salud ha transformado la forma en que se recopilan, procesan, analizan e interpretan los datos de la salud poblacional. Los registros de salud electrónicos, los sistemas de vigilancia epidemiológica y las bases de datos clínicas han producido mucha información que se puede analizar utilizando estadísticas, la minería de datos y el aprendizaje automático para producir un conocimiento útil (Yang y Lee,2019).

Utilizando estas herramientas se vuelve posible integrar la información de varias fuentes, identificar patrones y construir modelos analíticos que ayuden a tomar decisiones en varios campos dentro del sector de la salud. También se vuelve fácil analizar escenarios más complejos que involucran factores demográficos, socioeconómicos, conductuales y clínicos (Yang y Lee,2019).

En este caso la Organización Mundial de la Salud señala que la transformación digital del sector de la salud es un aspecto importante en la prestación de una mejor atención y de sistemas de salud y procesos de toma de decisiones basados en la evidencia (*World Health Organization, 2021)*. La aplicación de estos métodos en campos específicos como la salud pública y la salud oral se discutirá más adelante en este artículo.

Figura 2. Aplicación de la Ciencia de Datos en el ámbito sanitario.



Fuente: Elaboración propia.

5.2 APRENDIZAJE AUTOMÁTICO Y MODELOS PREDICTIVOS

5.2.1 ¿Qué es el aprendizaje automático?

El Aprendizaje Automático (*Machine Learning*) es un campo de la Inteligencia Artificial (IA) que tiene como objetivo crear algoritmos capaces de aprender a partir de los datos y de utilizar su experiencia para predecir o tomar decisiones sin la necesidad de programar explícitamente cada caso (Géron, 2023).

El Aprendizaje Automático se contrapone al enfoque tradicional de programar un sistema cuyo comportamiento se basa en un conjunto de reglas previamente escritas por un programador ya que permite al modelo detectar la relación entre las variables analizando ejemplos y mejora su capacidad de hacer predicciones mediante el crecimiento de la cantidad de datos y la mejora de su calidad (James et al., 2021; Géron, 2023).

Uno de los pioneros en definir el aprendizaje automático fue el investigador Arthur Samuel quien afirmó que: *"[Machine Learning is the] field of study that gives computers the ability to learn without being explicitly programmed."* (Géron, 2023, p. 4). Es de destacar que esta definición sigue siendo una de las más populares en la literatura científica ya que captura la esencia misma de este campo científico.

El progreso del Aprendizaje Automático siempre ha estado estrechamente relacionado con el crecimiento de los datos digitales, el aumento del poder de cómputo de las computadoras y el desarrollo de las tecnologías de almacenamiento de datos. A pesar de que las primeras investigaciones sobre el aprendizaje automático se realizaron en la segunda mitad del siglo XX el verdadero desarrollo de esté mismo, comenzó a partir de la década de los 90 bajo la influencia de la digitalización de los procesos empresariales y el surgimiento de Internet (Géron, 2023; James et al., 2021).

5.2.2 Aprendizaje supervisado

El aprendizaje supervisado *(Supervised Learning)* es uno de los enfoques más importantes del aprendizaje automático y se describe mediante el uso de un conjunto de datos etiquetados en el proceso de entrenamiento de un modelo. En este tipo de aprendizaje, cada observación está formada por un conjunto de variables predictoras *(predictors, features o inputs)* y una variable respuesta *(response o output),* cuyo valor es conocido y sirve como referencia para que el algoritmo aprenda la relación existente entre ambas (James et al., 2021).

Según James et al. (2021) *"supervised statistical learning refers to building a statistical model for*

predicting, or estimating, an output based on one or more inputs" (p. 17). El propósito del aprendizaje supervisado es desarrollar modelos que puedan generalizar el conocimiento adquirido y realizar predicciones sobre nuevas observaciones. Es esencial evitar la memorización del conjunto de entrenamiento para favorecer el proceso de generalización (James et al., 2021).

Los problemas que se abordan mediante el aprendizaje supervisado pueden clasificarse ya sea como problemas de regresión o de clasificación dependiendo de la naturaleza de la variable objetivo. En este estudio el uso del aprendizaje supervisado se justifica por el hecho de que la variable objetivo se conoce en el momento del entrenamiento y se refiere a la presencia o ausencia de una enfermedad oral, por lo que la investigación se clasifica como un problema de clasificación binaria.

5.2.3 Problemas de clasificación

El objetivo de los problemas de clasificación es asignar cada observación a una clase previamente definida basándose en los valores de las variables predictoras (James et al., 2021). A diferencia de los problemas de regresión, la clasificación no estima ninguna variable numérica continua, sino que se ocupa de variables categóricas o cualitativas.

Según James et al. (2021) *"classification refers to the problem of predicting a qualitative response as opposed to a quantitative one"* (p. 18). En este enfoque el modelo se entrena con ejemplos etiquetados para poder predecir las clases de nuevos ejemplos y en muchos casos estimar la probabilidad de pertenecer a cada clase posible (Géron, 2023).

Los problemas de clasificación pueden ser binarios o multiclases. En la clasificación binaria existen dos clases posibles mientras que en la clasificación multiclases el modelo elige una clase entre tres o más opciones (James et al., 2021). La clasificación binaria es una de las tareas más comunes en la biomedicina porque ayuda a modelar situaciones donde la variable de interés está presente o ausente.

En este estudio la tarea es resolver un problema de clasificación binaria donde la variable objetivo ***(ENFERMEDAD_BUCODENTAL)*** diferencia la presencia o ausencia de una enfermedad oral en términos de variables sociodemográficas y hábitos de salud del banco de datos NHANES 2011-2012.

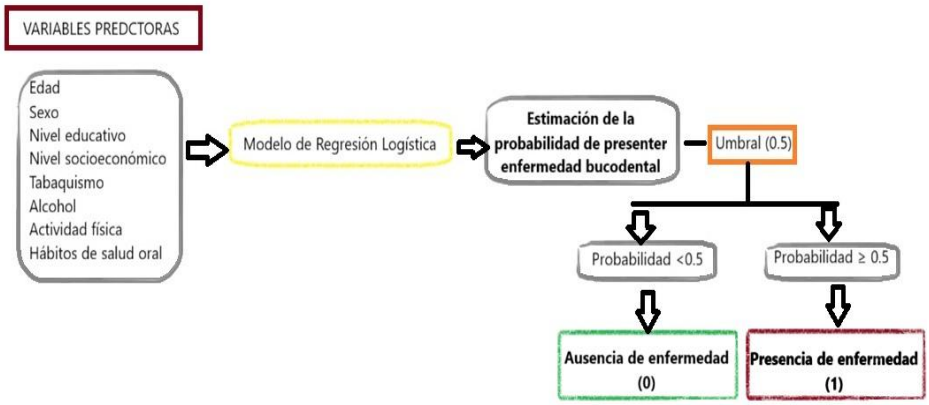
5.2.4 Regresión logística

La regresión logística se encuentra entre los algoritmos de clasificación más populares en el aprendizaje supervisado, especialmente aquellos que se ocupan de las ciencias de la salud o la epidemiología. La regresión logística busca estimar la probabilidad de que una observación pertenezca a una de las categorías dadas un conjunto de variables predictoras (James et al., 2021).

Mientras que la regresión lineal se utiliza para predecir los valores de una variable numérica continua la regresión logística se utiliza cuando el resultado es categórico, principalmente binario. La forma en la que este algoritmo cumple con su tarea es usando una función logística para transformar cualquier número en una probabilidad entre 0 y 1. Como afirma James et al. (2021), *"rather than modeling this response Y directly, logistic regression models the probability that Y belongs to a particular category" (p. 134).*

Una vez estimada la probabilidad la regresión logística asigna un umbral (generalmente 0.5) para clasificar una observación en una de dos categorías. Además de clasificar las observaciones la regresión logística ofrece la oportunidad de interpretar la asociación entre las variables predictoras y la variable objetivo a través de coeficientes los cuales cuantifican el efecto de las variables predictoras en las probabilidades logarítmicas (logaritmos de las probabilidades relativas (*log-odds*)) de la variable objetivo. Esta capacidad del algoritmo da origen a su popularidad en la investigación biomédica y epidemiológica.

Figura 3. Funcionamiento general de un modelo de regresión logística



Fuente: Elaboración propia.

Entre los principales beneficios de la regresión logística se encuentra el hecho de que este algoritmo es bastante simple, rápido y altamente interpretable. Gracias a estas características es posible examinar la contribución de cada predictor al modelo y analizar su relación con la variable objetivo.

Sin embargo, la interpretación de los coeficientes de la regresión logística depende de cómo las variables del modelo estén codificadas y escaladas. Al mismo tiempo la regresión logística tiene algunas limitaciones que se hacen evidentes en la presencia de relaciones altamente no lineales entre las variables e interacciones complejas (James et al., 2021).

Debido a su simplicidad y uso extensivo en la literatura científica la regresión logística sirve como un punto de referencia para la comparación con otros modelos en problemas de clasificación binaria. Por otro lado, en tiempos recientes la regresión logística ha sido complementada con modelos más complicados de aprendizaje automático como árboles de decisión y Random Forest Estos modelos tienen la ventaja de poder capturar la no linealidad entre las variables (Géron, 2023).

5.2.5 Árboles de decisión

Los árboles de decisión son algunos de los algoritmos de aprendizaje supervisado más utilizados para resolver problemas de clasificación y regresión. El funcionamiento de este algoritmo se basa en una estructura jerárquica compuesta por nodos, ramas y hojas, donde cada nodo corresponde a la regla de decisión realizada sobre una variable predictora mientras que la hoja corresponde al resultado de la predicción (James et al.,2021).

Como indica Géron (2023) los árboles de decisión van dividiendo los datos gradualmente en grupos cada vez más homogéneos utilizando una serie de divisiones binarias. Este enfoque permite identificar los patrones entre las variables y obtener un modelo que sea fácil para un usuario comprender su lógica.

Una de las principales ventajas de este algoritmo es su capacidad de representar visualmente el procedimiento de clasificación. Todas las decisiones tomadas por un árbol se pueden representar como reglas simples y permiten comprender el camino que lleva a una predicción determinada.

Figura 4. Estructura simplificada de un árbol de decisión. Fuente: Elaboración propia.



No obstante, los árboles de decisión presentan ciertas limitaciones. Géron (2023) señala que estos modelos son sensibles a pequeñas variaciones en los datos de entrenamiento, pudiendo generar estructuras muy diferentes cuando se modifican ligeramente las observaciones disponibles. Asimismo, un árbol excesivamente profundo puede ajustarse en exceso a los datos de entrenamiento, fenómeno conocido como sobreajuste (*overfitting*), reduciendo su capacidad para generalizar correctamente sobre nuevos datos.

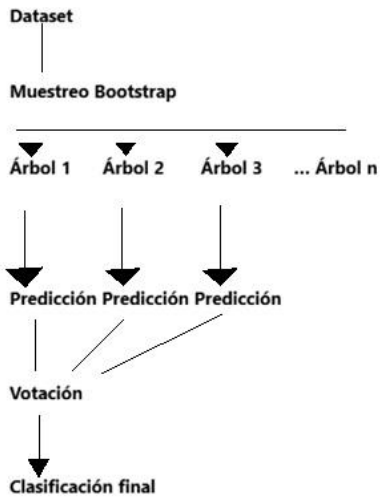
Debido a estas limitaciones, en numerosas aplicaciones los árboles de decisión se utilizan como modelos base para construir métodos de ensamblado (*ensemble methods*), siendo Random Forest uno de los algoritmos más representativos de esta familia (Géron, 2023).

5.2.6 Random Forest

Random Forest es un algoritmo de aprendizaje automático supervisado que combina varios árboles de decisión construidos a partir de diferentes muestras aleatoriamente seleccionadas y diferentes variables aleatoriamente seleccionadas. En lugar de construir solo un árbol de decisión este algoritmo crea un conjunto de árboles usando diferentes muestras aleatorias del conjunto de datos y diferentes muestras aleatorias de las variables predictoras. La decisión final se produce mediante un voto entre todos los árboles incluidos en el bosque (Breiman,2001).

Según el desarrollador de este algoritmo, Breiman (2001), "*Random forests are a combination of tree predictors*" (p. 5). Este enfoque ayuda a aumentar la estabilidad de los modelos ante pequeños cambios en el conjunto de entrenamiento.

Figura 5. Funcionamiento general del algoritmo Random Forest.



Fuente: Elaboración propia.

No solo la mayor estabilidad del modelo sino también la capacidad de descubrir relaciones complejas y no lineales entre las variables y el gran número de predictores mientras se estima la importancia relativa de cada predictor hacen que este clasificador sea efectivo en el proceso de clasificación (Géron, 2023).

Además, se debe mencionar que este enfoque de aprendizaje automático reduce el problema de la varianza y el sobreajuste en comparación con un árbol de decisión individual porque depende no solo de la configuración de los hiperparámetros y las características de los datos sino también de la combinación de árboles entrenados en diversos subconjuntos tanto de los datos como de las variables. De esta manera el error de cada árbol en particular se compensa debido al procedimiento de votación (James et al., 2021).

El uso de tales características hace que este clasificador sea uno de los más populares en la investigación relacionada con la salud. Se utiliza ampliamente en el desarrollo de modelos predictivos que ayudan a determinar factores de riesgo, la probabilidad de una enfermedad y apoyan las decisiones clínicas (Géron, 2023).

5.3 APLICACIONES DEL APRENDIZAJE AUTOMÁTICO EN EL ÁMBITO SANITARIO

5.3.1 Inteligencia Artificial y salud pública

La Inteligencia Artificial (IA) representa una de las innovaciones digitales que están siendo adoptadas por los sistemas de salud de todo el mundo. La integración de esta innovación ha permitido la capacidad de procesar grandes cantidades de datos relacionados con la salud para aumentar, lo que permite el análisis de los datos de los registros médicos electrónicos, los registros hospitalarios, los estudios epidemiológicos, entre otras fuentes de información relacionadas con la salud. Estas innovaciones permiten la facilitación de decisiones basadas en la evidencia y la mejora de la planificación de los servicios de salud.

La Global Strategy on Digital Health 2020–2025 establece como visión *"improve health for everyone, everywhere by accelerating the development and adoption of appropriate, accessible, affordable, scalable and sustainable person-centric digital health solutions"* (World Health Organization, 2021, p. 10). Es importante destacar que la transformación digital debe contribuir a la mejora de los sistemas de salud a través del uso de tecnologías digitales que ayuden a mejorar los servicios de salud y la salud pública y lograr la cobertura universal de salud.

Además, uno de los objetivos de esta estrategia es el fortalecimiento de la gobernanza de los

datos de salud, la estandarización de la interoperabilidad y el uso responsable de las tecnologías incluyendo la Inteligencia Artificial y el análisis de datos para los fines de la investigación, la vigilancia epidemiológica y la toma de decisiones dentro de los sistemas de salud.

5.3.2 Modelos predictivos en salud: aplicaciones y limitaciones

La creación de modelos predictivos representa uno de los campos más consolidados del aprendizaje automático aplicado al sector de la salud. Consiste en calcular la probabilidad de la aparición de una enfermedad específica en un paciente basado en el análisis conjunto de una variedad de factores clínicos, demográficos, ambientales, conductuales y socioeconómicos. La peculiaridad de los algoritmos utilizados aquí radica en la posibilidad de tomar en cuenta múltiples variables e identificar interacciones complicadas entre ellas, lo cual aumenta la efectividad de los modelos (Yang y Lee,2019).

Con la ayuda de estos enfoques se ha hecho posible introducir un enfoque preventivo en la investigación y la práctica de la salud pública para estratificar a la población según el riesgo de desarrollar ciertas enfermedades y planificar intervenciones para los segmentos más vulnerables. En este punto los modelos predictivos pueden ser vistos como herramientas auxiliares para la toma de decisiones, la planificación de la salud y la optimización de los recursos, pero no como un reemplazo del razonamiento clínico y el enfoque basado en la evidencia (Organización Mundial de la Salud,2021).

En cuanto al área de la salud oral las técnicas de aprendizaje automático han experimentado una popularidad considerable recientemente. Así, según Hasuike et al. (2022) en la revisión sistemática se afirma que los algoritmos tienen un alto potencial en cuanto a la mejora de la predicción de la evolución dental. Sin embargo, los investigadores hacen hincapié en la importancia de obtener grandes bases de datos e implementar procedimientos de validación más rigurosos para minimizar el sesgo. De manera similar Ogwo et al. (2024) lograron desarrollar modelos que predicen la probabilidad de que una persona tenga caries utilizando factores sociodemográficos, dietéticos y conductuales. Los autores encontraron que la integración de varias variables aumenta el valor predictivo de los modelos en comparación con los convencionales. Asimismo, según Çiftçi et al. (2024) diferentes algoritmos de aprendizaje automático permiten lograr una estratificación precisa de grupos con diferentes probabilidades de tener caries, lo cual demuestra un alto potencial de la herramienta para mejorar las intervenciones preventivas.

Sin embargo, la efectividad de los modelos predictivos depende de muchos factores como la

calidad de los datos, la representatividad de la población bajo análisis, el proceso de validación y la capacidad de generalización. Es por eso por lo que la interpretación de los resultados debe hacerse con cuidado y la información debe tomarse en cuenta como un complemento a la evidencia clínica y epidemiológica pero no como un reemplazo de la toma de decisiones profesionales.

5.4 SALUD BUCODENTAL COMO PROBLEMA DE SALUD PÚBLICA

5.4.1 Salud bucodental como componente de la salud general

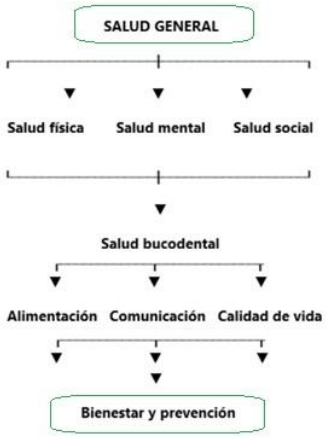
La salud bucal constituye una parte integral de la salud y el bienestar general de las personas. La importancia de ella no solo radica en la ausencia de enfermedades de la cavidad oral sino también en la influencia en procesos fisiológicos básicos como la nutrición, la comunicación, la respiración y la socialización. Por lo tanto, mantener una salud bucal óptima es necesario para la preservación de la calidad de vida y el buen bienestar físico, psicológico y social de las personas (World Health Organization [WHO], 2022).

Segun la OMS "*the state of the mouth, teeth and orofacial structures that enables individuals to perform essential functions such as eating, breathing and speaking, and encompasses psychosocial dimensions such as self-confidence, well-being and the ability to socialize and work without pain, discomfort or embarrassment" (WHO, 2022, p. 8).*

Esta definición muestra un cambio de paradigma en los conceptos tradicionales de la salud bucal que se concentraban únicamente en la presencia de la enfermedad a favor de un enfoque holístico moderno que destaca el vínculo cercano entre la salud bucal y la condición general de una persona.

Las enfermedades orales se han convertido en uno de los mayores problemas de salud pública en la actualidad. La Organización Mundial de la Salud afirma que 3.5 mil millones de personas sufren de alguna forma de enfermedad oral. Las más comunes son las caries dentales, la enfermedad periodontal y la pérdida de dientes y representan una carga económica y social sustancial para los sistemas de salud (OMS,2022).

Figura 6. La salud bucodental como componente de la salud general.



Fuente: Elaboración propia.

En la misma línea Peres y otros (2019) destacan el hecho de que las enfermedades orales tienen varios factores de riesgo que son comunes con otras enfermedades crónicas no transmisibles como las enfermedades cardiovasculares, la diabetes, algunos tipos de cáncer y las enfermedades respiratorias. Algunos de estos factores de riesgo son el consumo de tabaco, el consumo excesivo de azúcar, el abuso del alcohol y las disparidades socioeconómicas.

Además, los autores indican que la prevención es la mejor manera de enfrentar la carga de las enfermedades orales a nivel mundial y por lo tanto las políticas de salud deberían enfocarse en fomentar buenas prácticas, eliminar factores de riesgo comunes y garantizar el acceso a la atención dental (Peres y otros,2019).

En este sentido el uso de la Ciencia de Datos y el aprendizaje automático podría resultar útil para reforzar las medidas de prevención a través de la identificación de personas con mayores posibilidades de tener enfermedades orales. La combinación de datos clínicos, sociodemográficos y de comportamiento puede llevar a la creación de modelos para fines de toma de decisiones.

5.4.2 Caries dental

La caries dental es una enfermedad crónica, multifactorial y prevenible que se desarrolla como resultado de la interacción entre los microorganismos contenidos en la placa dental, el consumo frecuente de azúcares fermentables y los factores del huésped a lo largo de un periodo de tiempo extendido (World Health Organization [WHO], 2022).

Según la Organización Mundial de la Salud la caries dental es la enfermedad oral más extendida del mundo que afecta a millones de personas. Es un grave problema de salud pública debido a su

alta tasa de prevalencia y al impacto negativo que tiene en la calidad de vida (WHO, 2022). La caries se caracteriza por un proceso dinámico de mineralización y desmineralización del esmalte dental donde la relación entre estos procesos determina si la enfermedad va a progresar o va a parar. Habrá una destrucción progresiva de los tejidos dentales y la aparición de lesiones carias cuando la desmineralización ocurra con más frecuencia que la remineralización.

Los principales factores de riesgo que aumentan la probabilidad de desarrollar caries incluyen una mala higiene bucal, el consumo frecuente de azúcares, la falta de acceso a intervenciones preventivas, un bajo estatus socioeconómico y algunos hábitos de salud. Debido a su naturaleza compleja la caries es una enfermedad muy adecuada para crear modelos predictivos basados en el aprendizaje automático que tengan en cuenta factores clínicos, conductuales y sociodemográficos (Ogwo et al.,2024).

5.4.3 Enfermedad periodontal

La enfermedad periodontal se refiere a un conjunto de condiciones inflamatorias que involucran los tejidos que sostienen los dientes como son las encías, el ligamento periodontal, el cemento radicular y el hueso alveolar. La progresión de la enfermedad periodontal conduce a la pérdida de la unión clínica, la destrucción de los huesos e incluso en etapas avanzadas la pérdida del diente. Esta enfermedad afecta la función de masticación y la calidad de vida de las personas (Organización Mundial de la Salud [OMS],2022).

La periodontitis se refiere a la etapa más avanzada de la enfermedad periodontal y su desarrollo resulta de una reacción inflamatoria causada por un biófilo que está afectado por factores biológicos, conductuales y ambientales. Los principales factores de riesgo asociados con esta condición son el tabaquismo, la diabetes, la edad, la mala higiene oral y el estado socioeconómico entre otros (Tonetti et al.,2018).

Para proporcionar consistencia en la vigilancia epidemiológica de la periodontitis, Eke et al. (2012) revisaron la definición de la condición en estudios poblacionales y concluyeron que " Periodontitis surveillance definitions should be based on measurements of clinical attachment loss and probing depth." (p.1450). Por lo tanto, la clasificación de la periodontitis depende principalmente de dos mediciones clínicas, a saber la pérdida de la unión clínica (CAL) y la profundidad del sondaje (PD).

5.4.4 Factores de riesgo asociados

Las causas de las enfermedades orales y dentales son bastante multifactoriales debido a la interacción de factores biológicos, conductuales, socioeconómicos y ambientales. La aparición y el desarrollo tanto de la caries dental como de la enfermedad periodontal se basan en la presencia de numerosos factores de riesgo. Por lo tanto, la aparición y el desarrollo de las enfermedades orales y dentales no ocurren bajo la influencia de solo un factor sino bajo el efecto conjunto de varios determinantes (Peres et al., 2019; Organización Mundial de la Salud [OMS], 2022).

En este sentido cabe destacar que la edad de los pacientes es uno de los factores biológicos. La edad aumenta la exposición acumulativa a los factores de riesgo lo cual aumenta la probabilidad de la enfermedad. Además, algunos estudios han identificado la prevalencia y el desarrollo de estas enfermedades dependiendo del género de los pacientes porque pueden variar dependiendo de factores biológicos y otros hábitos de salud (Peres et al., 2019).

Sin embargo, cabe resaltar que los factores conductuales juegan un gran papel. Uno de los principales factores de riesgo en el caso de la enfermedad periodontal es el tabaquismo ya que contribuye al aumento de la destrucción de los tejidos que sostienen el diente. Una mala higiene bucal da lugar a la formación de una película bacteriana mientras que hábitos inadecuados en la nutrición, el consumo de alcohol y el estilo de vida contribuyen al desarrollo de enfermedades orales y dentales (Tonetti et al., 2018; OMS, 2022).

Finalmente cabe resaltar que el estado socioeconómico también afecta significativamente la salud bucal. Variables como la educación, el ingreso y el acceso a los servicios de salud se encuentran entre esos factores que influyen en la exposición a los factores de riesgo, el comportamiento saludable y la atención dental adecuada. Por consiguiente, la investigación científica muestra que el desarrollo de las enfermedades orales y dentales es causado por la compleja interacción de factores biológicos, conductuales y socioeconómicos.

Tabla 2. Principales factores de riesgo asociados a las enfermedades bucodentales.
Fuente: Elaboración propia a partir de Peres et al. (2019), Tonetti et al. (2018) y World Health Organization (2022).

CATEGORÍA	FACTORES CONSIDERADOS
Biológicos	Edad, Sexo
Conductuales	Tabaquismo, consumo de alcohol, higiene oral, actividad física
Socioeconómicos	Nivel educativo, Income-to-Poverty Ratio (PIR), acceso a la atención odontológica

5.5 Estado del arte

En la actualidad los métodos de aprendizaje automático se utilizan comúnmente en la odontología para la construcción de modelos que puedan predecir enfermedades orales y dentales y revelar posibles relaciones entre las variables. Recientemente la literatura muestra cómo los modelos de aprendizaje automático pueden incluir una variedad de variables (clínicas, sociodemográficas y de comportamiento) y estimar la probabilidad de desarrollar caries, periodontitis o pérdida de dientes a pesar de algunos problemas asociados con la validez externa, sesgos e interpretación de los resultados.

El estudio clave sobre este tema es el realizado por Hasuike et al. (2022) el cual tenía como objetivo estimar la posibilidad de utilizar modelos de aprendizaje automático para predecir la pérdida de dientes. Como señalaron los autores estos métodos son prometedores para mejorar el pronóstico en la odontología, pero muchos estudios en este campo sufren del problema de los sesgos y requieren una validación metodológica adicional.

En cuanto a las caries dentales Ogwo et al. (2023) propusieron modelos de aprendizaje automático que podrían predecir los resultados relacionados con el desarrollo de caries dentales basados en variables longitudinales. El estudio ha mostrado valores satisfactorios de la precisión y la precisión de los modelos propuestos y reveló la posibilidad de utilizarlos como herramientas de detección para pacientes con alta probabilidad de desarrollar la enfermedad.

De manera similar, Çiftçi et al. (2024) estimaron el desempeño de diferentes algoritmos de aprendizaje automático en la clasificación de pacientes según la probabilidad de desarrollar caries y identificaron factores que afectan la salud bucal. El estudio ha comparado el desempeño de varios modelos predictivos y ha revelado la posibilidad de utilizar los métodos de aprendizaje automático para clasificar a los pacientes según la probabilidad de tener la enfermedad.

Teniendo en cuenta los hallazgos obtenidos por la literatura revisada se puede observar que la mayoría de los estudios se enfocan en un tipo específico de patología oral y utilizan diferentes combinaciones de variables clínicas, sociodemográficas y de comportamiento para construir modelos predictivos. Estos estudios muestran el potencial del aprendizaje automático como herramienta para la investigación odontológica a pesar de que existen algunas limitaciones asociadas con la inconmensurabilidad entre estudios, los problemas de la validez externa, la interpretación de los resultados y los sesgos metodológicos.

6. Metodología

6.1 DISEÑO DE LA INVESTIGACIÓN

El trabajo se planteó con un enfoque cuantitativo, observacional y retrospectivo basado en un análisis secundario de datos abiertos del *National Health and Nutrition Examination Survey (NHANES),* correspondiente al ciclo 2011–2012. Para ponerlo de forma simple, se eligió cuantitativo porque había una necesidad de poder medir numéricamente variables como edad, ingresos, nivel educativo, tabaquismo, etc. Y que estas sean capaces de estimar la presencia o no de la enfermedad dental. Como lo señalan Provost y Fawcett (2013) en su libro, este tipo de enfoque es apropiado cuando se necesita entender patrones en conjunto de datos grandes y crear modelos predictivos.

Por otro lado, es observacional ya que no se lleva a cabo intervenciones clínicas o de recolección de datos. Y, además, es un estudio retrospectivo ya que al utiliza datos de NHANES, es decir daros que ya están recolectados y publicados y no se requiere de ningún otro tipo de recolección de datos. Este enfoque se utiliza hoy en día ampliamente en estudios epidemiológicos, ya que permiten crear modelos predictivos usando información de la población de alta calidad y reproducibilidad (James et al., 2021).

Ahora bien, para responder que metodología se utilizó, el flujo clásico de un proyecto de Ciencias de Datos. Como lo describen Provost y Fawcett (2013) este flujo consiste en varias etapas incluyendo la comprensión del problema, la adquisición y preparación de los datos, la creación y evaluación de los modelos predictivos. Siguiendo el marco metodológico proporcionado el presente estudio incluye la identificación de la fuente de la información, la integración de datos de diferentes módulos de NHANES, la limpieza y transformación de los datos, la creación de la variable objetivo-binaria, el análisis exploratorio de datos, el desarrollo de modelos de aprendizaje automático, su evaluación y la visualización de los resultados.

La variable objetivo se define con presencia o ausencia de enfermedad, por lo que es una clasificación binaria. El problema se planteó así para facilitar clasificación. Y se considera la presencia de caries y/o periodontitis como enfermedad. Para resolver esta clasificación se crearon modelos supervisados que estiman el porcentaje de riesgo de enfermedad. Y según James et al. (2021), este enfoque es uno de los más utilizados para los proyectos de clasificación en el aprendizaje automático.

Existen otros enfoques metodológicos para resolver problemas de predicción de riesgo de enfermedad, por ejemplo, la clasificación multiclases, el uso de regresión para variables continuas o algoritmos más sofisticados. Pero se ha elegido una clasificación binaria con modelos de aprendizaje automático supervisados por considerarse la más adecuada para el alcance de este trabajo. En el apartado de líneas futuras se introducen las posibles mejoras en algoritmos más sofisticados, entre otras mejoras.

6.2 MATERIALES

6.2.1 Fuente de datos

Los datos que se utilizaron fueron extraídos de la *National Health and Nutrition Examination Survey* (NHANES), desarrollada por el *National Center for Health Statistics* (NCHS), perteneciente a los *Centers for Disease Control and Prevention* (CDC) de los Estados Unidos. El diseño de NHANES es una encuesta combinada que incluye entrevistas, cuestionarios y exámenes clínicos y físicos con el objetivo de evaluar el estado de salud y nutricional de la población de los Estados Unidos (CDC, 2024).

A continuación, se enumeran algunas de las principales características de NHANES:

- Inclusión de información de múltiples dominios de salud como variables demográficas, socioeconómicas, clínicas, nutricionales y de comportamiento.
- Permite el análisis combinado de diferentes factores vinculados al desarrollo de enfermedades
- Ayuda a explorar las relaciones entre las condiciones de salud y posibles factores de riesgo:
- Se ha vuelto una herramienta popular en la investigación epidemiológica y de salud pública.

Se selecciono NHANES como fuente de datos por estas características mencionadas y además por la presencia de los datos clínicos objetivos recolectados durante el examen de los participantes. Esta característica es especialmente importante para el análisis de la salud bucal ya que permite el uso de mediciones estandarizadas y reduce la dependencia de la información auto informada. Además, la accesibilidad de la base de datos contribuye a la reproducibilidad del análisis y permite comparar los resultados con otros estudios realizados sobre el mismo conjunto de datos.

Para este trabajo, se seleccionó un ciclo de dos años (NHANES 2011-2012) ya que tiene todos los datos necesarios para la construcción de variables relacionadas con caries, periodontitis, y relacionadas con niveles socioeconómicos y de comportamiento. Dentro de este ciclo hay información clínica relacionada con información de caries, profundidad de sondaje, retracción gingival, nivel de inserción dental, pérdida ósea, entre otros. Que fue fundamental para definir la variable objetivo.

La razón de por qué se eligió solo un ciclo, es que se priorizó mantener la homogeneidad de los protocolos, de las variables, y los criterios de procesamiento de datos. Como se comentará luego, al aumentar el número de ciclos aumentaría el tamaño de muestra, pero también requeriría trabajos de mayor armonización que no se consideraron dentro de los límites de este trabajo. Pero si plantearlo como línea futura.

Tabla 3. Base de datos utilizada en la investigación.

CARACTERÍSTICA	DESCRIPCIÓN
Base de datos	National Health and Nutrition Examination Survey (NHANES)
Organismo responsable	Centers for Disease Control and Prevention (CDC)
Ciclo utilizado	2011-2012
Tipo de estudio	Encuesta nacional de salud y nutrición
País	Estados Unidos
Acceso	Público y gratuito
Sitio web	https://www.cdc.gov/nchs/nhanes

Fuente: Elaboración propia a partir del CDC (2024).

6.2.2 Archivos de NHANES utilizados

NHANES organiza los datos en diferentes módulos temáticos, ubicados en diferentes archivos independientes. Para este trabajo, fue necesario procesar y unos estos archivos a través del identificador único de cada participante (***SEQN***), con el fin de que la base de datos sea unificada y confiable.

La selección de estos módulos se llevó a cavo teniendo en cuenta la literatura científica, que fue explicada en el marco teórico. Para poder entender que tipo de información eran relevantes para el planteo de este trabajo. Teniendo esto en cuenta, se procesador módulos de información demográfica y socioeconómica, exámenes clínicos dentales y periodontales, salud bucal y estilo de vida/comportamiento como el tabaquismo, el alcoholismo y la actividad física. Este enfoque permitió explorar los datos de diferentes aspectos de la salud antes de seleccionar el conjunto final de variables para el modelado.

La variable objetivo-binaria ***ENFERMEDAD_BUCODENTAL*** fue creada a través de los módulos de exámenes dentales y periodontales ***(OHXDEN_G y OHXPER_G)***. Que incluyen información clínica que permite discernir entre presencia o ausencia de enfermedad.

El archivo demográfico ***(DEMO_G)*** y módulos con información sobre el consumo de tabaco (**SMQ_G)**, el consumo de alcohol (**ALQ_G)** y la actividad física (**PAQ_G)** incluyeron las variables predictoras consideradas en los modelos.

Como modo de información también se hacen procesado y evaluados módulos que luego no ingresaron en el conjunto de datos final, por no presentar valor relevante. Por ejemplo, el módulo de cuestionario de salud bucal ***(OHQ_G).***

Tabla 4. Archivos de NHANES 2011–2012 utilizados en la investigación.

ARCHIVO	DESCRIPCIÓN	INFORMACIÓN PROCESADA / UTILIZADA
DEMO_G	Información demográfica y socioeconómica	SEQN, edad, sexo, grupo étnico, nivel educativo y PIR
OHXDEN_G	Examen clínico dental	Información clínica utilizada para determinar la presencia de caries dental
OHXPER_G	Examen periodontal	CAL y PD utilizadas para la clasificación de periodontitis
OHQ_G	Cuestionario de salud oral	Variables exploradas durante la preparación de los datos, posteriormente excluidas del modelado final
SMQ_G	Cuestionario sobre tabaquismo	Información utilizada para construir la variable de tabaquismo
ALQ_G	Cuestionario sobre consumo de alcohol	Información utilizada para construir la variable de consumo de alcohol
PAQ_G	Cuestionario de actividad física	Información utilizada para construir la variable de actividad física

Fuente: Elaboración propia a partir de NHANES 2011–2012 (CDC, 2024).

Gracias al identificador único (***SEQN***) asignado a cada participante NHANES, todos los archivos se pudieron vincular. Esto permitió combinar toda la información de los diferentes módulos, en un único conjunto de datos y mantener la correspondencia de cada participante.

Aunque NHANES dispone de numerosos módulos adicionales con información clínica, dietética y de laboratorio, estos no fueron incorporados al presente análisis al encontrarse fuera del conjunto de variables definido para responder a los objetivos de la investigación. La incorporación de nuevas fuentes de información y la evaluación de procedimientos adicionales de selección de variables constituyen posibles líneas de trabajo futuro.

6.3 INSTRUMENTOS COMPUTACIONALES

En este trabajo se han utilizado diferentes herramientas informáticas, las cuales están orientadas al procesamiento, análisis, modelado y visualización de datos. Se eligió *Python* como lenguaje de programación. Gracias a sus bibliotecas especializadas permite abordar de forma integrada cada

etapa del trabajo. Además, es el lenguaje que hemos utilizado en estos años de Bachillerato por lo cual tiene sentido utilizarlo para el desarrollo del trabajo final.

El desarrollo del proyecto se hizo mediante, *Visual Studio Code*, donde *Jupyter Notebook* ha servido como entorno interactivo para la documentación y realizar todas las etapas de este trabajo. La combinación de ambas herramientas permitió integrar código, resultados, visualizaciones y documentación, facilitando el seguimiento y la reproducibilidad del proceso metodológico.

Para el procesamiento y transformación de los datos se han realizado con la ayuda de la biblioteca *Pandas*, mientras que *NumPy* se empleó para cálculos numericos y transformaciones de datos.

Por otro lado, la biblioteca *Scikit-learn* se ha utilizado para el desarrollo de los modelos predictivos, esta biblioteca proporcionó las herramientas necesarias para el preprocesamiento de los datos, la división en conjuntos de entrenamiento y prueba, el entrenamiento de los algoritmos de Regresión Logística y Random Forest y la evaluación de su rendimiento mediante diferentes métricas de clasificación. Asimismo, se utilizó luego para la implementación de la ponderación de clases utilizada en la etapa de la evaluación de versiones alternativas de ambos modelos.

La creación de las visualizaciones empleadas durante el análisis exploratorio, la evaluación de los modelos y la comparación de resultados fueron generadas mediante las bibliotecas *Matplotlib* y *Seaborn*. Facilitaron la representación gráfica de las diferentes distribuciones de las variables, las matrices de confusión, las curvas ROC y comparaciones entre modelos evaluados.
Como última etapa se utilizó Power BI, en donde se pudo plasmar en un Dashboard los principales hallazgos y conclusiones de este trabajo. Además de poder evaluar mediante filtros las diferentes distribuciones de las variables. En un apartado de este trabajo, donde se explica los resultados estará más detallado. Asimismo, los diagramas metodológicos que se encuentran en el desarrollo de este trabajo fueron elaborados mediante *draw.io*.

Tabla 5. Instrumentos computacionales empleados.

INSTRUMENTO	FUNCIÓN
Python	Desarrollo del proyecto
Visual Studio Code + Jupyter Notebook	Programación, ejecución y documentación del análisis
Pandas	Manipulación, integración y preparación de datos
NumPy	Operaciones numéricas y transformación de datos
Scikit-learn	Preprocesamiento, modelado y evaluación predictiva
Matplotlib	Visualización de resultados
Seaborn	Visualización estadística
Power BI	Desarrollo del dashboard interactivo para la visualización de resultados
Draw.io	Elaboración de diagramas metodológicos

Fuente: Elaboración propia

6.4 PREPARACIÓN METODOLÓGICA DE LOS DATOS

En primer lugar, se recopiló la información de distintos módulos de NHANES dentro del ciclo elegido (2011-2012) y que previamente se han analizado y considerado relevantes para este trabajo. Como ya hemos explicado se relacionó toda la información mediante el identificador único ***(SEQN)*** para que se obtenga un conjunto de datos único que contemple toda la información requerida sobre los participantes.

Luego se llevó a cabo la limpieza de estos datos, se procesaron las variables y algunas fueron recodificadas. Se construyó la variable objetivo-binaria ***ENFERMEDAD_BUCODENTAL*** que se basa en la presencia o no de caries dentales y/o periodontitis.

Seguido a esto se realizó Análisis Exploratorio de Datos (EDA) de los datos recolectados para entender mejor la distribución de las variables, analizar si hay datos faltantes y evaluar la relación entre las variables predictoras y la objetivo. Estos resultados fueron fundamentales para construir el conjunto de variables utilizados en el proceso de modelado.

Siguiendo con el proceso de preparación de datos, fue necesario realizar una división de datos entre entrenamiento y prueba, manteniendo la distribución de la variable objetivo. Luego se realizó un preprocesamiento para cada algoritmo y se construyeron dos modelos de aprendizaje automático supervisado: *Regresión Logística y Random Forest*. Además, al evaluar los resultados se evidencio un desbalance de clases, por lo que se probaron las versiones de cada modelo con ponderación de clases.

La evaluación de los modelos se evaluó mediante métricas de clasificación incluyendo *Accuracy, Precisión, Recall, F1-score y ROC-AUC*, complementadas con matrices de confusión y curvas ROC.

Finalmente se organizaron e interpretaron los resultados de todas las etapas del análisis y se creó el dashboard de Power BI. Para esto también fue necesario crear otros CSV a través de SQL de Power BI.

6.5 MODELOS DE APRENDIZAJE AUTOMÁTICO EMPLEADOS

Se eligieron dos algoritmos de modelo de aprendizaje automático supervisado: Regresión Logística y Random Forest. La razón de esta elección es la posibilidad de poder comparar un modelo estadístico clásico, como es la Regresión Logística ampliamente utilizado en epidemiología y un algoritmo basado en árboles de decisión.

Gracias a la literatura científica que hemos citado en el marco teórico, se sabe que la *Regresión Logística* posee una alta interpretabilidad y es un modelo que es utilizado en estudios

epidemiológicos y biomédicos. Este algoritmo, permite una forma simple y replicable de tratar problemas de clasificación binaria. Permitiendo estimar cuál es la probabilidad de pertenecer a un grupo según los valores de las variables predictoras.

Por otro lado, como segundo algoritmo se eligió Random Forest. Este agrupa los resultados de varios árboles de decisión creados a partir de diferentes muestras y subconjuntos de variables predictoras. Da la posibilidad de evaluar las interacciones entre las variables predictoras y dependencias no lineales (Breiman, 2001; Géron, 2023).

Los dos algoritmos fueron entrenados con las mismas variables predictoras y la misma división en los grupos de entrenamiento y prueba, para así poder tener las mismas condiciones para su posterior evaluación. Se definió una semilla aleatoria ***(random_state=42)*** para asegurar que las operaciones aleatorias siempre tengan los mismos criterios cada una de las operaciones, y que sea más fácil verificar los resultados.

Al observar el desequilibrio de clases, se decidió también evaluar con el parámetro ***class_weight="balanced".*** Este enfoque hace que el modelo de más importancia a la categoría con minoría. Es decir, le da más visibilidad al grupo que menos aparece. Evitando así un sesgo de las clases mayoritarias. (He & Garcia, 2009).

Para la evaluación del desempeño de los modelos se utilizaron las métricas de *Accuracy, Precisión, Recall, F1-score y ROC-AUC*. El Accuracy significa la proporción de observaciones clasificadas correctamente; El Recall es la proporción de predicciones positivas entre las observaciones que pertenecen a la clase positiva; El F1-score es la media armónica entre el Precisión y el Recall. La métrica ROC-AUC permite estimar el poder discriminativo del modelo en varios umbrales de decisión (James et al., 2021; Géron, 2023).

Además de las métricas mencionadas se utilizaron matrices de confusión y curvas ROC para observar la distribución de verdaderos positivos y negativos, y falsos positivos y negativos. Además, evalúa la relación entre los diferentes umbrales de decisión.

La comparación inicial se hizo entre las versiones base y con ponderación de clases de cada algoritmo. Posteriormente se compararon los mejores modelos entre sí con respecto a las métricas de evaluación elegidas.

Tabla 6. Comparación de los modelos empleados.

Característica	Regresión logística	Random Forest
Tipo de modelo	Modelo estadístico de clasificación	Modelo de conjunto basado en árboles
Interpretabilidad	Alta	Media

Relaciones no lineales	Limitada	Sí
Interacciones entre variables	Requieren especificación	Puede capturarlas automáticamente
Complejidad	Baja	Mayor
Función en el estudio	Modelo de referencia	Modelo alternativo basado en árboles

Fuente: Elaboración propia a partir de James et al. (2021), Breiman (2001) y Géron (2023).

Tabla 7. Métricas y herramientas utilizadas para evaluar los modelos.

MÉTRICA	JUSTIFICACIÓN DE SU UTILIZACIÓN
Accuracy	Evaluar la proporción global de clasificaciones correctas
Precisión	Evaluar la fiabilidad de las predicciones positivas
Recall	Evaluar la capacidad para identificar correctamente los casos positivos
F1-score	Evaluar conjuntamente Precisión y Recall mediante una única medida
ROC-AUC	Evaluar la capacidad discriminativa del modelo considerando diferentes umbrales de clasificación
Matriz de confusión	Analizar los verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos

Fuente: Elaboración propia a partir de James et al. (2021), Géron (2023) y He y Garcia (2009).

6.6 VISUALIZACIÓN DE RESULTADOS

Como último paso de este trabajo y del apartado metodología, se realizó mediante Power Bi un tablero, de tres páginas. Esto se planteó para poder visualizar los principales hallazgos y resultados.

Para esta etapa se utilizaron los mismos datos generados en el trabajo en Python, y además en Power Bi, se crearon nuevas medidas, o columnas a través de Query para obtener las medidas especificas para la visualización.

El tablero se compone de tres páginas. La primera se planteó como un pantallazo general de la población analizada y la distribución de la enfermedad. La segunda página se enfocó en mostrar los resultados de la relación entre la enfermedad oral y las características sociodemográficas y los hábitos. Y la tercera página, se visualiza como se evaluó el modelo predictivo seleccionado y la comparación con el modelo de referencia, utilizando las medidas de evaluación.

En cada página se agregaron filtros interactivos relacionados al sexo, la actividad física, el consumo de alcohol y el tabaquismo para cambiar las visualizaciones de acuerdo con las características seleccionadas.

7. Desarrollo sostenible e impacto del proyecto

7.1 TEMPORALIZACIÓN E HITOS

Este trabajo se llevó a cabo, mediante una planificación que fue planteada desde el principio para poder estructurar todas las etapas del proyecto. Haciendo así mucho más fácil el control de las actividades a realizar, poder llegar a todos los objetivos establecidos y por supuesto coordinándolo con el calendario académico del Trabajo Final de Bachelor.

Como punto inicial, se planteó el problema a estudiar. Y se estudió la literatura científica, tanto de Ciencia de Datos como de Odontología, para poder crear un marco teórico y fundamentar las decisiones de este trabajo.

Luego se analizó la fuente de datos, que era lo más conveniente y se decidió que solo se utilizaría un ciclo de NHANES (2011-2012) y se prepararían todos los archivos necesarios para poder lograr los objetivos de este trabajo.

Después se continuo con la integración, a través de un identificador único, y la preparación de los datos. Seguido por la realización de un análisis exploratorio, la construcción de los modelos predictivos y la evaluación de estos últimos. El último paso fue realizar un tablero interactivo o Dashboard en Power Bi para visualizar los resultados.

7.2 CONTRIBUCIÓN A LOS OBJETIVOS DE DESARROLLO SOSTENIBLE (ODS)

Figura 7. Objetivos de Desarrollo Sostenible (ODS) a los que contribuye la investigación.



Fuente: Naciones Unidas (2015).

Una de las metas de la Universidad de Carlemany es contribuir a los Objetivos de Desarrollo Sostenible (ODS) establecidos por las Naciones Unidas. Y este trabajo de fin de Bachelor de Ciencia de Datos, logra contribuir con ellos también.

La principal aportación es con el objetivo ***ODS 3: Salud y Bienestar***. Las conclusiones destacan que mejorando algunos aspectos la metodología utilizada en este trabajo podría contribuir al apoyo de identificar grupos de riesgo y poder planificar modelos de prevención y promoción de salud.

Otro de los objetivos de las Naciones Unidas que este proyecto contribuye, es al ***ODS 4: Educación de Calidad***, mediante las herramientas de Ciencia de Datos y Machine Learning para un análisis de datos.

Como tercer objetivo, ***ODS 9: Industria, Innovación e Infraestructura,*** demostrando como las técnicas de Machine Learning aportan a problemas de salud pública y dejando claro como la Ciencia de Datos puede contribuir a la mejora de análisis y generación de herramientas para la salud.

Como último objetivo se encuentra el ***ODS 10: Reducción de las Desigualdades*** gracias al análisis de factores asociados a las enfermedades bucales y dentales y el uso de datos abiertos.

7.3 IMPACTO AMBIENTAL, SOCIAL Y ECONÓMICO

Al utilizar datos abiertos preexistentes, el impacto ambiental de este trabajo es limitado, casi nulo. Gracias a la digitalización, hoy un trabajo como este permite que el uso de recursos materiales sea nulo.

En cuando en el ámbito social, se demuestra que hay factores de esta índole que causan las enfermedades dentales. Además, se demuestra como la tecnología de aprendizaje automático puede ayudar a identificar personas con riesgo de padecer enfermedades. Permitiendo así pensar en toma de decisiones basadas en datos para la prevención y promoción de la salud.

Sobre el impacto económico, gracias a los datos abiertos como NHANES se evitan los gastos relacionados con la adquisición de información. Solo se ha destinado dinero para la adquisición de material bibliográfico no disponible de forma gratuita.

8. Procesos y resultados

8.1 FUENTES DE DATOS Y RECOPILACIÓN

Los datos que se han utilizado en el estudio pertenecer al *ciclo 2011–2012 de la National Health and Nutrition Examination Survey (NHANES),* desarrollado por el National Center for Health Statistics (NCHS) de los Estados Unidos. A través del portal oficial de NHANES, se obtuvieron los archivos utilizados para el desarrollo de este trabajo. Se han descargado en formato XPT (SAS Transport Files) y posteriormente importados y procesados mediante Python.

Para la construcción de la base de datos se utilizó los módulos ***DEMO_G, OHXDEN_G, OHXPER_G, OHQ_G, SMQ_G, ALQ_G y PAQ_G***. Gracias a estos archivos se pudo obtener información demográfica y socioeconómica, además de datos de exámenes clínicos odontológicos e información perteneciente a hábitos y comportamientos de salud.

A través de la variable ***SEQN***, que es un indicador único asignado a cada participante de NHANES, los módulos fueron integrados. Esto hizo mucho más fácil relacionar a nivel individual la información procedente a los distintos archivos y progresivamente consolidad un único conjunto de datos.

Todo lo relacionado con la información clínica se obtuvo mediante diferentes módulos odontológicos. Por un lado, la presencia de caries dental, provino de la información disponible en ***OHXDEN_G***, mientras que la periodontitis se construyó utilizando las mediciones periodontales de Clinical Attachment Loss (CAL) y Probing Depth (PD) disponibles en ***OHXPER_G***, aplicando el criterio operativo definido para el presente estudio a partir de las definiciones epidemiológicas propuestas por CDC/AAP (Eke et al., 2012).

Luego uniendo estos dos módulos se obtuvo la variable objetivo-binaria ***ENFERMEDAD_BUCODENTAL***, que diferencia entre participantes sin enfermedad y aquellos con presencia de enfermedad (caries dental y/o periodontitis).

Para las variables relacionadas con las características demográfica, situación socioeconómica y hábitos de salud, se tuvieron en cuenta: edad; sexo; grupo étnico; nivel educativo; índice ingreso-pobreza (PIR); tabaquismo; consumo de alcohol y actividad física.

Posteriormente a integrar y preparar todos los módulos, se obtuvo un conjunto de datos de un total de 3.306 participantes y 17 variables (sin registros duplicados). Esta base de datos fue la

utilizada para las posteriores etapas de exploración, preparación y selección de variables descritas en el apartado siguiente.

Tabla 8. Principales variables recopiladas de los módulos NHANES 2011–2012.

Categoría	Variable(s) NHANES	Información obtenida
Edad	**RIDAGEYR**	Edad del participante
Sexo	**RIAGENDR**	Sexo del participante
Etnia	**RIDRETH1**	Grupo étnico
Nivel educativo	**DMDEDUC2**	Nivel educativo
Nivel socioeconómico	**INDFMPIR**	Índice ingreso-pobreza (PIR)
Tabaquismo	**Variables de SMQ_G**	Información sobre hábito tabáquico
Consumo de alcohol	**Variables de ALQ_G**	Información sobre consumo de alcohol
Actividad física	**Variables de PAQ_G**	Información sobre actividad física
Salud oral	**Variables de OHQ_G**	Información complementaria sobre salud oral
Caries dental	**Variables clínicas de OHXDEN_G**	Determinación de la presencia de caries
Periodontitis	**Variables clínicas de OHXPER_G**	Determinación de la presencia de periodontitis

Fuente: Elaboración propia a partir de NHANES 2011–2012 (CDC, 2024).

8.2 EXPLORACIÓN Y PREPARACIÓN DE DATOS

Fue muy importante que antes de comenzar con el análisis exploratorio, los archivos descargados originales de NHANES pasaron por un proceso de limpieza, transformación e integración mediante nueve scripts desarrollados en Python. Esto fue realizado para mantener una organización sobre los cambios realizados a cada fuente y que sea más fácil la validación de los datos. Se pensó que cada script pueda procesar un módulo o una etapa específica del conjunto de datos, generando así archivos intermedios que se almacenaron en una carpeta llamada

Como primero, el archivo que tenía la información demográfica ***DEMO_G*** fue procesado mediante el script ***01_demo.py.*** Fueron conservadas las variables SEQN, RIDAGEYR, RIAGENDR, RIDRETH1, DMDEDUC2 e INDFMPIR. Todos los códigos especiales que tenían respuestas no informativas en el nivel educativo fueron eliminados, y se realizaron comprobaciones de valores faltantes y duplicados del identificador SEQN. Como resultado se generó el archivo ***demo_clean.csv***, que constituyó la base demográfica y socioeconómica utilizada en las etapas posteriores.

A la hora de procesar los datos clínicos odontológicos se realizaron dos scripts independientes. Por un lado, para el archivo relacionado con caries ***OHXDEN_G***, se creó el script ***02_ohxden.py.*** Este utiliza solo participantes con examen oral completo. Y se creó una variable binaria ***CARIES***, que identifica la presencia de caries en al menos una superficie dental. Este procedimiento generó el archivo ***caries_final.csv.***

Por otro lado, el segundo script es el ***script 03_periodontitis.py,*** que procesó el archivo ***OHXPER_G.*** Al igual que el anterior solo se usaron los participantes con examen oral completo. Y se identificó las variables que corresponden a la pérdida de inserción clínica (PCL) y profundidad de sondaje (PCD). Un detalle para saber es que hay valores codificados como 99, estos corresponden a mediciones no disponibles, y se trataron como valores faltantes. Además, se creó la variable binaria ***PERIODONTITIS***, que aplica el siguiente criterio: presencia de al menos una medición de pérdida de inserción clínica igual o superior a 4 mm o una profundidad de sondaje igual o superior a 5 mm. El resultado de esto fue almacenado en ***periodontitis_final.csv.***

A partir las dos variables previamente explicadas, **CARIES** y **PERIODONTITIS**, se construyó ***ENFERMEDAD_BUCODENTAL***, asignando el valor 1 cuando se encontraba presente al menos una de las dos condiciones y 0 cuando ambas estaban ausentes. El resultado de esta etapa fue ***dataset_master.csv***, compuesto por 3.306 participantes y 9 variables.

Algo fundamental para conservar únicamente a los participantes que tenían simultáneamente información demográfica, examen de caries y enfermedad periodontal, fue la creación del script ***04_merge_data.py*** que integró a: ***demo_clean.csv; caries_final.csv; periodontitis_final.csv.*** Se logró mediante uniones internas (*inner joins*) y utilizando ***SEQN*** como clave.

Cada hábito fue procesado de forma independiente. Comenzando con el ***script 05_build_smoking.py*** utilizó las variables ***SMQ020*** y ***SMQ040*** del módulo de tabaquismo. Los códigos de respuestas negativas o de desconocimientos se trataron como valores faltantes, y las respuestas combinadas generaron ***SMOKER_STATUS,*** con las categorías *Never*, *Former* y *Current*. El archivo resultante fue ***smoking_final.csv.***

El alcoholismo fue procesado en el script ***07_build_alcohol.py***. La variable ***ALQ101*** fue depurada y posteriormente recodificada para construir ***ALCOHOL_USE***, donde 1 representa consumo de alcohol y 0 ausencia de consumo según el criterio utilizado. El resultado fue almacenado en ***alcohol_final.csv***.

La actividad física se procesó mediante ***08_build_physical_activity.py*** utilizando las variables ***PAQ635, PAQ650 y PAQ665***, correspondientes a desplazamiento activo, actividad recreativa vigorosa y actividad recreativa moderada. A partir de estas respuestas se construyó ***PHYSICALLY_ACTIVE***: donde el valor 1 es cuando el participante respondió afirmativamente en al menos una de las tres actividades, 0 cuando respondió negativamente en las tres y como valor faltante cuando la información disponible no permitía clasificarlo con seguridad. El archivo resultante fue ***physical_activity_final.csv.***

Para los hábitos sobre la salud oral fue preparado mediante ***06_build_oral_health.py***. A partir de las variables ***OHQ030, OHQ845, OHQ850, OHQ855*** y ***OHQ860*** se generaron las siguientes variables: ***LAST_DENTAL_VISIT; ORAL_HEALTH_RATING; GUM_TREATMENT; LOOSE_TEETH; BONE_LOSS***. El resultado se almacenó en ***oral_health_final.csv.***

Finalmente, para una integración total del tabaquismo, alcoholismo, actividad física y salud oral el ***script 09_merge_final_dataset.py*** integra ***dataset_master.csv*** con todos los archivos antes descriptos. Estas incorporaciones se realizaron mediante uniones izquierdas (*left joins*) sobre ***SEQN***, manteniendo los 3.306 participantes definidos previamente en el dataset maestro. Luego de cada unión se comprobó que no existieran duplicados y que los valores sean válidos. Asimismo, se verificó nuevamente que ***ENFERMEDAD_BUCODENTAL*** coincidiera con la combinación lógica de ***CARIES*** y ***PERIODONTITIS.***

El resultado de todo este proceso fue ***dataset_final.csv***, compuesto por 3.306 participantes y 17 variables. Este archivo reunió la información clínica, demográfica, socioeconómica, conductual y de salud oral disponible después del procesamiento y constituyó la entrada utilizada posteriormente en el notebook principal para realizar el análisis exploratorio de datos.

Tabla 9. Proceso de generación de los archivos de data_processed

SCRIPT	ARCHIVO GENERADO	FUENTE / ENTRADA	PROCESAMIENTO PRINCIPAL	RESULTADO
01_demo .py	**demo_clean.csv**	DEMO_G.xpt	Selección de variables demográficas y socioeconómicas; eliminación de códigos no informativos de educación; validación de SEQN	Variables demográficas y socioeconómicas depuradas
02_ohxden.py	**caries_final.csv**	OHXDEN_G.xpt	Selección de exámenes orales completos; procesamiento de superficies coronales	SEQN, CARIES
03_periodontitis.py	**periodontitis_final.csv**	OHXPER_G.xpt	Selección de exámenes periodontales completos; limpieza de PCL/PCD; aplicación del criterio operativo simplificado	SEQN, PERIODONTITIS
04_merge_data.py	**dataset_master.csv**	demo_clean.csv, caries_final.csv, periodontitis_final.csv	Integración mediante *inner join* y construcción de la variable objetivo	3.306 participantes, 9 variables, incluida ENFERMEDAD_BUCODENTAL
05_build_smoking.py	**smoking_final.csv**	SMQ_G.xpt	Limpieza de SMQ020 y SMQ040; clasificación del estado tabáquico	SEQN, SMOKER_STATUS
06_build_oral_health.py	**oral_health_final.csv**	OHQ_G.xpt	Limpieza, recodificación y renombrado de variables de salud oral	LAST_DENTAL_VISIT, ORAL_HEALTH_RATING, GUM_TREATMENT, LOOSE_TEETH, BONE_LOSS

07_build_alcohol.py	**alcohol_final.csv**	ALQ_G.xpt	Limpieza y recodificación de ALQ101	SEQN, ALCOHOL_USE
08_build_physical_activity.py	**physical_activity_final.csv**	PAQ_G.xpt	Integración de PAQ635, PAQ650 y PAQ665	SEQN, PHYSICALLY_ACTIVE
09_merge_final_dataset.py	**dataset_final.csv**	dataset_master.csv + archivos procesados de hábitos y salud oral	Integración mediante *left join*, validación de tipos, duplicados y coherencia de la variable objetivo	3.306 participantes y 17 variables

Fuente: Elaboración propia a partir del proceso de preparación desarrollado en Python.

8.3 ANÁLISIS EXPLORATORIO

8.3.1 Descripción general del conjunto de datos

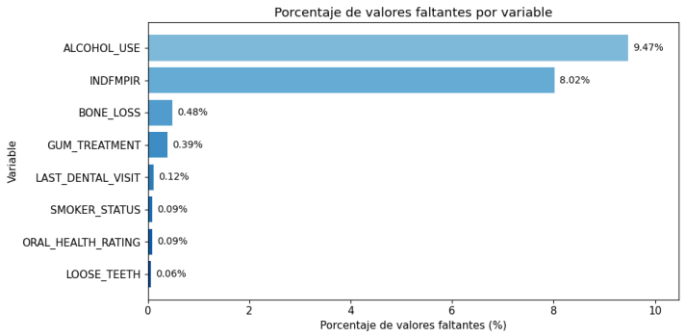
Para empezar, se realizó una exploración inicial de la estructura del conjunto de datos. En esta etapa inicial se exploró el número total de variables y participantes, la naturaleza de las variables y si hay duplicados.

Como se mencionó en el apartado anterior el conjunto de datos final consta de 3.306 participantes y 17 variables, el cual incluye la identificación individual de cada participante (***SEQN***), las variables sociodemográficas, las variables de hábitos y de salud bucal, variables relacionadas con la caries y la periodontitis y una variable objetivo-binaria **ENFERMEDAD_BUCODENTAL.** Por otro lado, las variables son de diferente naturaleza, algunas son numéricas, otras binarias o categóricas. Y se confirmó que no había duplicados.

8.3.2 Calidad de los datos

Al analizar la calidad de los datos se confirmó que no había duplicados, y los valores faltantes se concentraron en un número reducido de variables. Que se pueden ver con claridad en el gráfico a continuación.

Figura 8. Porcentaje de valores faltantes **(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012)**



Como se observa en el gráfico, mayor porcentaje de datos faltantes correspondió a la variable de consumo de alcohol ***(ALCOHOL_USE),*** con un 9,47 %, seguida del índice ingreso-pobreza ***(INDFMPIR),*** con un 8,02 %. En el resto de las variables, la proporción de valores faltantes fue considerablemente menor y se mantuvo por debajo del 0,5 %.

8.3.3 Estadística descriptiva

Para entender mejor a el tipo de población estudiada se realizó un análisis descriptivo de las variables numéricas y categóricas. Y para plasmarlo de una forma más didáctica, se realizados las siguientes tablas. Para las variables numéricas se calcularon el número de participantes, la media, la desviación estándar, así como el mínimo y el máximo.

Tabla 10. Estadística descriptiva de las variables numéricas

Variable	N	Media	Desviación estándar	Mínimo	Máximo
Edad	3306	51,84	14,18	30,00	80,00
Índice ingreso-pobreza	3041	2,63	1,67	0,00	5,00

Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

Para las variables categóricas se encontraron las frecuencias absolutas y relativas de cada categoría.

Tabla 11. Distribución de variables categóricas

Variable	Categoría	Frecuencia	Porcentaje (%)
Sexo	Mujer	1676	50.70
	Hombre	1630	49.30
Grupo étnico	Mexicano-americano	354	10.71
	Otro hispano	341	10.31
	Blanco no hispano	1223	36.99
	Negro no hispano	831	25.14
	Otra raza o multirracial	557	16.85
Nivel educativo	Menos de 9.º grado	317	9.59
	9.º–11.º grado	434	13.13
Nivel educativo	Título universitario o superior	949	28.71
	NaN	911	27.56
	NaN	695	21.02
Tabaquismo	Nunca fumó	1889	57.14
	Exfumador	809	24.47
	Fumador actual	605	18.30
	No disponible	3	0.09
Consumo de alcohol	Consume	2183	66.03
	No consume	810	24.50

Variable	Categoría	Frecuencia	Porcentaje (%)
	No disponible	313	9.47
Actividad física	Activo	2117	64.04
	No activo	1189	35.96
Enfermedad bucodental	Ausencia	1979	59.86
	Presencia	1327	40.14

Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

Los principales resultados se resumen en los siguientes ítems:

- La edad promedio fue de 51.84 años con un valor mínimo de 30 años y un valor máximo de 80 años y una desviación estándar de 14.18 años.
- El índice de pobreza de ingresos (PIR) fue de 2.63 con un máximo de 5 y un mínimo de 0, con una desviación estándar de 1.67.
- El número de observaciones disponibles para la variable es menor que el de otras variables (n=3041), lo cual explica la presencia de valores faltantes.
- La distribución de las variables categóricas es útil para analizar las características sociodemográficas y de comportamiento de la población estudiada en cuanto al género, la etnia, el nivel educativo y hábitos como el tabaquismo, el consumo de alcohol y la práctica de actividad física.

Por otro lado, el propósito de esta etapa del análisis es solamente caracterizar la composición de la población. La distribución específica de la variable objetivo y la distribución individual de las variables predictoras se discuten en las siguientes secciones.

8.3.4 Distribución de la variable objetivo

La variable objetivo ***ENFERMEDAD_BUCODENTAL*** clasifica entre participantes sin enfermedad bucodental y participantes con presencia de caries dental y/o periodontitis.

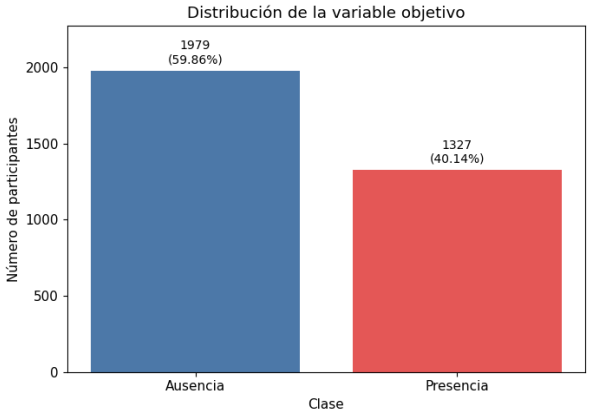
Antes del desarrollo de los modelos predictivos se analizó la distribución de ambas clases, para entender su verdadera representación en el conjunto de datos.

Tabla 12. Distribución de la variable objetivo

Enfermedad bucodental	Frecuencia	Porcentaje
Sin enfermedad	1979	59,86%
Con enfermedad	1327	40,14%
Total	**3306**	**100,00%**

Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

Figura 9. Distribución de la variable objetivo



Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

El gráfico muestra un número elevado de participantes sin enfermedad oral los cuales constituyen el 59,86% del muestreo (n=1979), en contraste con los que tienen enfermedad oral que constituyen el 40,14% (n=1327). Hay un margen de diferencia del 20%, lo que demuestra que las hay un desequilibrio entre las dos clases.

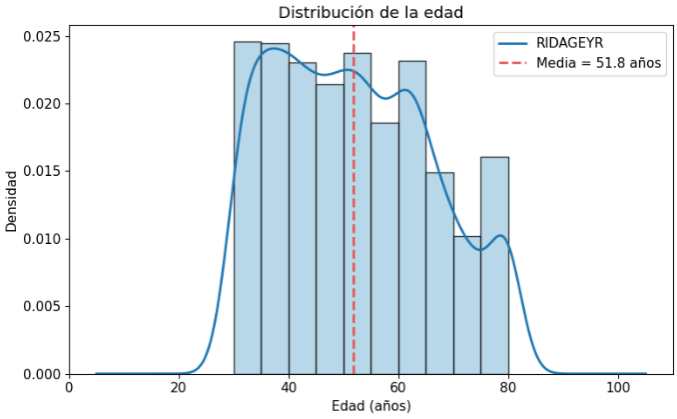
Esto es importante, porque si bien el desequilibrio no es drástico, al ser mayor el porcentaje de negativos en la base de datos, puede generar un sesgo hacia la mayoría en el modelado.

8.3.5 Análisis de las variables predictoras

Se analizaron individualmente todas las variables predictoras. De esta forma, se pudo caracterizar la composición demográfica, socioeconómica y conductual de la población antes de estudiar su relación con la enfermedad bucodental.

Figura 10. Distribución de la edad

(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)

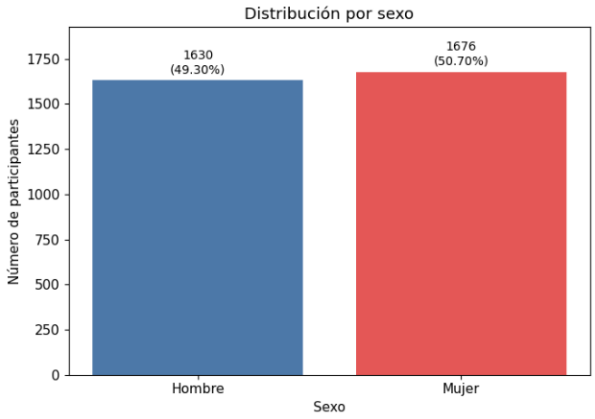


La media de la edad de los participantes es de 51,8 años, con valores comprendidos entre los 30 y los 80 años. Esto demuestra la favorable característica que el estudio no se concentró

exclusivamente en un único grupo etario. Y es tan positivo, porque se puede evaluar en diferentes edades cual es el comportamiento con la enfermedad bucodental.

Figura 11. Distribución por sexo.

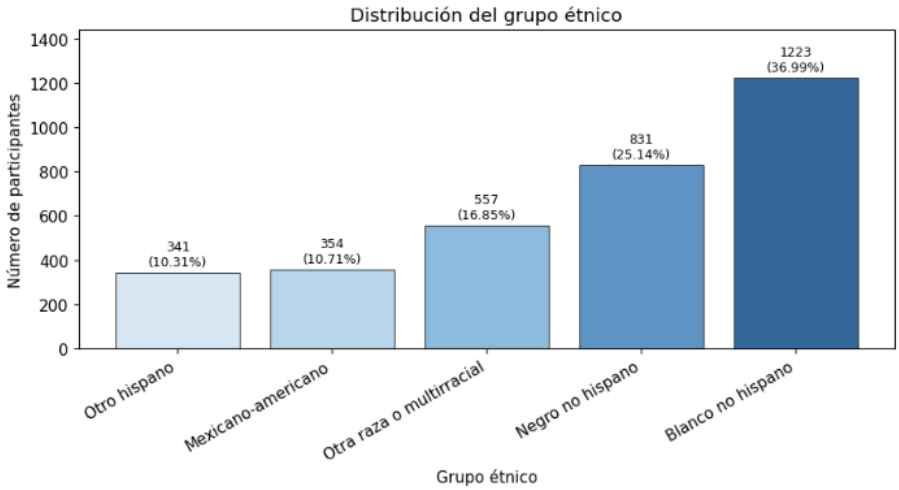
(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



Se refleja un equilibrio en cuanto al sexo, con 1.676 mujeres (50,70 %) y 1.630 hombres (49,30 %). Este balance evita un predominio dentro de la población.

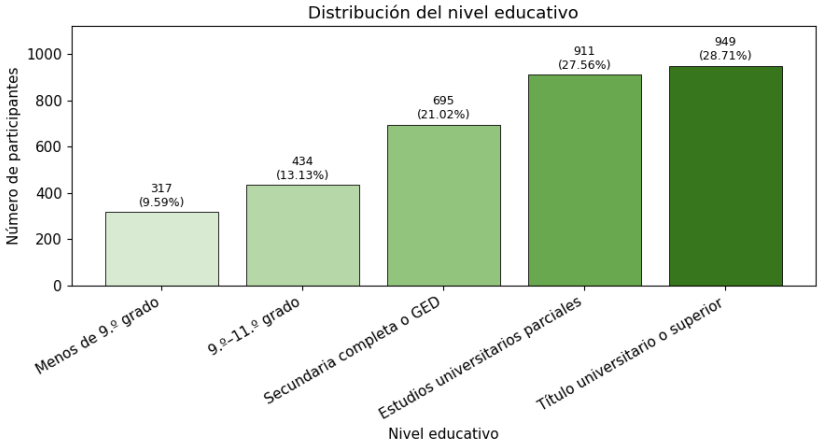
Figura 12. Distribución del grupo étnico.

(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



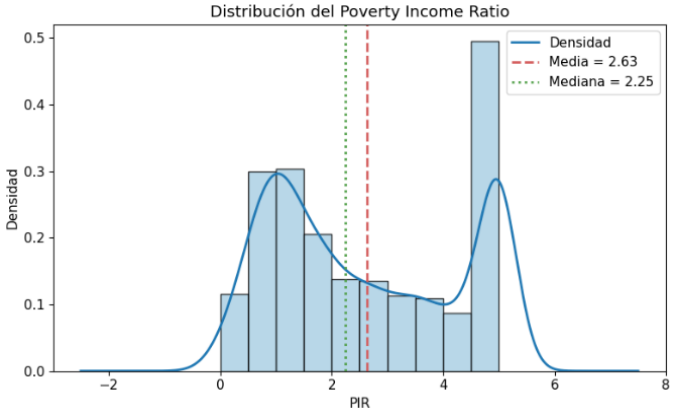
En este análisis se presenta una mayor heterogeneidad, pero era de esperarse ya que recordemos que la población está situada en EE. UU., país donde hay una gran heterogeneidad en la etnia. La mayoría corresponde a los participantes blancos no hispanos constituyeron (36,99 %), seguidos por los participantes negros no hispanos (25,14 %). El resto de la muestra estuvo compuesto por otras razas o grupos multirraciales (16,85 %), mexicanoamericanos (10,71 %) y otros hispanos (10,31 %). Aunque las proporciones fueron diferentes, se optó por mantener todas las categorías en el conjunto de datos. Ya que proporciona un carácter positivo de diversidad demográfica.

Figura 13. Distribución del nivel educativo.
(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



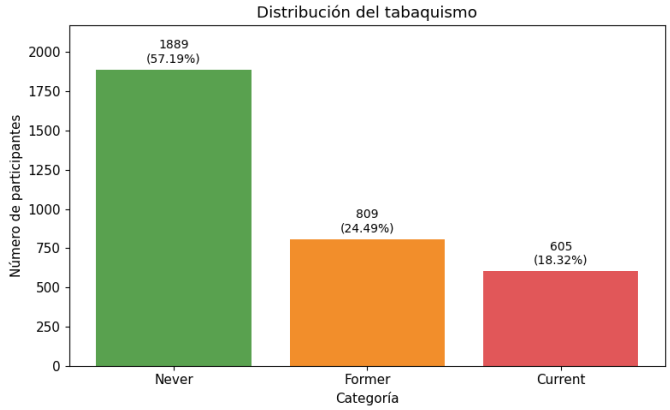
Los participantes con título universitario o superior (28,71 %) y los estudios universitarios parciales (27,56 %) representan la mayoría y esto tiene sentido al ver la media de la edad de la población estudiada. No obstante, también se pueden observar representados los otros niveles educativos.

Figura 14. Distribución del índice ingreso-pobreza (PIR)
(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



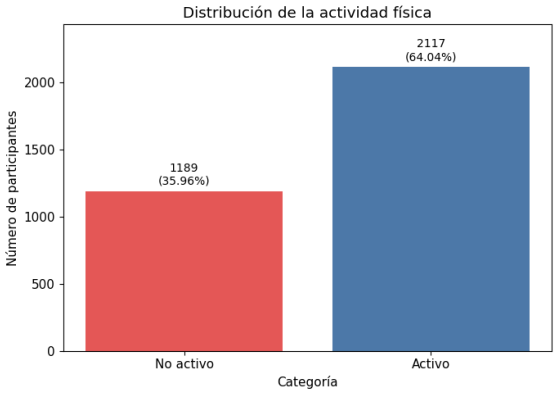
El índice ingreso-pobreza (PIR) presentó una media de 2,63 y una mediana de 2,25, dentro de un rango comprendido entre 0 y 5.

Figura 15. Distribución del tabaquismo.
(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



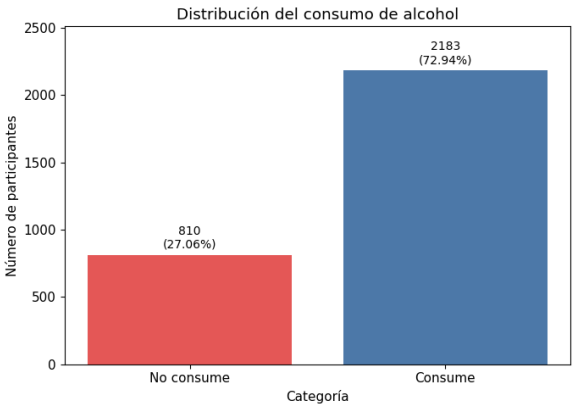
En este gráfico se puede evaluar el tabaquismo, clasificados en never (nunca han fumado) con un 57,19%, former (exfumador) presentando un 24,49% y current (fumadores) con la minoría de 18,32%.

Figura 16. Distribución de la actividad física.
(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



Hay un predominio de participantes clasificados como físicamente activos, que representaron el 64,04 % de la muestra, frente al 35,96 % de participantes no activos.

Figura 17. Distribución del consumo de alcohol.
(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



En relación al alcoholismo, el 72,94 % fue clasificado como consumidor y el 27,06 % como no consumidor, observándose una mayor diferencia entre las categorías de esta variable.

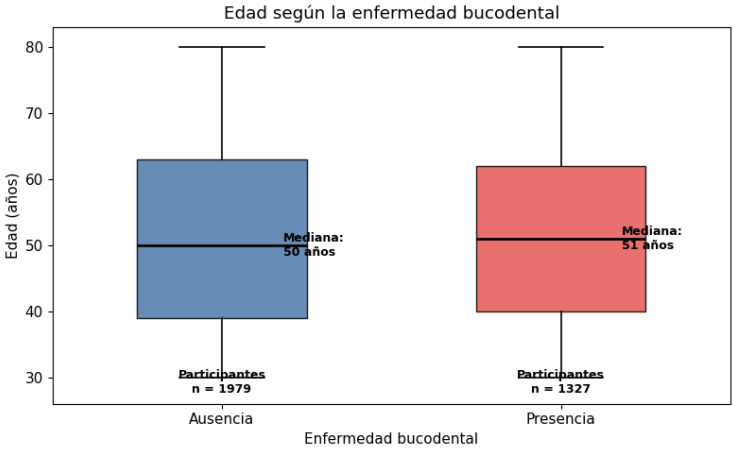
Esta primera caracterización permite comprender cómo está compuesta la población analizada antes de estudiar la relación entre sus características y la presencia de enfermedad bucodental. El siguiente apartado profundiza precisamente en estas relaciones, comparando la distribución de la enfermedad entre los diferentes grupos de participantes.

8.3.6 Relación entre variables predictoras y enfermedad bucodental

La asociación entre las variables predictoras y el estado de la enfermedad oral fue evaluada basándonos en la comparación entre el porcentaje de sujetos clasificados (con o sin enfermedad) y los diferentes factores demográficos, socioeconómicos y de comportamiento.

Figura 18. Distribución de la enfermedad bucodental según edad.

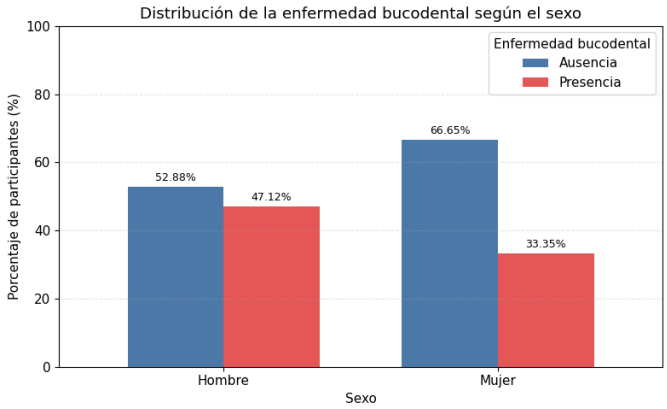
(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



La edad es uno de los patrones más claros. A mayor edad mayor riesgo y por ende una mayor cantidad de sujetos con clasificación positiva. Esto la convierte en una variable de especial interés para los análisis posteriores.

Figura 19. Distribución de la enfermedad bucodental según sexo.

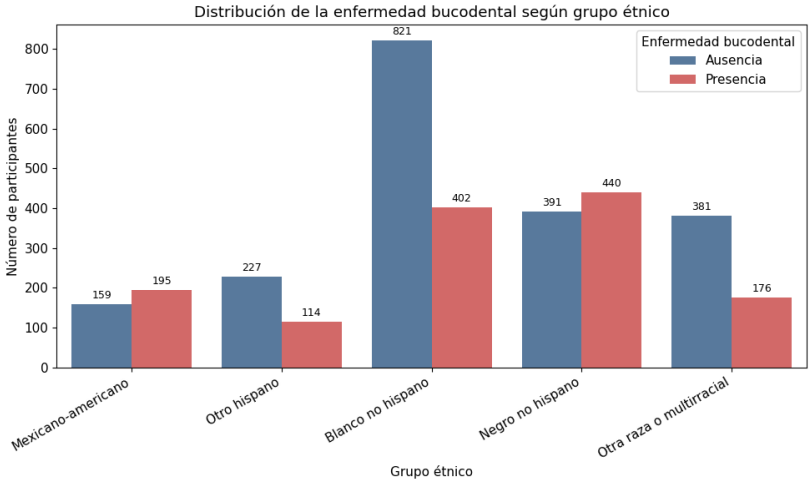
(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



En el sexo no hay tanta diferencia, tanto hombres como mujeres presentaron clasificación positiva en la enfermedad. Por lo que se podría decir que es sexo no muestra una gran relación como indicador de la enfermedad bucodental.

Figura 20. Distribución de la enfermedad bucodental según grupo étnico.

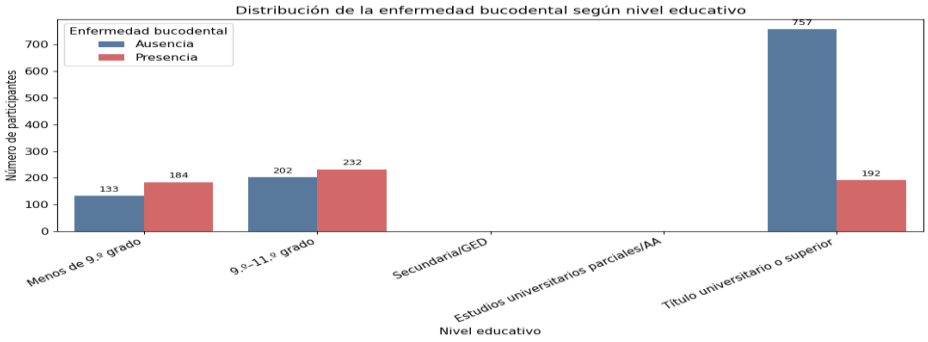
(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



En el grupo étnico algunas categorías mostraron una mayor presencia de enfermedad bucodental que otras, lo que evidencia que la distribución de la variable objetivo fue heterogénea. El grupo con mayor ausencia de enfermedad es el de blanco no hispano, y con mayor número de presencia de enfermedad es el grupo de negro no hispano.

Figura 21. Distribución de la enfermedad bucodental según nivel educativo.

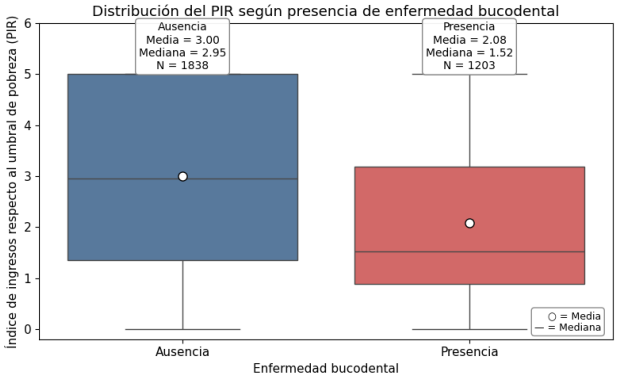
(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



Se evidenció un patrón claro, a mayor educación menor proporción de enfermedad. Esto apunta claramente a una relación entre las características características socioeducativas y la salud bucodental.

Figura 22. Distribución de la enfermedad bucodental según índice ingreso-pobreza (PIR).

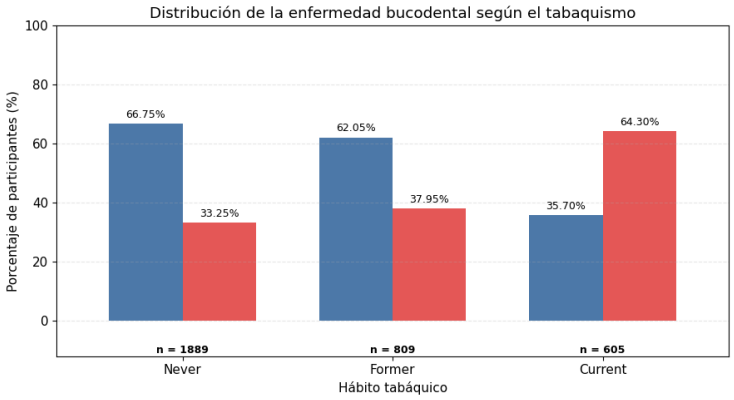
(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



El análisis del índice ingreso-pobreza (PIR) reforzó esta diferencia socioeconómica. Los participantes con enfermedad en su mayoría presentaron niveles bajos de PIR.

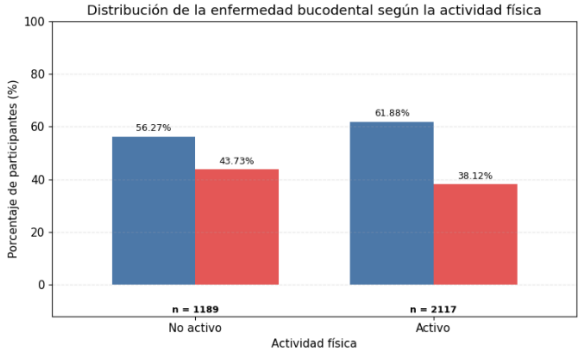
Figura 23. Distribución de la enfermedad bucodental según tabaquismo.

(Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



Aquí se puede evidenciar una clara presencia de enfermedad en fumadores. Y una ausencia en no fumadores y exfumadores.

Figura 24. Distribución de la enfermedad bucodental según la actividad física.

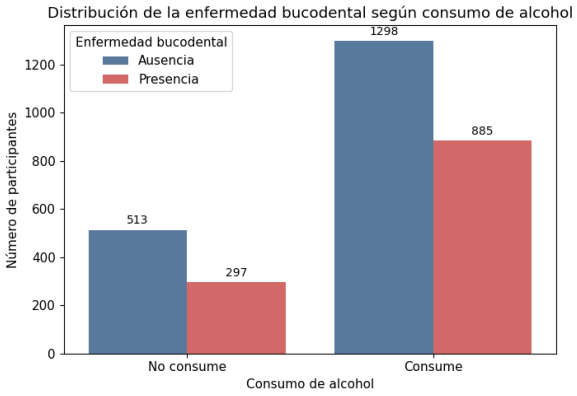


Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)

La actividad física presentó menos diferencias entre participantes activos y no activos. Aunque si hubo algunas discrepancias, fue menos marcada que en las variables predictoras anteriores.

Figura 25. Distribución de la enfermedad bucodental según consumo de alcohol.

Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.)



En cuanto al alcoholismo si se observan diferencias. Pero se puede ver que tanto la ausencia como la presencia de enfermedad se encuentra mayoritariamente en el grupo de consumidores.

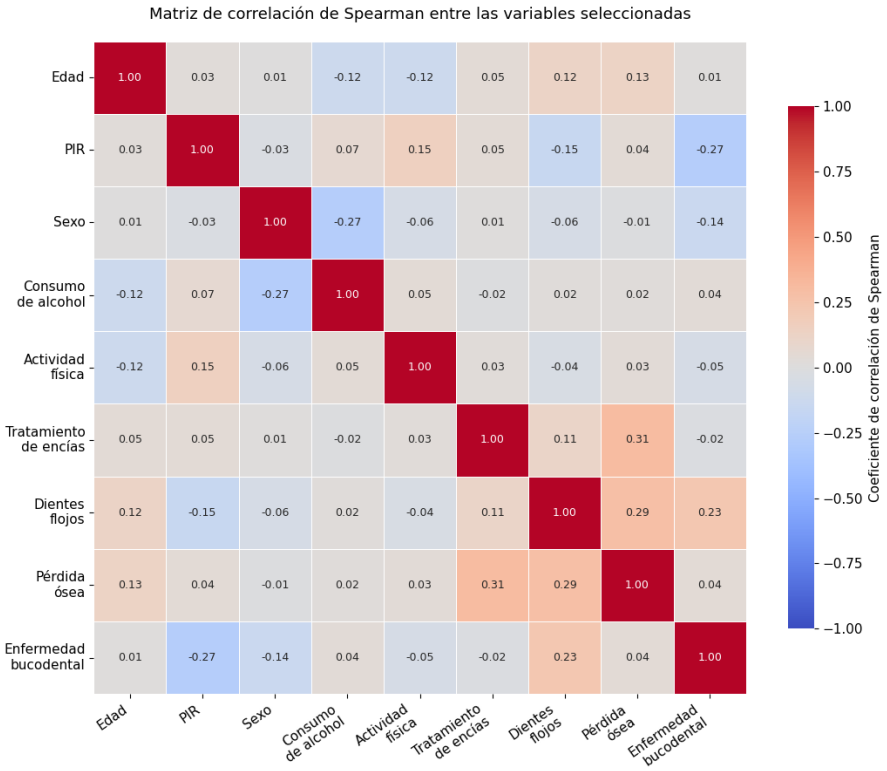
Basándonos en los patrones observados en el análisis podemos concluir que la edad y algunos factores socioeconómicos revelan diferencias claras entre los grupos que se están comparando mientras que otros presentan variaciones bastante sutiles. La siguiente parte nos ayudará a medir estas dependencias y averiguar cuáles de ellas son estadísticamente significativas en relación con las enfermedades orales.

8.3.7 Asociación entre variables

El siguiente análisis permitió profundizar más en las relaciones de las variables antes de comenzar con el entrenamiento de los modelos predictivos. Dado que las variables tienen una naturaleza diferente, el análisis se diferenció dependiendo si las variables eran numéricas, binarias o categóricas. Las variables ***CARIES*** y ***PERIODONTITIS*** no fueron incorporadas en este análisis, ya que son las que conforman la variable objetivo ***ENFERMEDAD_BUCODENTAL***.

Para las variables numéricas y binarias se analizó la correlación mediante el coeficiente de Spearman. Como puede observarse en la *Figura 26*, las correlaciones entre los predictores fueron de baja magnitud. Las relaciones más fuertes fueron entre el tratamiento de encías y la pérdida ósea (ρ = 0,31), y aparte entre la presencia de dientes flojos y la pérdida ósea (ρ = 0,29). Esto es comprensible ya que estas tres variables están vinculadas con los cambios en el tejido periodontal desde un punto de vista clínico.

Figura 26. Matriz de correlación de Spearman entre las variables seleccionadas.



Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

En relación con la variable objetivo, las correlaciones también se caracterizaron por tener coeficientes más pequeños. La correlación más significativa se encontró con el índice ingreso-pobreza (PIR), y fue negativa de ρ = −0,27. Por lo tanto, podemos concluir que a mejor nivel socioeconómico se tiende a relacionar con una menor presencia de enfermedad bucodental.

En cuanto a las otras variables sus correlaciones con la variable dependiente tuvieron magnitudes más pequeñas: sexo (ρ = −0.14), actividad física (ρ = −0.05), consumo de alcohol (ρ = 0.04), pérdida ósea (ρ = 0.04), tratamiento de las encías (ρ = −0.02) y edad (ρ = 0.01). Por consiguiente, no hubo correlaciones fuertes entre los predictores estudiados y la variable objetivo. Esto es muy importante para el siguiente paso del modelado porque no existe una fuerte dependencia lineal o monótona entre las variables que podría sugerir la existencia de algún problema de redundancia entre los predictores. Para llevar a cabo un análisis adicional se estudiaron las variables categóricas con la ayuda de la prueba de independencia de Chi-cuadrado y el coeficiente de Cramer V. Los resultados se presentan en la Tabla 13.

Tabla 13. Asociación entre variables categóricas y enfermedad bucodental

Variable	N	Chi-cuadrado	Grado de libertad	p-valor	V-Cramer	Magnitud
Nivel educativo	3306	266,42	4	<0,001	0,284	Débil
Tabaquismo	3301	186,01	2	<0,001	0,237	Débil
Grupo étnico	3306	139,85	41	<0,001	0,206	Débil
Sexo	3306	64,58	1	<0,001	0,140	Débil
Actitud física	3306	9,76	1	0,002	0,054	Muy Débil
Consumo de alcohol	2993	3,55	1	0,060	0,034	Muy Débil

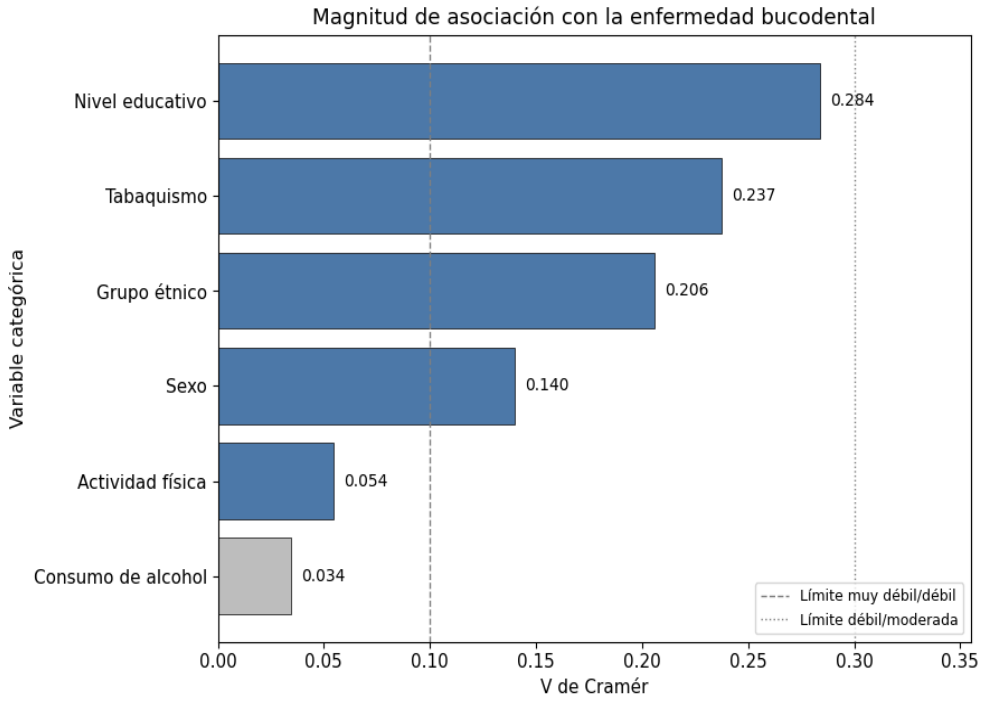
Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

En resumen, se pueden encontrar diferencias en la magnitud de la asociación frente a la presencia de significancia estadística. Las variables con la mayor asociación con las enfermedades orales fueron el nivel de educación ($V=0.284$; $p<0.001$), el tabaquismo ($V=0.237$; $p<0.001$) y la etnia ($V=0.206$; $p<0.001$). Aunque todas estas variables fueron estadísticamente significativas su V de Cramer indica que la magnitud de estas asociaciones pertenece a la categoría de débiles.

Otra variable con una asociación estadísticamente significativa (aunque de menor intensidad) fue el género ($V=0.140$; $p<0.001$). Por otro lado, en relación con la actividad física existe una asociación estadísticamente significativa ($p=0.002$) pero con una magnitud muy baja ($V=0.054$). En resumen, este resultado demuestra que un valor p estadísticamente significativo no siempre significa que sea una asociación de alta intensidad.

El consumo de alcohol fue la única variable categórica que no presento ninguna asociación estadísticamente significativa con las enfermedades orales ($p=0.060$), con un valor de V de Cramer de la menor magnitud ($V=0.034$). También se debe señalar que esta variable tuvo un menor número de observaciones ($n=2993$) debido a los valores faltantes encontrados en la etapa de calidad de los datos. En todos los casos el porcentaje de celdas con una frecuencia esperada menor a cinco fue del 0%.

Figura 27. Magnitud de la asociación entre las variables categóricas y la enfermedad bucodental según V de Cramér.



Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

A partir del gráfico anterior se puede observar que ninguna variable categórica tuvo una correlación media o alta con la enfermedad oral. Las tres categorías que se destacan frente a las demás son los niveles de educación, el tabaquismo y la etnia. De esto se puede concluir que el resultado no está influenciado solo por un factor dominante sino por varios factores sociodemográficos, conductuales y clínicos.

8.4 MODELADO

8.4.1 Preparación de los datos para el modelado

Después de completar el análisis exploratorio, se continuo con el entrenamiento y la prueba de los modelos predictivos. En esta etapa del trabajo se seleccionaron los predictores finales, la división de los datos (datos para entrenamiento y datos de prueba), se trataron los valores faltantes, se codificaron las variables categóricas y se realizó el escalado de las variables numéricas.

Se terminaron eligiendo ocho predictores para la construcción de los modelos. Estos incluyeron factores demográficos, socioeconómicos y de comportamiento de los participantes. La variable objetivo es ***ENFERMEDAD_BUCODENTAL.***

Tabla 14. Variables utilizadas para el modelado

VARIABLE	DESCRIPCIÓN	TIPO	ROL
RIDAGEYR	Edad del participante	Numérica continua	Predictora
INDFMPIR	Índice de ingresos respecto al umbral de pobreza	Numérica continua	Predictora
RIAGENDR	Sexo del participante	Categórica binaria	Predictora
RIDRETH1	Grupo étnico	Categórica nominal	Predictora
DMDEDUC2	Nivel educativo	Categórica ordinal	Predictora
SMOKER_STATUS	Hábito tabáquico	Categórica nominal	Predictora
PHYSICALLY_ACTIVE	Realización de actividad física	Categórica binaria	Predictora
ALCOHOL_USE	Consumo de alcohol	Categórica binaria	Predictora
ENFERMEDAD_BUCODENTAL	Presencia de enfermedad bucodental	Categórica binaria	Objetivo

Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

Para esta etapa se ignoraron las variables asociadas a la exploración clínica (***GUM_TREATMENT, LOOSE_TEETH y BONE_LOSS***) Esto se hizo porque la información contenida en estas variables está asociada al estado dental del paciente. Por lo tanto, el modelo creado no incluye ninguna

información relacionada a estas variables, sino que se enfoca en estimar el riesgo con las variables sociodemográficas, socioeconómicas y de comportamiento.

Finalmente, los 3,306 pacientes fueron divididos en dos grupos. El 80% (n=2,644) se utilizó para desarrollar el modelo y el resto (n=662) se utilizó para evaluar el modelo.

Tabla 15. División del conjunto de datos para el modelado

CONJUNTO	OBSERVACIONES (N)	PORCENTAJE (%)
Entrenamiento	2644	80.0
Prueba	662	20.0
Total	3306	100.0

Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

La división se realizó mediante un muestreo estratificado en relación a la variable objetivo manteniendo la proporción de personas que tienen y/o no enfermedad dental en ambos grupos. Se eligió una semilla aleatoria fija ***(random_state = 42)*** para poder reproducir la división a lo largo del análisis.

La imputación de los valores faltantes se realizó después del procedimiento de división. El valor mediano de los datos de entrenamiento se utilizó para imputar las variables numéricas edad y PIR y la categoría más frecuente para las variables categóricas. Los valores de imputación se calcularon solamente en los datos de entrenamiento y se aplicaron a los datos de prueba. De esta manera después del procedimiento de imputación no quedaron valores faltantes en las ocho variables predictivas utilizadas en el análisis.

Para convertir las variables categóricas que tenían más de dos categorías (grupo étnico, educación y tabaquismo) en variables binarias se utilizó el procedimiento de codificación *One-Hot Encoding.* Se eliminó la primera categoría en cada variable ***(drop="first")*** y así se estableció una categoría de referencia evitando la redundancia. Al igual que en el procedimiento anterior el codificador se ajustó usando solamente los datos de entrenamiento y luego se aplicó a los datos de prueba.

Finalmente se realizó la estandarización usando *StandardScaler* en el caso de las variables numéricas edad y PIR las cuales se necesitaron para ajustar la regresión logística. Después del proceso de estandarización la media de las variables en el conjunto de entrenamiento estuvo cerca de 0 y la desviación estándar fue aproximadamente 1.

De esta manera se obtuvieron los conjuntos de datos finales para ajustar los modelos. En esta etapa se realizaron dos análisis separados para la regresión logística y el Random Forest.

8.4.2 Regresión Logística

La Regresión Logística fue el primer modelo que se evaluó. Primero se creó el modelo base utilizando el conjunto de datos imputado, codificado y escalado sin realizar ningún ajuste específico para el desequilibrio de la variable objetivo.

El desempeño del modelo base es bastante decente en general con una brecha notable entre el desempeño de las métricas. Específicamente hay un bajo valor de Recall en el caso de la clase positiva lo cual implica que el modelo tiene dificultades para reconocer a algunos de los pacientes que padecen la enfermedad dental oral. Esto es especialmente importante en el contexto de la investigación actual ya que el propósito principal del estudio no es solamente tener la proporción óptima de clasificaciones correctas.

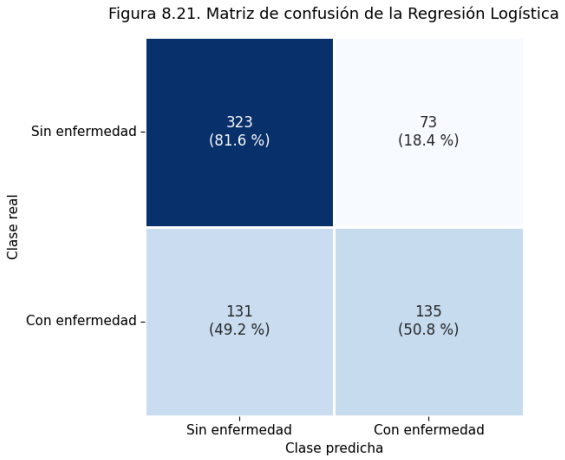
Tabla 16. Métricas de evaluación de la Regresión Logística base

Métrica	Qué evalúan	Valor
Accuracy	Clasificaciones correctas	0.692
Precisión	Exactitud de los positivos predichos	0.649
Recall	Positivos correctamente identificados	0.508
F1-score	Equilibrio entre Precisión y Recall	0.570
ROC-AUC	Capacidad discriminativa	0.760

Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

La matriz de confusión fue más efectiva al analizar a los participantes que no padecían la enfermedad que a los participantes que sí la padecían. Esto significa que muchos de los participantes que sí tenían la enfermedad fueron analizados como no tenerla.

Figura 28. Matriz de confusión de la Regresión Logística base.



Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

Debido a esta diferencia en el rendimiento de la detección para ambas clases el siguiente paso fue entrenar una nueva Regresión Logística con ponderación de clase ***("class_weight":"balanced").*** En otras palabras, el algoritmo les daría un mayor valor a los errores en la clase minoritaria, pero sin agregar o quitar ninguna fila de los datos. La ponderación de clase ya había sido planeada debido al desequilibrio que se encontró en la variable objetivo.

El cambio produjo una mejora clara en la capacidad del modelo para detectar participantes con enfermedad. El Recall aumentó de 0,508 en el modelo base a 0,677 en la versión balanceada, mientras que el F1-score pasó de 0,570 a 0,633. Como contrapartida, la precisión disminuyó de 0,649 a 0,594 y el Accuracy pasó de 0,692 a 0,684. El ROC-AUC prácticamente no se modificó, pasando de 0,760 a 0,761.

Tabla 17. Comparación de las configuraciones de Regresión Logística

MÉTRICA	QUÉ EVALÚA	MODELO BASE	MODELO BALANCEADO	DIFERENCIA
Accuracy	Clasificaciones correctas	0.692	0.684	-0.008
Precisión	Exactitud de los positivos predichos	0.649	0.594	-0.055
Recall	Positivos correctamente identificados	0.508	0.677	0.169
F1-score	Equilibrio entre Precisión y Recall	0.570	0.633	0.063
ROC-AUC	Capacidad discriminativa	0.760	0.761	0.001

Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

La comparación ayuda a comprender el impacto del uso del ponderado. El modelo de regresión logística equilibrada sufrió la pérdida de algo de su precisión y exactitud general, pero al mismo tiempo pudo reconocer a mucha más gente con la enfermedad. Debe notarse que la ganancia en la precisión fue también seguida por el aumento en el puntaje F1 que indica que el modelo se volvió mejor en encontrar casos positivos y hacerlos precisos. La estabilidad de AUC ROC también es bastante consistente con estos cambios ya que el ponderado de clase principalmente afectó el proceso de clasificación en términos de dos clases, pero no aumento el poder discriminativo general del modelo. Por lo tanto, la Regresión Logística con ponderado de clase fue elegida la configuración de Regresión Logística para la comparación final porque a pesar de ser menos precisa que el modelo base pudo reconocer a más participantes con enfermedades dentales.

8.4.3 Random Forest

El siguiente algoritmo examinado fue el método Random Forest. Primero se entrenó un modelo base utilizando los datos que habían sido preprocesados antes. A diferencia del algoritmo de Regresión Logística el escalado de las características numéricas fue innecesario ya que no juega un papel clave para el enfoque de Random Forest. Como resultado se han obtenido las siguientes

métricas las cuales indican que el modelo tiene una capacidad de clasificación moderada. Considerando las métricas por separado vale la pena señalar que la misma diferencia existe entre la capacidad de clasificación del conjunto de observaciones y la detección de la enfermedad oral de los participantes.

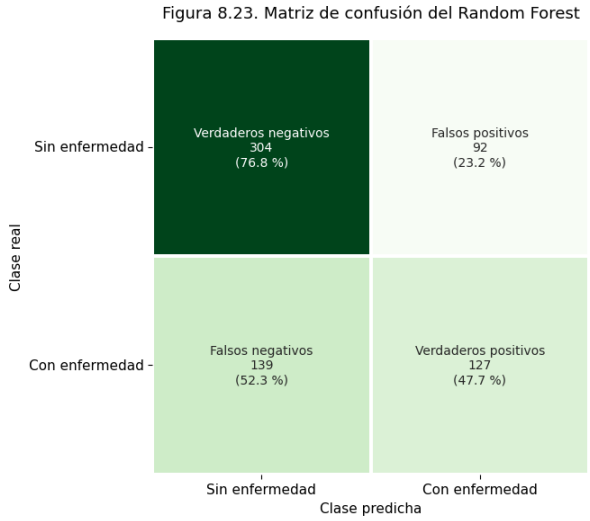
Tabla 18. Métricas de evaluación del modelo Random Forest base

Métrica	Qué evalúan	Valor
Accuracy	Clasificaciones correctas	0.651
Precisión	Exactitud de los positivos predichos	0.580
Recall	Positivos correctamente identificados	0.477
F1-score	Equilibrio entre Precisión y Recall	0.524
ROC-AUC	Capacidad discriminativa	0.692

Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

La matriz de confusión ayudó a examinar las predicciones que estaba generando el algoritmo de manera más profunda. Esto fue de la misma manera que se hizo con la Regresión Logística base; el modelo demostró una mejor capacidad para predecir la existencia de una clase que para predecir a todos los participantes con la enfermedad lo que resultó en muchos falsos negativos.

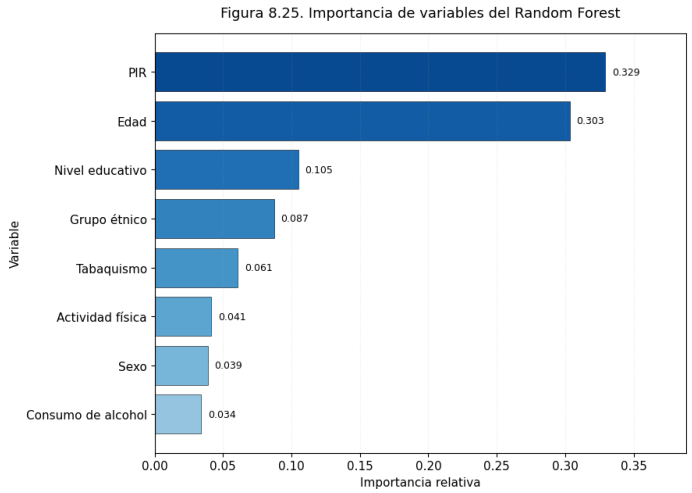
Figura 29. Matriz de confusión del modelo Random Forest base.



Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

Otra característica del Random Forest es que permite la estimación de la importancia de las variables utilizadas en el proceso de clasificación. El análisis indicó que la información de los predictores no era igual; había variables que tenían más importancia en el proceso de toma de decisiones de los árboles. Debe tenerse en cuenta que esta importancia se refiere al funcionamiento del modelo y no significa una relación de causa y efecto con la enfermedad oral.

Figura 30. Importancia de las variables en el modelo Random Forest.



Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

Como resultado del desequilibrio de la variable objetivo se probó posteriormente otra configuración con ***class_weight="balanced"***, utilizando el mismo enfoque que el que se utilizó para la Regresión Logística. De esta manera el algoritmo automáticamente proporcionó un peso desigual a las clases mientras se entrenaba para poder reconocer mejor la clase menos frecuente. Sin embargo, cuando se trata del Random Forest el uso de la ponderación de clase no trae ninguna mejora en cuanto al desempeño del modelo. Contrario a la Regresión Logística el modelo con balanceo no proporciona un compromiso suficientemente favorable de las métricas.

Tabla 19. Comparación entre Random Forest base y Random Forest con ponderación de clases

MÉTRICA	QUÉ EVALÚA	MODELO BASE	MODELO CON PONDERACIÓN
Accuracy	Clasificaciones correctas	0.651	0.645
Precisión	Exactitud de los positivos predichos	0.580	0.569
Recall	Positivos correctamente identificados	0.477	0.481
F1-score	Equilibrio entre Precisión y Recall	0.524	0.521
ROC-AUC	Capacidad discriminativa	0.692	0.697

Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

La conclusión del análisis es que el uso de ponderación de clase para este algoritmo en particular no tiene que llevar a mejores resultados ya que depende de los detalles tanto del modelo como de los datos que se están analizando. La configuración equilibrada no fue suficientemente mejor que la original y tuvo un peor desempeño en términos de todas las métricas analizadas al mismo tiempo. Por eso se eligió la configuración base de Random Forest como la mejor opción para este algoritmo en el análisis final.

8.4.4 Comparación final de los modelos

Después de evaluar todos los posibles ajustes de parámetros de los algoritmos, llegó el momento de una comparación final entre la Regresión Logística con ponderación de clase y el Random Forest Base. La decisión sobre el ajuste final se tomó después de considerar tanto las métricas de clasificación alcanzadas en el conjunto de prueba, especialmente la sensibilidad y la puntuación F1 ya que la precisión de la clasificación de las personas que tienen enfermedad oral es muy importante.

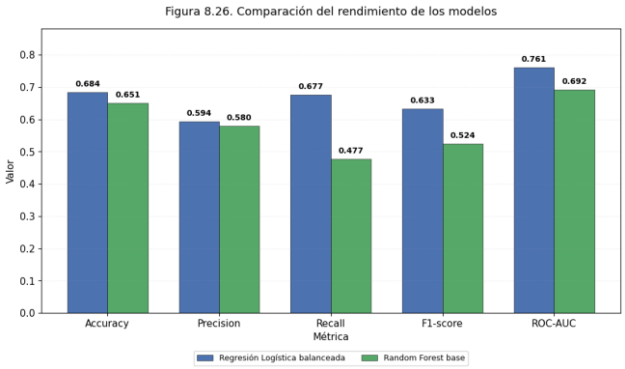
Tabla 20. Comparación del rendimiento de los modelos seleccionados

MÉTRICA	QUÉ EVALÚA	REGRESIÓN LOGÍSTICA BALANCEADA	RANDOM FOREST BASE	DIFERENCIA (RL - RF)
Accuracy	Clasificaciones correctas	0.684	0.651	0.033
Precisión	Exactitud de los positivos predichos	0.594	0.580	0.014
Recall	Positivos correctamente identificados	0.677	0.477	0.199
F1-score	Equilibrio entre Precisión y Recall	0.633	0.524	0.109
ROC-AUC	Capacidad discriminativa	0.761	0.692	0.069

Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

Los resultados muestran discrepancias bastante menores en algunas de las medidas, pero una superioridad mucho más evidente de la *Regresión Logística Balanceada* cuando se trata de la capacidad de detectar la clase positiva. Aunque la puntuación de Accuracy fue ligeramente mejor en la Regresión Logística (0.684 frente a 0.651) la medida de precisión se mantuvo igual en ambos casos (0.594 y 0.580). La mayor discrepancia se puede observar en el Recall que obtuvo una puntuación de 0.677 en el caso de la *Regresión Logística* frente a 0.477 en el *Random Forest*. Esto significa que el primer modelo ha logrado clasificar mejor a los individuos que han sufrido una enfermedad oral que el último. Este hecho se confirma con F1-score (0.633 y 0.524 respectivamente). Ahora es el momento de la representación gráfica de estos hallazgos.

Figura 31. Comparación del rendimiento de los modelos de clasificación.

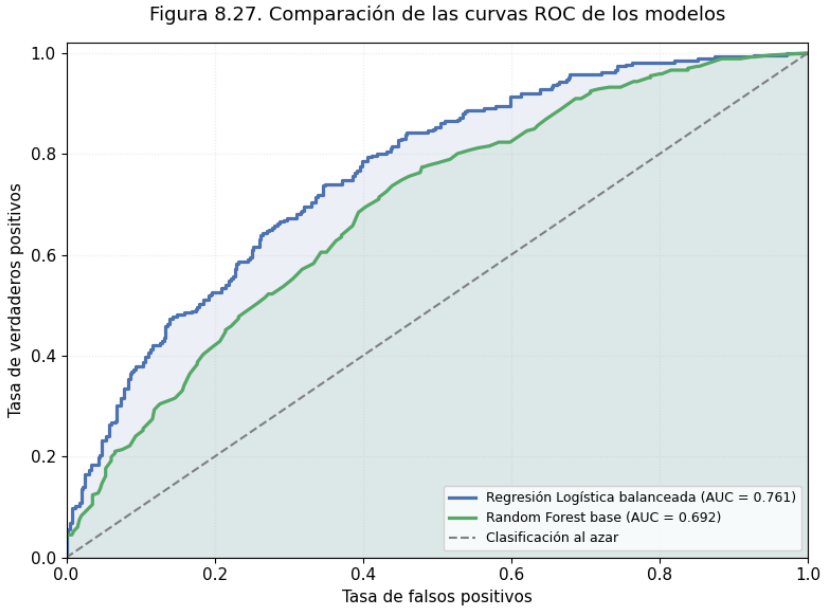


Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

Esta trama también demuestra que no hubo ningún modelo que mostrara resultados sobresalientes en comparación con los demás para todos los criterios antes mencionados. Por

otro lado, la Regresión Logística Balanceada demostró un mejor desempeño en cuanto a la precisión, la recall y la puntuación F1 mientras que el Random Forest base mostró alguna ventaja en cuanto a la precisión. Esta característica es bastante significativa con respecto al objetivo puesto ya que era necesario mantener el equilibrio entre hacer predicciones correctas y detectar a los pacientes. Además, se analizó el poder discriminativo de ambos clasificadores sobre la base de las Curvas ROC.

Figura 32. Comparación de las curvas ROC de los modelos.



Fuente: Elaboración propia mediante Python a partir de datos de NHANES 2011–2012.

Para el puntaje de ROC AUC la Regresión Logística obtuvo un 0.764 mientras que el Random Forest tuvo un 0.720. Ambos gráficos están por encima de la línea aleatoria pero los puntajes muestran que existe una capacidad discriminativa justa de los dos modelos. Sin embargo, la diferencia entre los dos modelos es insignificante pero la Regresión Logística balanceada vuelve a ganar.

8.4.5 Selección del modelo final

Teniendo en cuenta estos resultados el modelo de ***Regresión Logística con ponderación de clase*** fue elegido el mejor modelo para este trabajo. Esta elección no se hizo por ninguna medida en particular sino debido al desempeño general: el modelo fue más preciso, tuvo un mayor valor de Recall, F1-score y ROC AUC mientras que la tasa de Precisión era muy cercana a la del algoritmo Random Forest.

Un Recall de 0.677 fue especialmente valioso durante esta elección ya que demostró que aproximadamente el 60.8% de aquellos pacientes que padecían de enfermedad dental oral en el conjunto de datos de prueba fueron identificados por este modelo. Por otro lado, también está claro que esta tasa podría incrementarse en cierta medida ya que todavía no se reconocen todos los casos.

También se debe señalar que la Regresión Logística tuvo un mejor desempeño que Random Forest. A pesar de la capacidad de Random Forest para reconocer relaciones no lineales e interacciones complicadas entre las variables predictoras en este conjunto de datos su poder no fue lo suficientemente útil para lograr mejores resultados.

8.5 VISUALIZACIÓN

Como último paso se creó un Dashboard en Power-Bi para poder sintetizar los resultados y visualizar los principales hallazgos de los análisis.

Para facilitar la incorporación de los conocimientos al entorno de Power BI se crearon archivos CSV que contienen toda la información requerida para presentar los resultados del análisis descriptivo, las medidas de asociación y el modelado predictivo junto con los indicadores, la matriz de confusión, la comparación de modelos y los datos de la curva ROC.

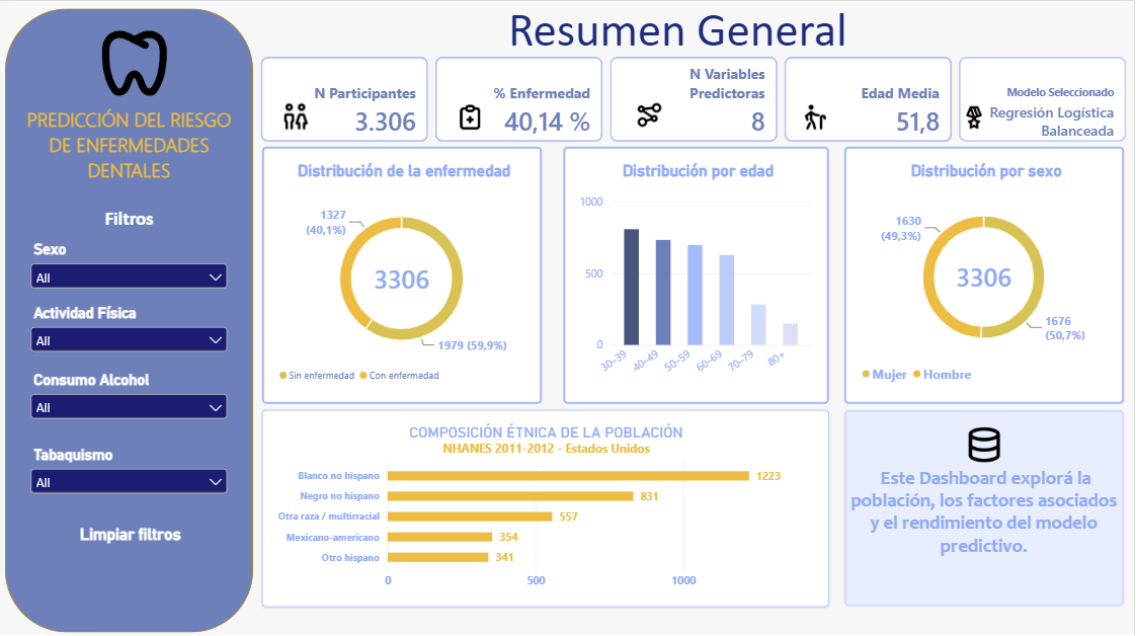
El archivo consta de tres páginas principales incluyendo Resumen General, Factores Asociados con la Enfermedad Oral y Resultados del Modelado Predictivo. Además se proporcionaron algunos filtros interactivos para explorar los resultados utilizando diversos atributos de los participantes.

8.5.1 Resumen general

La primera visualización ofrece un resumen general de la base de datos y proporciona una forma fácil de identificar las características básicas de la población que se analiza. Se han agregado algunos indicadores relacionados con el número de personas, la proporción de la enfermedad oral, el número de predictores, la edad promedio y el modelo final elegido.

Además, se ha presentado la distribución de la enfermedad, la distribución por grupos de edad, la distribución por género y la diversidad étnica de la población. Se proporciona la fuente de la base de datos que es NHANES 2011-2012 de los Estados Unidos. Se ofrecen filtros que modificarán la información mostrada según el género, la actividad física, el alcohol y el tabaco.

Figura 33. Página de resumen general del dashboard desarrollado en Power BI.



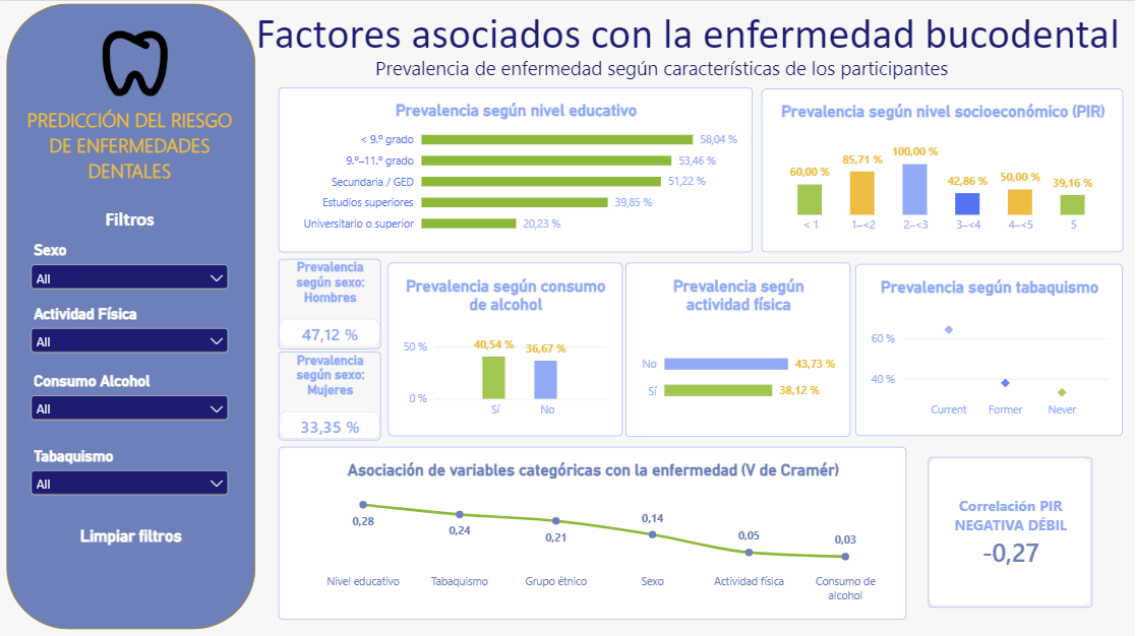
Fuente: Elaboración propia mediante Power BI a partir de datos de NHANES 2011–2012 procesados con Python.

8.5.2 Factores asociados con la enfermedad bucodental

La segunda página se enfocó en el estudio de la relación entre la prevalencia de la enfermedad que se está considerando y los indicadores socioeconómicos y los comportamientos relacionados con la salud los cuales fueron investigados. Para este fin se dio la prevalencia de la enfermedad según la educación, la relación de ingreso de la pobreza (PIR), el género, el consumo de alcohol, la actividad física y el tabaquismo.

En cuanto a las variables categóricas se utilizaron los coeficientes de Cramer V mientras que para el PIR se aplicó el coeficiente de correlación de Spearman. Esto nos permite diferenciar entre una simple comparación de prevalencias y la fuerza de las relaciones.

Figura 34. Página de factores asociados con la enfermedad bucodental.



Fuente: Elaboración propia mediante Power BI a partir de los resultados del análisis exploratorio realizado con Python.

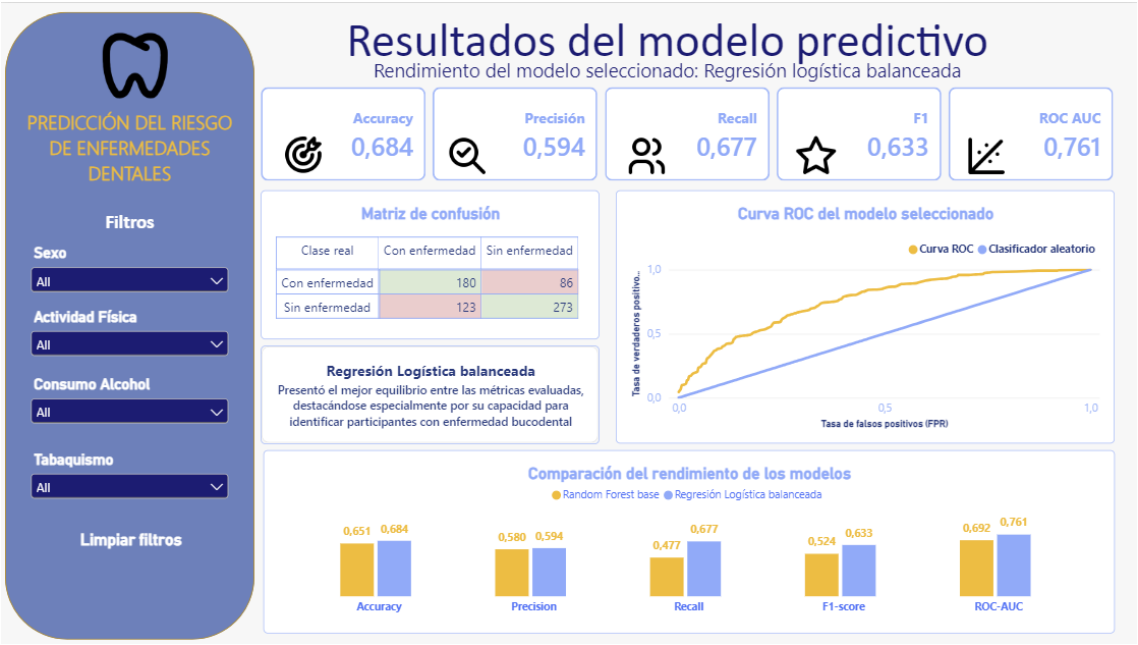
8.5.3 Resultados del modelo predictivo

La tercera página proporciona los resultados relacionados con el proceso de modelado y evaluación predictiva. El tablero contiene los parámetros importantes de la Regresión Logística Balanceada modelo que fue finalmente elegido para demostrar los resultados de la predicción de la investigación. Estos incluyen Accuracy, Precisión, Recall, F1-score y ROC-AUC.

La evaluación también se complementa con una matriz de confusión la cual nos dará la oportunidad de reconocer los verdaderos positivos, los verdaderos negativos, los falsos positivos y los falsos negativos, y con la curva ROC la cual muestra la eficiencia del modelo comparado con un clasificador aleatorio. Además, se proporciona la comparación entre la *Regresión Logística Balanceada y el Random Forest base* de referencia usando los mismos parámetros de clasificación.

De esta manera se mantiene la coherencia con la parte anterior del informe ya que ya se determinó allí que la *Regresión Logística Balanceada* será el modelo utilizado para demostrar los resultados finales predictivos en Power BI.

Figura 35. Página de resultados del modelo predictivo.



Fuente: Elaboración propia mediante Power BI a partir de los resultados del modelado realizado con Python y Scikit-learn.

9. Discusión y limitaciones

9.1 DISCUSIÓN DE LOS PRINCIPALES RESULTADOS.

A partir de todos los análisis y los resultados que se obtuvieron se pueden ver ciertos patrones con respecto a la presencia de enfermedad dental y evaluar si las variables seleccionadas podrías ser utilizadas o no para crear un modelo predictivo.

Las variables socioeconómicas fueron las que mayor relevancia o influencia tuvieron en los resultados. Por ejemplo, el PIR tuvo una correlación negativa con respecto a la enfermedad dental y el nivel de educación fue la variable con mayor asociación. Con esto dicho, se puede decir que sí, este tipo de variables están asociadas a la presencia de la enfermedad dental. Pero, por otro lado, solo con estas variables no se puede predecir una enfermedad.

Con respecto a los hábitos, el tabaquismo mostró el mayor nivel de asociación. Al contrario, la actividad física demostró ser la de menor asociación. Y el alcoholismo fue la única variable categórica sin ningún tipo de asociación. La conclusión a esto es que no todas las variables de comportamiento tienen la misma relación con la enfermedad dental.

Otra conclusión que llama la atención es que no hay una gran relación entre las variables predictivas. Y en este estudio en particular no se demostró una variable predictiva con una fuerte correlación con la enfermedad (para tener en cuenta que esto es solo teniendo en cuenta esta población estudiada). Estos hallazgos hay que tenerlos en mente a la hora de interpretar el desempeño de los modelos.

En la etapa del modelado, la ponderación de clases solo tuvo sentido para la Regresión Logística. Aunque se vea un peor rendimiento en precisión y Accuracy en comparación con el modelo base aumentó el Recall de 0.508 a 0.677 y el F1-score de 0.570 a 0.633. Esto fue importante, ya que gracias a este cambio se pudo lograr una mayor proporción de participantes con enfermedad oral.

Por el contrario, para el Random Forest, la ponderación de clases no evidenció ningún beneficio. Por lo que finalmente se utilizó el Random Forest Base. Es decir, no todas las estrategias funcionan igual y pueden tener diferentes resultados según el modelo.

Como un breve resumen de los resultados, el modelo de Regresión Logística con ponderación de clases obtuvo: Accuracy 0.684; Precisión 0.594; Recall 0.677; F1-score 0.633; ROC AUC 0.761. Por otro lado, el Random Forest demostró casi la misma precisión y todo el resto más bajo.

El significado de estos resultados en otras palabras es, que un modelo tenga un ROC AUC de 0.761, significa que tiene un poder discriminatorio por encima de la casualidad, pero aun así sigue siendo limitado. Que el Recall sea de 0.677 indica que puede detectar 6 de cada 10 pacientes con enfermedad dental. Por esto mismo es importante destacar que el modelo creado no podría utilizarse (así como esta) como una herramienta de diagnóstico clínico, solo se puede considerar como un modelo predictivo experimental dentro del alcance de este trabajo.

Sin embargo, se logró la meta de realizar un trabajo final Ciencias de Datos aplicado a los datos epidemiológicos sobre salud oral y se ha cubierto todos los pasos, desde la preparación de datos a comparar los modelos de Machine Learning y visualizarlos. Además, también permitió encontrar cuáles son las características más asociadas con la enfermedad oral y evaluar cómo diferentes elecciones de modelado afectan la detección de casos positivos. Para una futura ampliación de este trabajo.

9.2 COMPARACIÓN CON ESTUDIOS PREVIOS.

Parte de este trabajo fue encontrar otros investigadores que hayan logrado hallazgos similares a este trabajo, también usando como datos base NHANES. Algunos de estos investigadores fueron contactados con el fin de poder entablar una conversación al respecto. Ha sido muy enriquecedor poder leer otros trabajos, para saber como se ha abordado este tema anteriormente.

Centrándose en los factores socioeconómicos Borrell y Crawford (2008) analizaron a 10.648 adultos que participaron en el NHANES de 1999-2004 y encontraron diferencias en la prevalencia de la periodontitis según los ingresos, el nivel educativo y la etnia. Al controlar otras variables los participantes con menor nivel educativo y bajos ingresos estaban en mayor riesgo de padecer periodontitis. Esto es similar a los hallazgos de este trabajo, la gran diferencia es que ellos solo se basaron en la Periodontitis.

Algo casi idéntico sucede en el contexto de las caries según Boyajyan & Bilal (2026). Estos autores han estudiado adultos de NHANES de 2011 a 2020 y encontraron que los que tienen un PIR más bajo tienen una tasa más alta de caries. La similitud de sus resultados con los resultados de esta investigación confirma la importancia de los factores socioeconómicos en la investigación de la salud bucal.

Hung et al. (2019) han utilizado NHANES 2015-2016 y se centró en el aprendizaje automático. Específicamente creo modelos para identificar caries radiculares. En particular la investigación ha

aplicado diversas técnicas de aprendizaje automático tanto para seleccionar las variables importantes como para evaluar la capacidad de clasificación.

Vu et al. (2025) ha creado modelos predictivos de enfermedad periodontal utilizando NHANES 2009-2014. Este estudio ha utilizado un amplio rango de características y ha comparado numerosos clasificadores lo que significa que este enfoque de modelado es mucho más completo que el implementado en este trabajo.

Tabla 21. Comparación con estudios previos

ESTUDIO	DATOS	VARIABLE ESTUDIADA	ENFOQUE PRINCIPAL	DIFERENCIA RESPECTO AL PRESENTE ESTUDIO
Borrell & Crawford (2008)	NHANES 1999–2004	Periodontitis	Factores socioeconómicos	Análisis específico de periodontitis
Hung et al. (2019)	NHANES 2015–2016	Caries radicular	Machine Learning	Otro desenlace y mayor variedad de técnicas
Vu et al. (2025)	NHANES 2009–2014	Enfermedad periodontal	Machine Learning	Más características y clasificadores
Boyajyan & Bilal (2026)	NHANES 2011–2020	Experiencia de caries	Desigualdades socioeconómicas	Análisis específico de caries en varios ciclos
Presente estudio	NHANES 2011–2012	Caries y/o periodontitis	Identificación de patrones y estimación de la probabilidad de enfermedad mediante aprendizaje automático a partir de factores socioeconómicos y hábitos de salud	Variable objetivo combinada y 8 predictores

Fuente: Elaboración propia a partir de Borrell y Crawford (2008), Hung et al. (2019), Vu et al. (2025), Boyajyan y Bilal (2026) y los resultados del presente estudio.

9.3 ALCANCE Y POTENCIAL DE LOS MODELOS DESARROLLADOS

Uno de los objetivos de este trabajo fue explorar la posibilidad de si los algoritmos de aprendizaje automático pueden ayudar a prevenir enfermedades dentales a partir de características de hábitos, socioeconómicas y de salud. De los resultados obtenidos podemos afirmar que es factible, aunque con algunas restricciones debido a la limitada capacidad predictiva.

De todos los modelos, La *Regresión Logística Balanceada* fue la que mejor desempeño obtuvo. El aumento de la precisión ayudó a reconocer a más participantes con una enfermedad oral, una característica la cual es importante ya que no solo la clasificación de los participantes es importante aquí sino también descubrir la posibilidad de reconocer esos perfiles más propensos al desarrollo de la enfermedad.

Para el sector salud, los modelos predictivos son una gran herramienta de apoyo para la estratificación de población y el identificar grupos de riesgo, siendo esto posible cuando el funcionamiento y la validación del modelo sean lo necesariamente buenos. Este uso nunca remplazaría un examen clínico, es solo una herramienta más para campañas de prevención, toma de decisiones basadas en datos.

Otro punto importante e interés de este trabajo es poder utilizar esta metodología, en otras enfermedades. Si bien como caso estudio se utilizó la enfermedad dental, después de realizar todos los ajustes necesarios se podría utilizar en otras enfermedades donde los factores socioeconómicos y de comportamiento jueguen un papel importante. Ejemplo: Obesidad; Diabetes tipo 2; Depresión o Ansiedad; Enfermedades respiratorias crónicas; etc.

Así pues, el potencial clave que existe actualmente no es el uso clínico del modelo sino más bien la ilustración del proceso en el cual los factores socioeconómicos y de salud pueden ser utilizados como parte de la Ciencia de Datos para la identificación de ciertos patrones y la evaluación de probabilidades para proporcionar información que podría ser útil para la solución de problemas de salud pública. Para hacer un uso práctico de ello sería necesario mejorar el poder predictivo del modelo y probarlo en otros casos.

9.4 LIMITACIONES DEL ESTUDIO

La primera limitación, es que se utilizó un solo ciclo de NHANES (2011-2012). Se eligió este camino por que permitió poder tener unos datos homogéneos. Pero esto hizo que la muestra de la población sea escasa, comparando con los otros estudios realizados. Y además que no se comprobó si estos patrones son iguales en otros periodos.

La segunda limitación, es que para lograr la variable objetivo ***ENFERMEDAD_BUCODENTAL***, se utilizó las dos enfermedades (caries y periodontitis) en conjunto. Resolvió de una forma simple la clasificación, pero estas enfermedades no son iguales y los factores de riesgo pueden cambiar de una a otra. Por ejemplo, el tabaquismo para la periodontitis es uno de los principales factores de riesgo, cuando para las caries es la dieta.

La tercera limitación, fue la elección de los predictores. En el modelo final solo se incluyen 8 variables. Y esto permitió crear un modelo comprensible y relevante para el presente trabajo. Pero no es la lista completa que podría estar incluida en la enfermedad de caries y periodontitis. Sería muy interesante de sumar para líneas futuras, serían las enfermedades crónicas con relación a la periodontitis y caries. Ejemplo, cardiopatías o diabetes.

La cuarta limitación, es la presencia de valores faltantes. Si bien esto fue tratado en el preprocesamiento de datos, para una investigación de este tipo seria totalmente interesante poder tener conexión con la recolección de datos.

Una limitación en particular es el número de algoritmos aplicados. En este caso se utilizaron los algoritmos de Regresión Logística y Random Forest. Elegimos este enfoque para poder comparar dos algoritmos al mismo tiempo que nos aseguramos de que el proceso de modelado se mantenga claro y limitado al alcance del proyecto. Pero los resultados de esta investigación no pueden considerarse como una prueba de que el algoritmo de Regresión Logística Balanceada sea el mejor para resolver este problema en particular, es el mejor entre otros algoritmos alternativos.

De igual forma, a pesar de que el conjunto de datos se dividió en muestras de entrenamiento y prueba y se aplicó la validación cruzada para el ajuste de los hiperparámetros no realizamos ninguna validación externa de nuestro modelo sobre una muestra independiente. Por lo tanto, no podemos estar seguros de que el desempeño alcanzado de nuestro modelo se mantendrá consistente cuando lo apliquemos a otro ciclo, a otra población u otro sistema de atención de la salud. Este problema se vuelve especialmente relevante cuando se habla de modelos predictivos en la atención de la salud, cuando la necesidad de tener grandes bases de datos y una correcta validación es bien conocida.

Finalmente, los resultados obtenidos deben considerarse en el contexto del propósito exploratorio y académico del estudio. Ya que se ha logrado encontrar patrones predictivos, aun es insuficiente para proponer en uso clínico o preventivo.

Estas limitaciones no invalidan el trabajo o los resultados obtenidos, pero sí hay que tenerlos en cuenta para su interpretación. Además, ayudan a entender que aspectos se podrían mejorar para poder continuar expandiendo este trabajo.

10. Conclusiones y líneas futuras

10.1 CONCLUSIONES

Como primera conclusión y recordando el objetivo principal de este trabajo, que era, poder evaluar las capacidades de los algoritmos de aprendizaje automático para predecir el riesgo de una persona a padecer una enfermedad dental, mediante factores socioeconómicos y hábitos. Utilizando datos de salud abiertos y poder juzgar su papel en la prevención y en la toma de decisiones basadas en los datos. Podemos concluir que luego de todo el proceso realizado y los datos obtenidos, si es posible utilizar las técnicas de aprendizaje automático con este fin, pero en este trabajo aún existen limitaciones que hay que tratarlas antes de poder usarse.

El uso del identificador único **SEQN** fue clave para poder construir el conjunto de datos combinando los datos clínicos con los datos socioeconómicos y de comportamiento. Y en conjunto con toda la preparación de los datos, se logro un conjunto de datos confiable y adecuado para la exploración y el modelado.

La etapa de análisis exploratorio nos dio un primer pantallazo de que tipo de población estábamos estudiando. Dando una respuesta a, qué variables o patrones se asociaban a la presencia de la enfermedad oral. Las conclusiones como fueron también comentadas en otros apartados son que los factores socioeconómicos PIR y el nivel educativo, muestran la mayor correlación. Por el lado de los hábitos, hay una fuerte relación con el tabaquismo, pero casi nada con actividad física o alcoholismo. Sin embargo, ninguna asociación es lo demasiado fuerte para explicar la enfermedad por si sola.

Luego cuando se obtuvieron los resultados del aprendizaje automático, confirman estos datos. Al realizarse la comparación de los modelos de Regresión Logística y Random Forest (cada una en diferentes configuraciones), se demostró que la Regresión Logística con ponderación de clases en la mejor opción. Esto es así porque mejoró la capacidad del modelo de identificar casos de enfermedad.

Como se mencionó al principio, para poder considerar estos modelos para que sean aplicados para la prevención o en decisión basada en datos, se debe de mejorar el poder discriminatorio y su capacidad de detectar casos positivos.

Como otra conclusión, se confirmó que es posible utilizar datos de salud abiertos para desarrollar un proyecto de Ciencia de Datos. Fue posible crear un flujo completo de trabajo, desde la preparación, hasta la visualización. Siendo así posible pensar que esta metodología puede utilizarse como base para estudiar otras enfermedades multifactoriales.

10.2 Líneas futuras

Luego de haber comentado todas las limitaciones que posee este trabajo y las conclusiones principales, se podría plantear varias direcciones para una investigación futura.

Si se focaliza en el mismo tipo de enfermedades, como primero, se debería de aumentar el conjunto de variables predictivas. Incluir variables sobre la dieta, enfermedades sistémicas o en si su historia clínica, hábitos de higiene oral y frecuencia de consulta odontológica. Estas variables podrían ayudar a mejorar la capacidad predictiva actual.

Además, seria enriquecedor poder evaluar las enfermedades caries y periodontitis por separado. Se podrían evaluar características específicas de cada enfermedad, y evaluar si los modelos logran un mejor poder discriminatorio.

Otra línea, sería utilizar más ciclos de ***NHANES***, como lo han hecho otros investigadores. Esto permitiría no solo aumentar el tamaño de la muestra sino también evaluar en periodos de tiempo si hay algún cambio, hasta poder hacer un análisis más global de la problemática.

Sobre el modelado, se podrán probar otros algoritmos de aprendizaje automático. Por ejemplo el *Gradient Boosting*, que en simples palabras lo que hace es crear muchos árboles de decisión pequeños, que cada uno corrige al anterior, y luego se logra una predicción mucho más precisa. Otro ejemplo es el XGBoost, que básicamente es lo mismo que el *Gradient Boosting* más optimizado. Y como último ejemplo se podría decir las *Máquinas de Vectores de Soporte* que es muy útil para separar la población en grupos, en este trabajo sería el grupo con y el grupo sin enfermedad.

Se podría realizar más validaciones, por ejemplo, utilizando los datos no incluidos en el entrenamiento. Y así poder evaluar el poder predictivo en muestras independientes. Además, sería interesante considerar por ejemplo usar la Regresión Logística para realizar una estratificación de riesgo de la población. Y de esta forma identificar en que grupos se deberían de focalizar la prevención y estrategias de promoción de salud.

Finalmente, si se quisiera explorar otras enfermedades, otra línea futura sería poner a prueba la misma metodología. Utilizando datos de salud abiertos, y siguiendo los mismos pasos. O hasta se podría pensar en generar una base de datos, para que no solo se prediga una enfermedad, sino varias a la vez.

La gran conclusión de este trabajo es que se debe tomar como un comienzo o una punta pie para poder explorar diferentes enfermedades, variables, poblaciones y enfoques. Es decir, utilizar la contribución del aprendizaje automático al análisis preventivo de problemas de salud pública.

11. Referencias Bibliográficas

- **Borrell, L. N., Burt, B. A., Warren, R. C., & Neighbors, H. W. (2006).** *The role of individual and neighborhood social factors on periodontitis: The Third National Health and Nutrition Examination Survey. Journal of Periodontology,* 77(3), 444–453. https://doi.org/10.1902/jop.2006.050158
- **Borrell, L. N., & Crawford, N. D. (2008).** Social disparities in periodontitis among United States adults 1999–2004. *Community Dentistry and Oral Epidemiology, 36*(5), 383–391. https://doi.org/10.1111/j.1600-0528.2007.00406.x
- **Boyajyan, V., & Bilal, U. (2026).** *Socioeconomic disparities in dental caries experience: The National Health and Nutrition Examination Survey 2011–2020. American Journal of Preventive Medicine, 70(5), 108245.* https://www.sciencedirect.com/science/article/pii/S0749379725007135
- **Breiman, L. (2001).** *Random forests*. *Machine Learning, 45*(1), 5–32. https://link.springer.com/article/10.1023/A:1010933404324
- **Centers for Disease Control and Prevention. (2024).** *National Health and Nutrition Examination Survey (NHANES).* National Center for Health Statistics. https://www.cdc.gov/nchs/nhanes
- **Çiftçi, B. T., Karadayi, B., et al. (2024).** *Utilization of machine learning models in predicting caries risk groups and oral health-related risk factors in adults*. *BMC Oral Health*. https://doi.org/10.1186/s12903-024-04210-z
- **Eke, P. I., Page, R. C., Wei, L., Thornton-Evans, G., & Genco, R. J. (2012).** *Update of the case definitions for population-based surveillance of periodontitis*. *Journal of Periodontology, 83*(12), 1449–1454. https://doi.org/10.1902/jop.2012.110664
- **Featherstone, J. D. B. (2004).** *The continuum of dental caries—Evidence for a dynamic disease process*. *Journal of Dental Research, 83*(Spec Iss C), C39–C42. https://journals.sagepub.com/doi/10.1177/154405910408301s08
- **Géron, A. (2023).** *Hands-On Machine Learning with Scikit-Learn, Keras & TensorFlow* (3rd ed.). O'Reilly Media.
- **Gurin, J. (2014).** *Open Data Now: The Secret to Hot Startups, Smart Investing, Savvy Marketing, and Fast Innovation*. McGraw-Hill Education.
- **Hasuike, A., Watanabe, Y., Handa, S., & Saito, A. (2022).** *Machine Learning in Predicting Tooth Loss: A Systematic Review and Risk of Bias Assessment*. *Journal of Personalized Medicine, 12*(10), 1682. https://doi.org/10.3390/jpm12101682
- **He, H., & Garcia, E. A. (2009).** Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering, 21*(9), 1263–1284. https://doi.org/10.1109/TKDE.2008.239
- **Hung, M., Voss, M. W., Rosales, M. N., Li, W., Su, W., Xu, J., Bounsanga, J., Ruiz-Negrón, B., Lauren, E., & Licari, F. W. (2019).** Application of machine learning for diagnostic prediction of root caries. Gerodontology, 36(4), 395–404. https://onlinelibrary.wiley.com/doi/10.1111/ger.12432
- **James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021).** *An Introduction to Statistical Learning: With Applications in R* (2nd ed.). Springer. https://doi.org/10.1007/978-1-0716-1418-1
- **Kim, J. K., Baker, L. A., Seirawan, H., & Crimmins, E. M. (2012).** *Prevalence of oral health problems in U.S. adults, NHANES 1999–2004: Exploring differences by age, education, and race/ethnicity. Special Care in Dentistry, 32(6), 234–241.* https://pubmed.ncbi.nlm.nih.gov/23095066/

- **Ogwo, C., Brown, G., Warren, J., Caplan, D., & Levy, S. (2024).** *Predicting dental caries outcomes in young adults using machine learning approach*. *BMC Oral Health, 24*, 529. https://link.springer.com/article/10.1186/s12903-024-04294-7
- **Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011).** *Scikit-learn: Machine Learning in Python*. *Journal of Machine Learning Research, 12*, 2825–2830.
- **Peres, M. A., Macpherson, L. M. D., Weyant, R. J., Daly, B., Venturelli, R., Mathur, M. R., Listl, S., Celeste, R. K., Guarnizo-Herreño, C. C., Kearns, C., Benzian, H., Allison, P., & Watt, R. G. (2019).** *Oral diseases: A global public health challenge*. *The Lancet, 394*(10194), 249–260. https://doi.org/10.1016/S0140-6736(19)31146-8
- **Provost, F., & Fawcett, T. (2013).** *Data Science for Business: What You Need to Know about Data Mining and Data-Analytic Thinking*. O'Reilly Media.
- **United Nations. (2015).** *Transforming our world: The 2030 Agenda for Sustainable Development*. https://sdgs.un.org/2030agenda
- **Tonetti, M. S., Greenwell, H., & Kornman, K. S. (2018).** *Staging and grading of periodontitis: Framework and proposal of a new classification and case definition*. *Journal of Periodontology, 89*(Suppl. 1), S159–S172. https://doi.org/10.1002/JPER.18-0157
- **Vu, G. T., Mayya, V., Mandhidi, B., King, C., Little, B. B., Gurupur, V., & Singhal, A. (2025).** *Application of machine learning to predict periodontal disease in US adults: A cross-sectional analysis of NHANES 2009–2014*. *Health Informatics Journal, 31*(4). https://doi.org/10.1177/14604582251394617
- **World Health Organization. (2021).** *Global strategy on digital health 2020–2025*. World Health Organization. https://www.who.int/publications/i/item/9789240020924
- **World Health Organization. (2022).** *Global oral health status report: Towards universal health coverage for oral health by 2030*. World Health Organization. https://www.who.int/publications/i/item/9789240061484
- **Yang, H., & Lee, E. K. (2019).** *Healthcare Analytics: From Data to Knowledge to Healthcare Improvement*. *Wiley.*