UNIVERSITAT
Carlemany

De:
Planeta Formación y Universidades

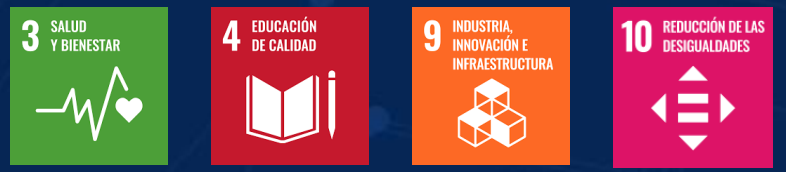
Titulación:	**Bàtxelor en Ciencias de Datos**
Estudiante:	Basaldella, Nazaret.
Tutor:	Gerardo Albà Soler
Dirección:	Gerardo Albà Soler
Fecha de depósito:	20 de septiembre de 2026.
ODS	nº3, nº4, nº9, nº10

Nazaret Basaldella

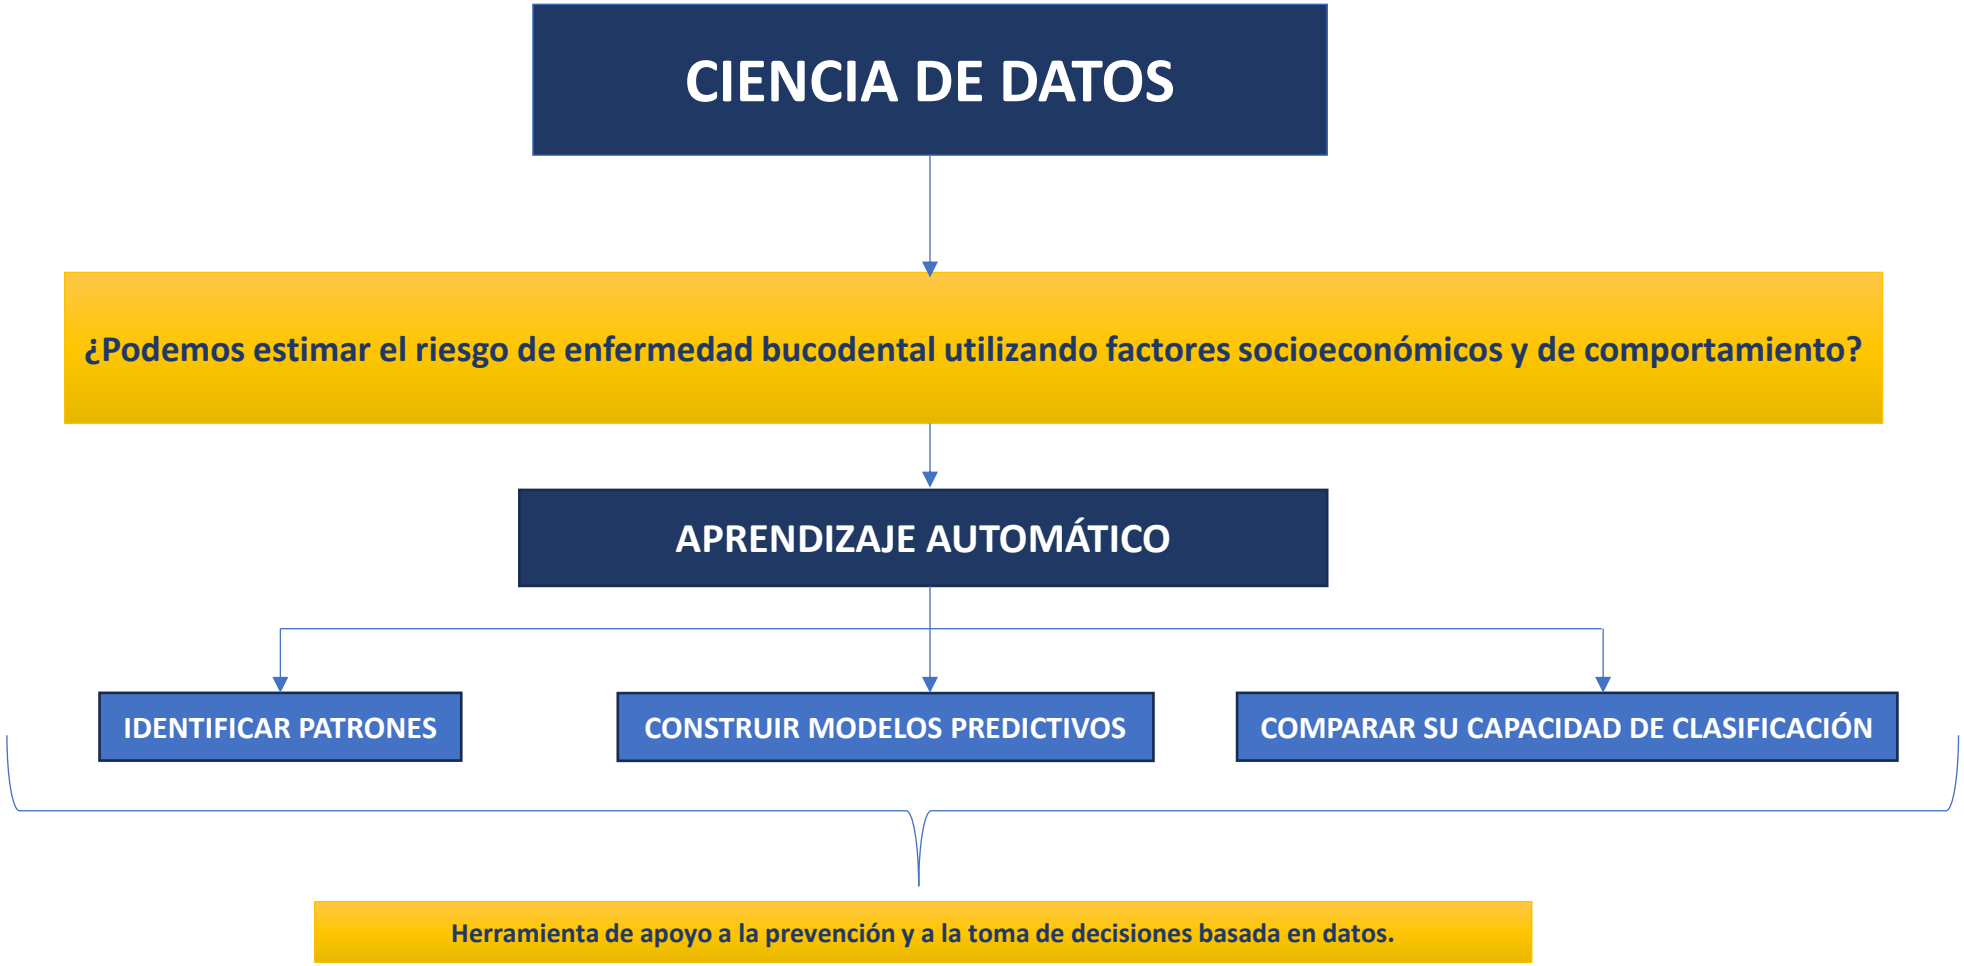
UNIVERSITAT
Carlemany

ANÁLISIS Y PREDICCIÓN DEL RIESGO DE ENFERMEDADES DENTALES MEDIANTE TÉCNICAS DE APRENDIZAJE AUTOMÁTICO: UN ESTUDIO BASADO EN VARIABLES SOCIOECONÓMICAS Y HÁBITOS DE SALUD

NHANES 2011-2012



OBJETIVO PRINCIPAL DEL PROYECTO



"El principal valor científico de este trabajo consiste en la aplicación de las habilidades de la Ciencia de Datos para resolver un problema del mundo real"

OBJETIVOS DE DESARROLLO SOSTENIBLE (ODS)



MARCO TEÓRICO Y FUNDAMENTO

De la ciencia de datos a la predicción del riesgo de enfermedades bucodentales

Nazaret Basaldella

1

CIENCIA DE DATOS

Transforma datos en evidencia que ayuda a comprender fenómenos y resolver problemas

Aplicaciones en SALUD

- Integración de diferentes fuentes de información.
- Identificación de patrones y relaciones entre variables.
- Construcción de modelos analíticos y predictivos.
- Apoyo a la toma de decisiones basada en evidencia.

2

APRENDIZAJE AUTOMÁTICO Y PREDICCIÓN

Desarrolla algoritmos capaces de aprender relaciones a partir de los datos y realiza predicciones sin programar explícitamente cada caso.

En este estudio

- ***Aprendizaje supervisado*** para el problema de clasificación (resultado binario)
- Modelos utilizados y comparados
  - **Regresión logística.**
  - **Random Forest**
- Permiten estimar la probabilidad de presentar enfermedad bucodental a partir de un conjunto de variables predictoras.

3

SALUD BUCODENTAL

Las enfermedades bucodentales constituyen un importante problema de salud pública y su aparición es multifactorial.

Factores asociados

- **Biológicos:** edad, sexo.
- **Conductuales:** tabaquismo, alcohol, higiene oral, actividad física.
- **Socioeconómicos:** nivel educativo, ingresos y acceso a atención odontológica.

4

FUNDAMENTO DEL ESTUDIO

La Ciencia de Datos permite analizar conjuntamente múltiples variables e identificar patrones complejos, haciendo posible desarrollar modelos predictivos para estimar el riesgo de enfermedad bucodental a partir de factores socioeconómicos y hábitos de salud.

UNIVERSITAT Carlemany

PIPELINE METODOLÓGICO

Enfoque cuantitativo, observacional y retrospectivo basado en un análisis secundario de datos abiertos

Nazaret Basaldella

1. Adquisición de datos
NHANES 2011–2012

2. Integración de datos
Unión de módulos mediante **SEQN.**

3. Limpieza y transformación
Tratamiento de valores faltantes; Recodificación; Selección de variables.

4. Construcción de la variable objetivo ENFERMEDAD_BUCODENTAL
Caries y/o periodontitis = clasificación binaria **0 / 1**

5. Análisis exploratorio (EDA)
Distribuciones; Estadística descriptiva; Relaciones y asociaciones.

6. Preparación para ML
Codificación de variables; Train/Test Split; Manejo del desbalance.

7. Modelado supervisado Regresión Logística + Random Forest.

8. Evaluación y comparación
Métricas de clasificación; Curvas ROC/AUC; Matriz de confusión.

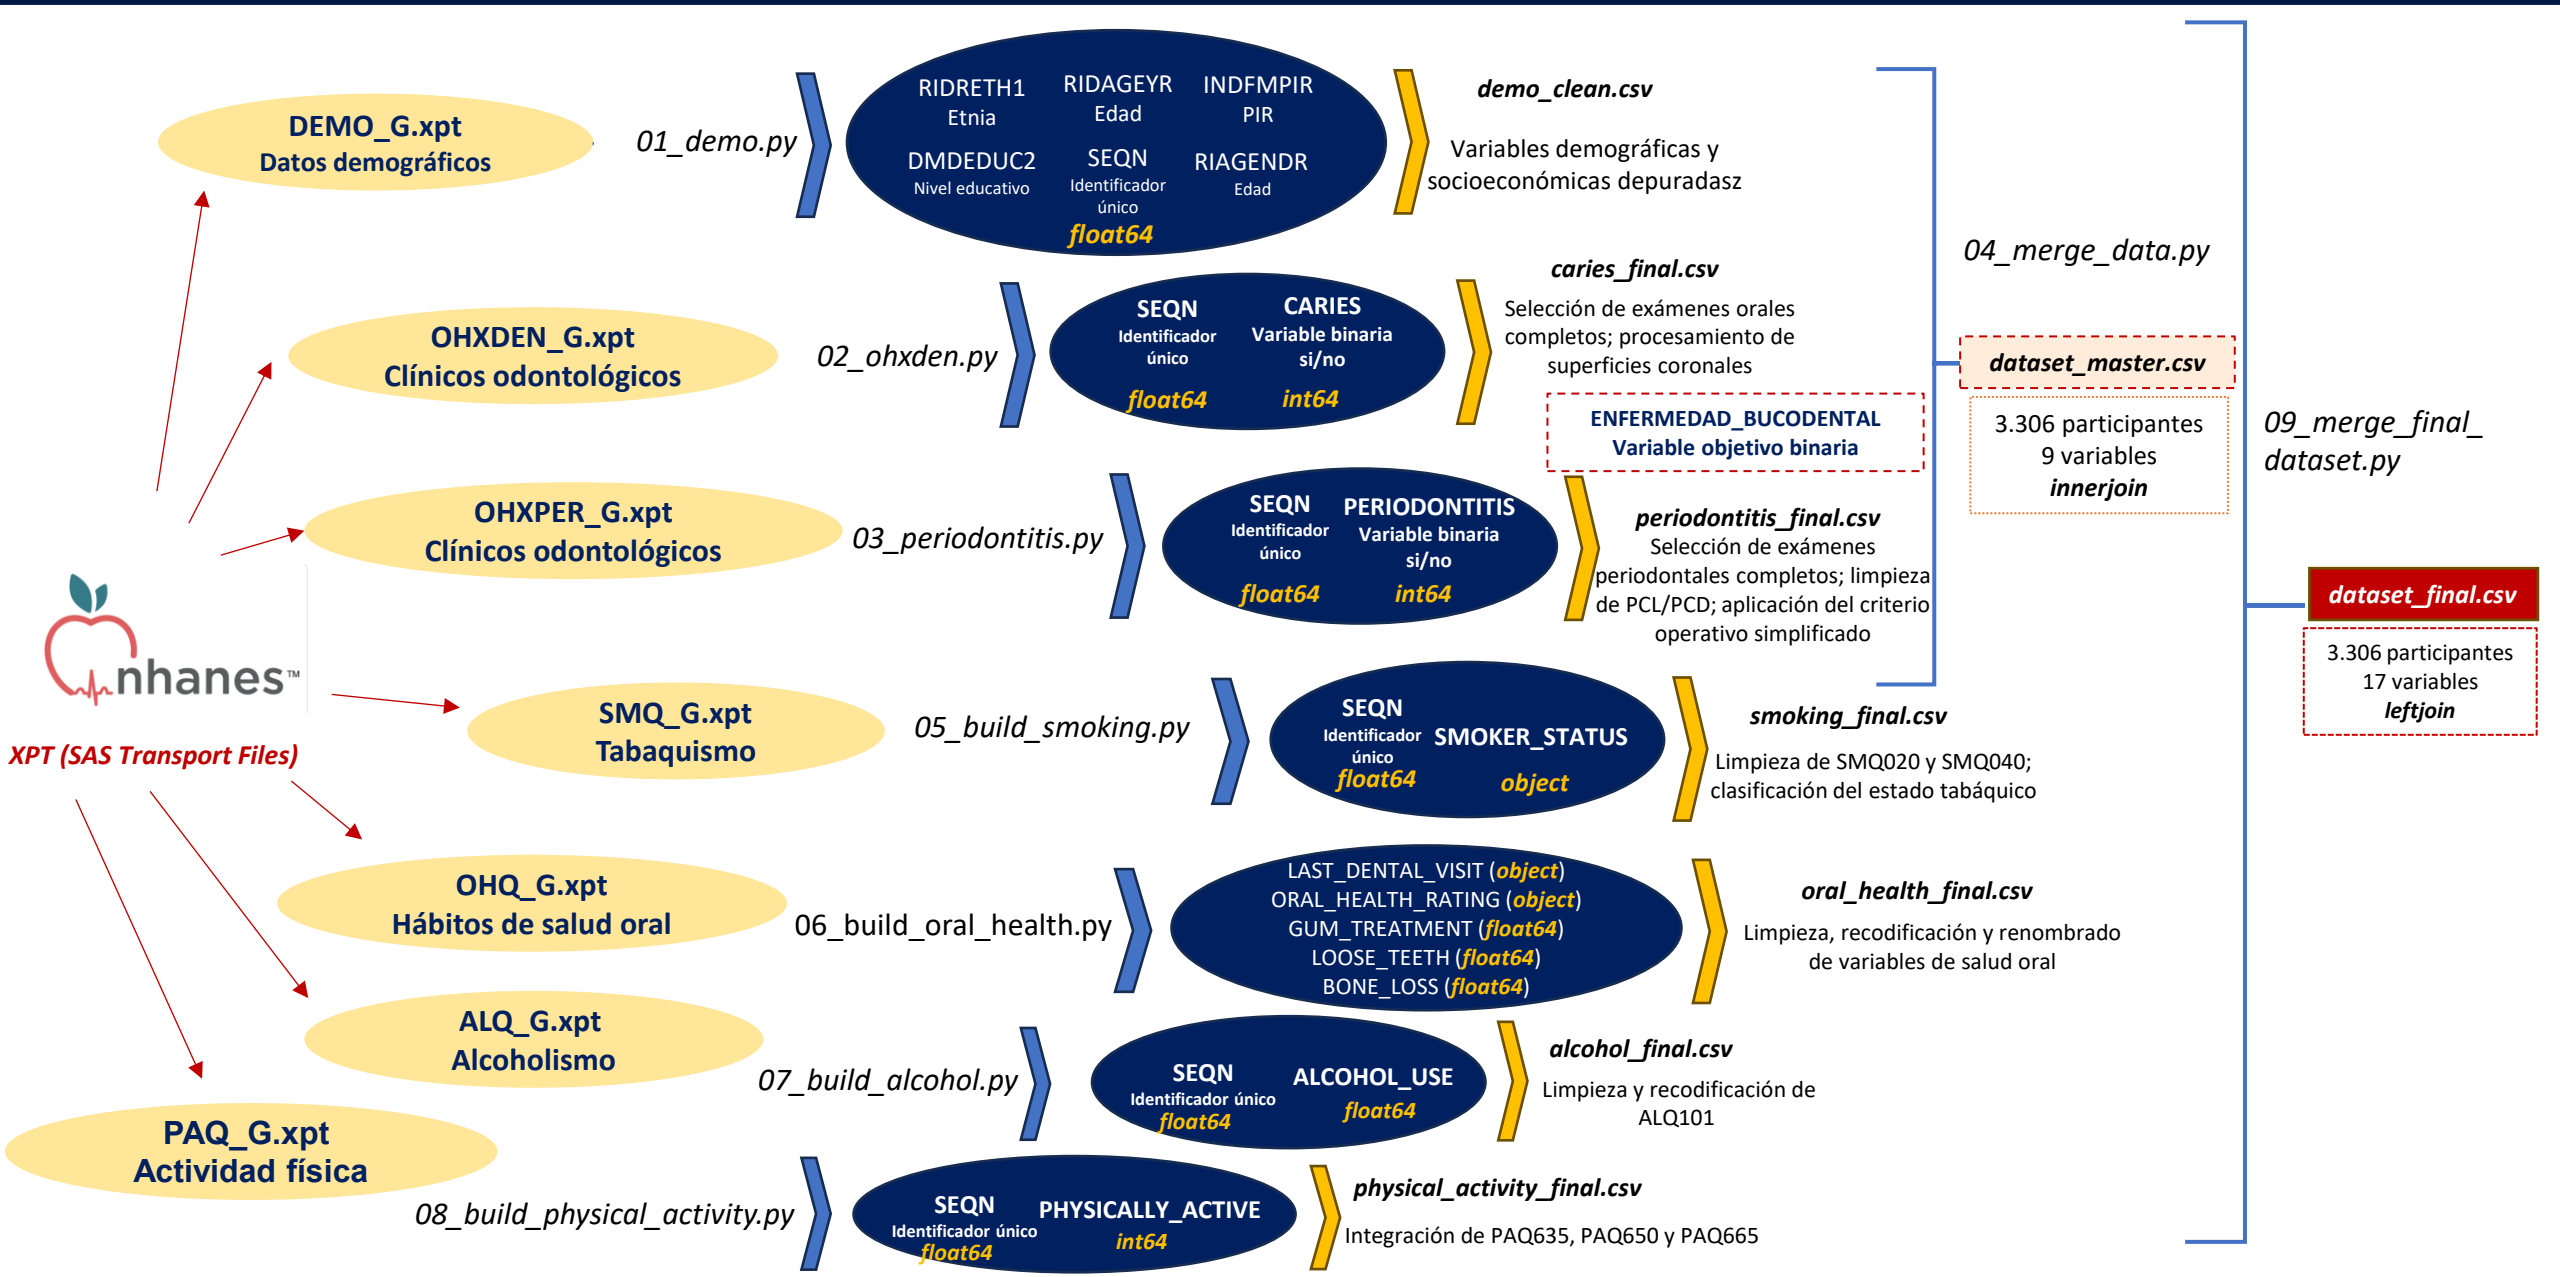
9. Interpretación y visualización
Factores asociados; Importancia de variables; Probabilidad/riesgo predicho.

UNIVERSITAT Carlemany

DATOS: NHANES 2011–2012

National Health and Nutrition Examination Survey

Nazaret Basaldella



CLASIFICACIÓN DE VARIABLES DEL ESTUDIO

VARIABLES CATEGÓRICAS

Categórica nominal

- RIDRETH1: Grupo étnico - float64.
- SMOKER_STATUS: Estado de fumador - object.

Categórica ordinal

- DMDEDUC2: Nivel educativo - float64.
- LAST_DENTAL_VISIT: Tiempo desde la última visita dental - object.
- ORAL_HEALTH_RATING: Valoración de la salud oral - object.

Categórica binaria nominal

- RIAGENDR: Sexo - float64

Categórica binaria

- ALCOHOL_USE: Consumo de alcohol - float64.
- PHYSICALLY_ACTIVE: Actividad física - int64.
- GUM_TREATMENT: Tratamiento de encías- float64.
- LOOSE_TEETH: Movilidad dental- float64.
- BONE_LOSS: Pérdida ósea- float64.
- CARIES: Estado de caries - int64.
- PERIODONTITIS: Estado de periodontitis - int64.
- ***ENFERMEDAD_BUCODENTAL: Ausencia o presencia de enfermedad bucodental. (VARIABLE OBJETIVO)*** - int64.

VARIABLES NUMÉRICAS

Numérica discreta

- RIDAGEYR: Edad en años cumplidos - float64

Numérica continua

- INDFMPIR: Relación ingresos/umbral de pobreza - float64

SEQN: Identificador único del participante- float64.

PRINCIPALES HALLAZGOS DEL ANÁLISIS EXPLORATORIO

Nazaret Basaldella

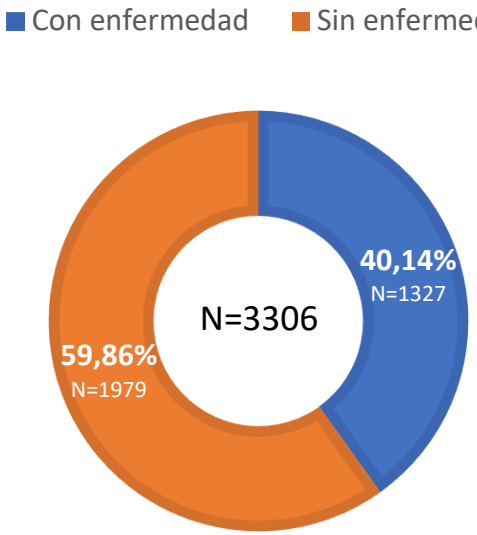


Creación de un diccionario de etiquetas de las variables categóricas utilizadas.

PRINCIPALES HALLAZGOS DEL ANÁLISIS EXPLORATORIO

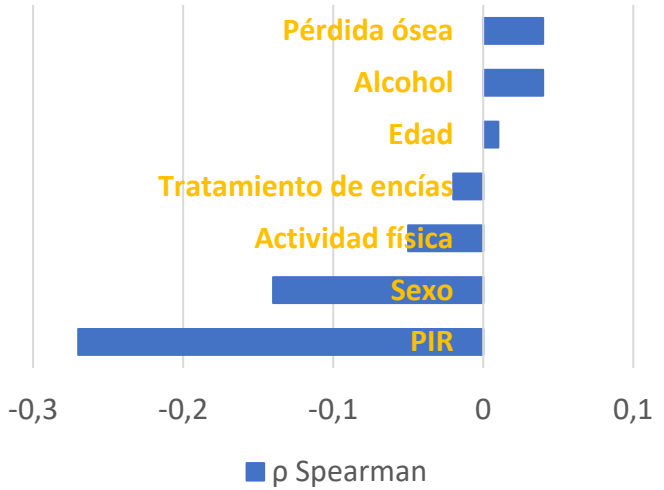
Nazaret Basaldella

1. Prevalencia de enfermedad bucodental



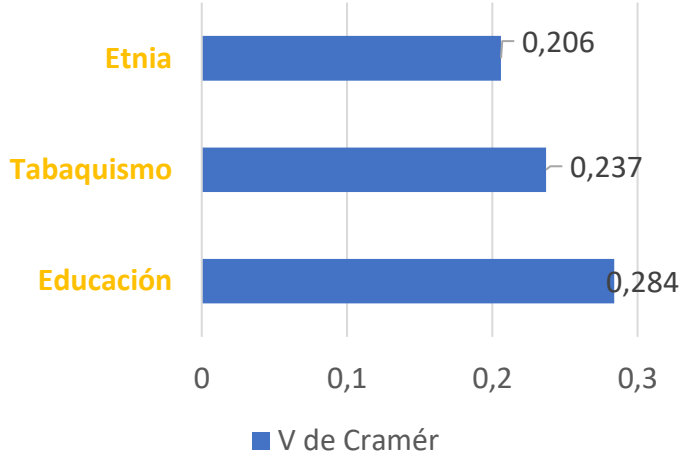
El 40,14% de los participantes presentó caries y/o periodontitis

2. Principal asociación numérica (Spearman)



El mayor índice ingreso-pobreza (mejor situación socioeconómica) se asocio con menor presencia de enfermedad bucodental

3. Principales asociaciones categóricas (V de Cramér)



Las variables educación, tabaquismo y etnia presentaron asociaciones estadísticamente significativas con la enfermedad bucodental ($p<0,001$), aunque de magnitud débil

El EDA mostró asociaciones principalmente socioeconómicas y conductuales,
pero ninguna variable presentó por sí sola una relación fuerte con la enfermedad bucodental.

Preparación de datos para el modelado

Nazaret Basaldella

Selección de predictores

8 variables: Edad; PIR; Sexo; Etnia; Educación; Tabaquismo; Actividad física; Alcohol; ENFERMEDAD_BUCODENTAL

↓

División en 2 grupos

80 % (n=2644) grupo de entrenamiento	20% (n=662) grupo de prueba	train_test_Split; stratify=y; random_state = 42

↓

Imputación de valores faltantes

Numéricas → mediana	Categóricas → moda

↓

One-Hot Encoding

Etnia; Educación; Tabaquismo	drop = "first"

↓

StandarScaler

Edad + PIR	scaler = StandardScaler()

DATOS PREPROCESADOS

8 variables predictoras (sociodemográficas, socioeconómicas y conductuales)

Train/Tes 80/20 - Imputación - One-Hot Encoding - Escalado

REGRESIÓN LOGÍSTICA

- **Modelo Base**
- **Evaluación inicial:** Métricas en conjunto de test
- **Manejo del desbalance de clases:** class_weight="balanced"
- **Modelo Final:** Regresión Logística Balanceada

RANDOM FOREST

- **Modelo Base**
- **Evaluación inicial:** Métricas en conjunto de test
- **Prueba con ponderación de clases:** class_weight="balanced"
- **Modelo Final:** Random Forest Base

Figura 8.27. Comparación de las curvas ROC de los modelos

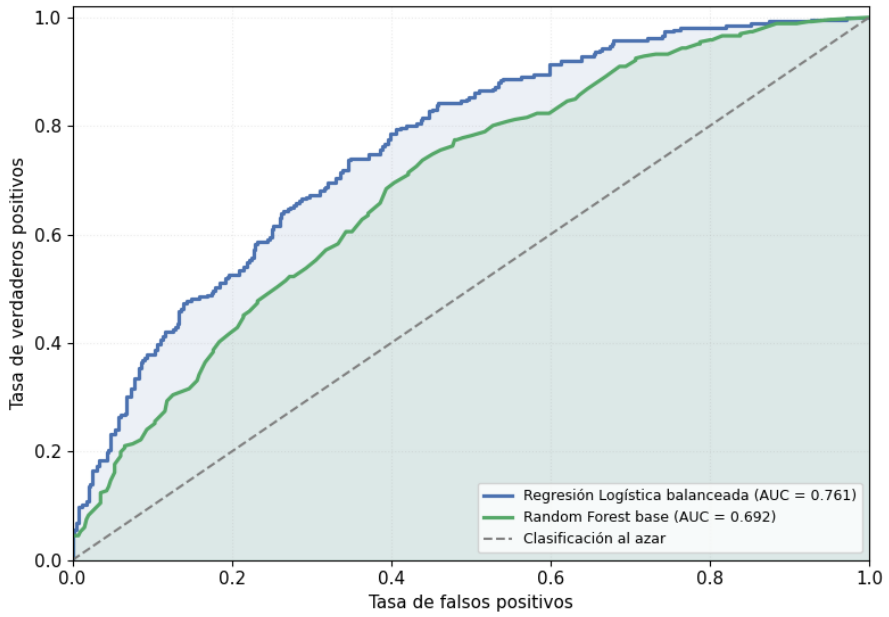
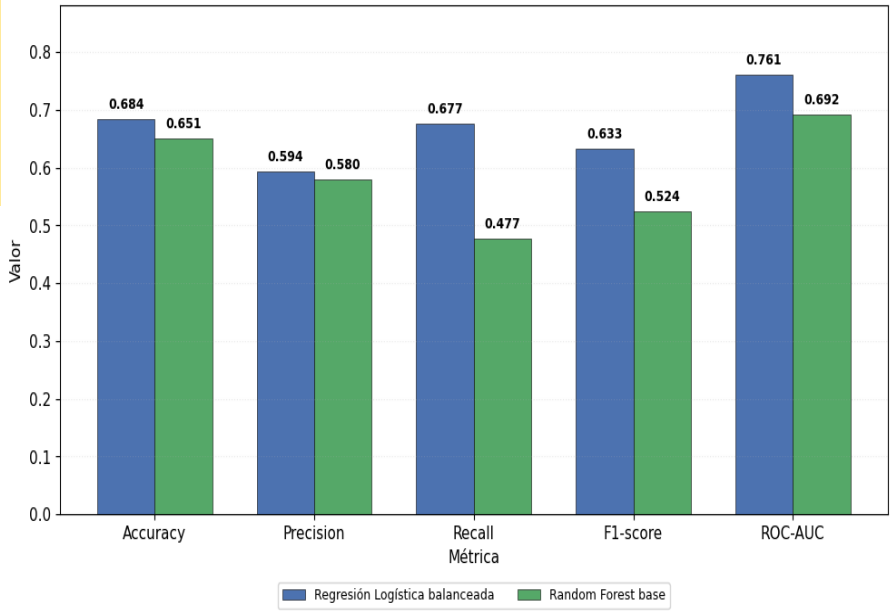


Figura 8.26. Comparación del rendimiento de los modelos



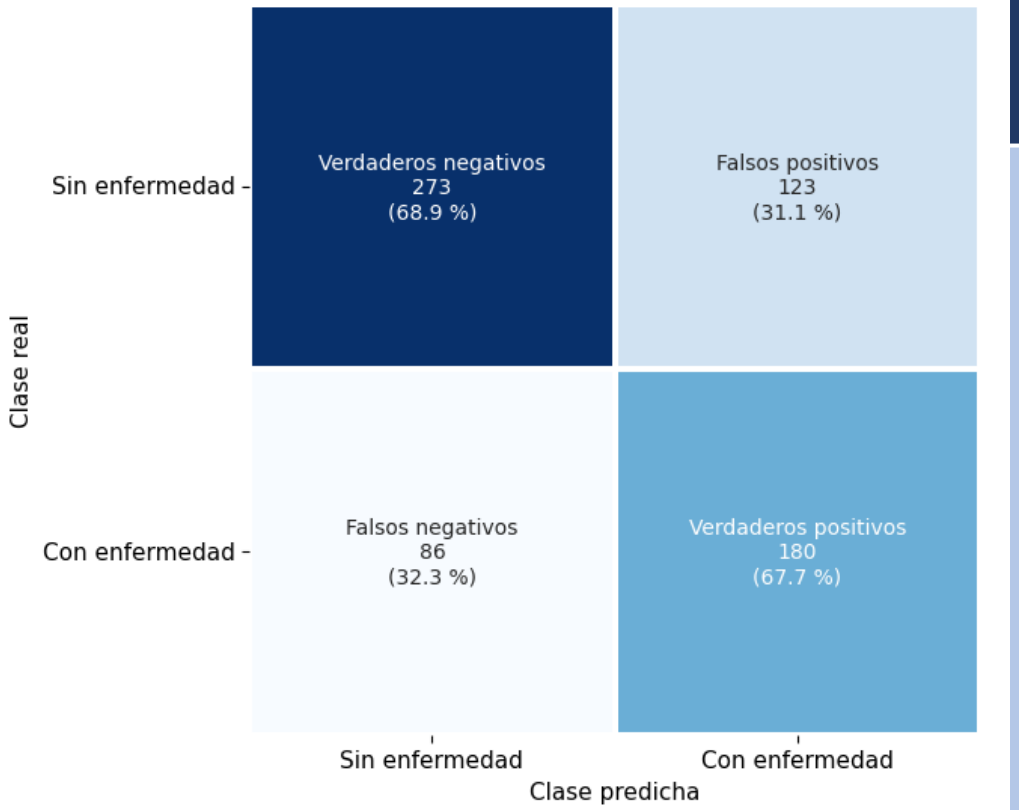
EVALUACIÓN Y MODELO SELECCIONADO

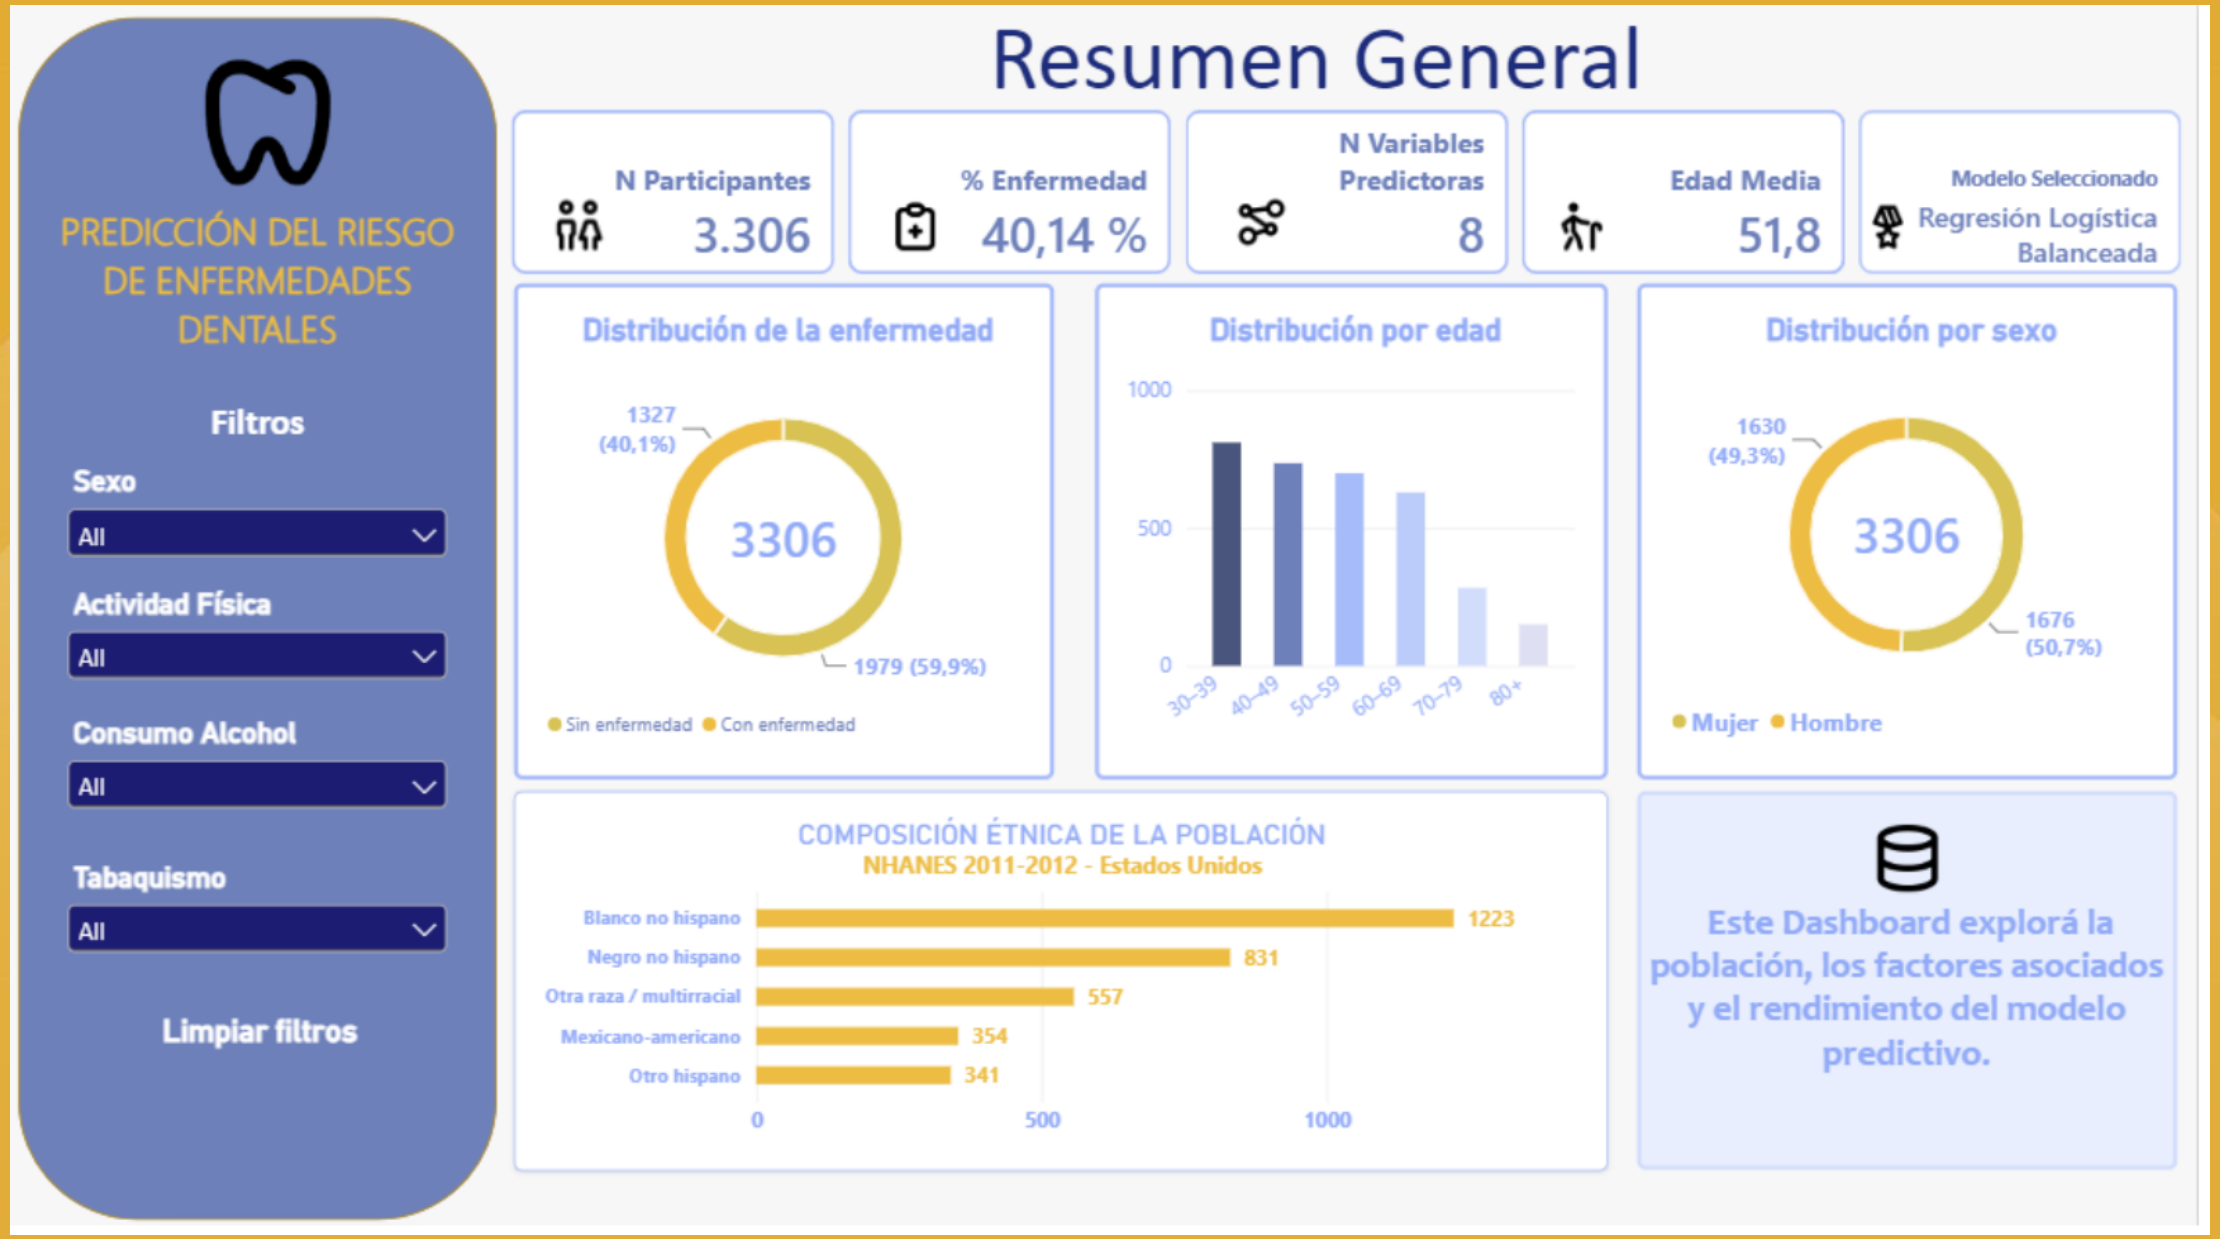
REGRESIÓN LOGÍSTICA BALANCEADA

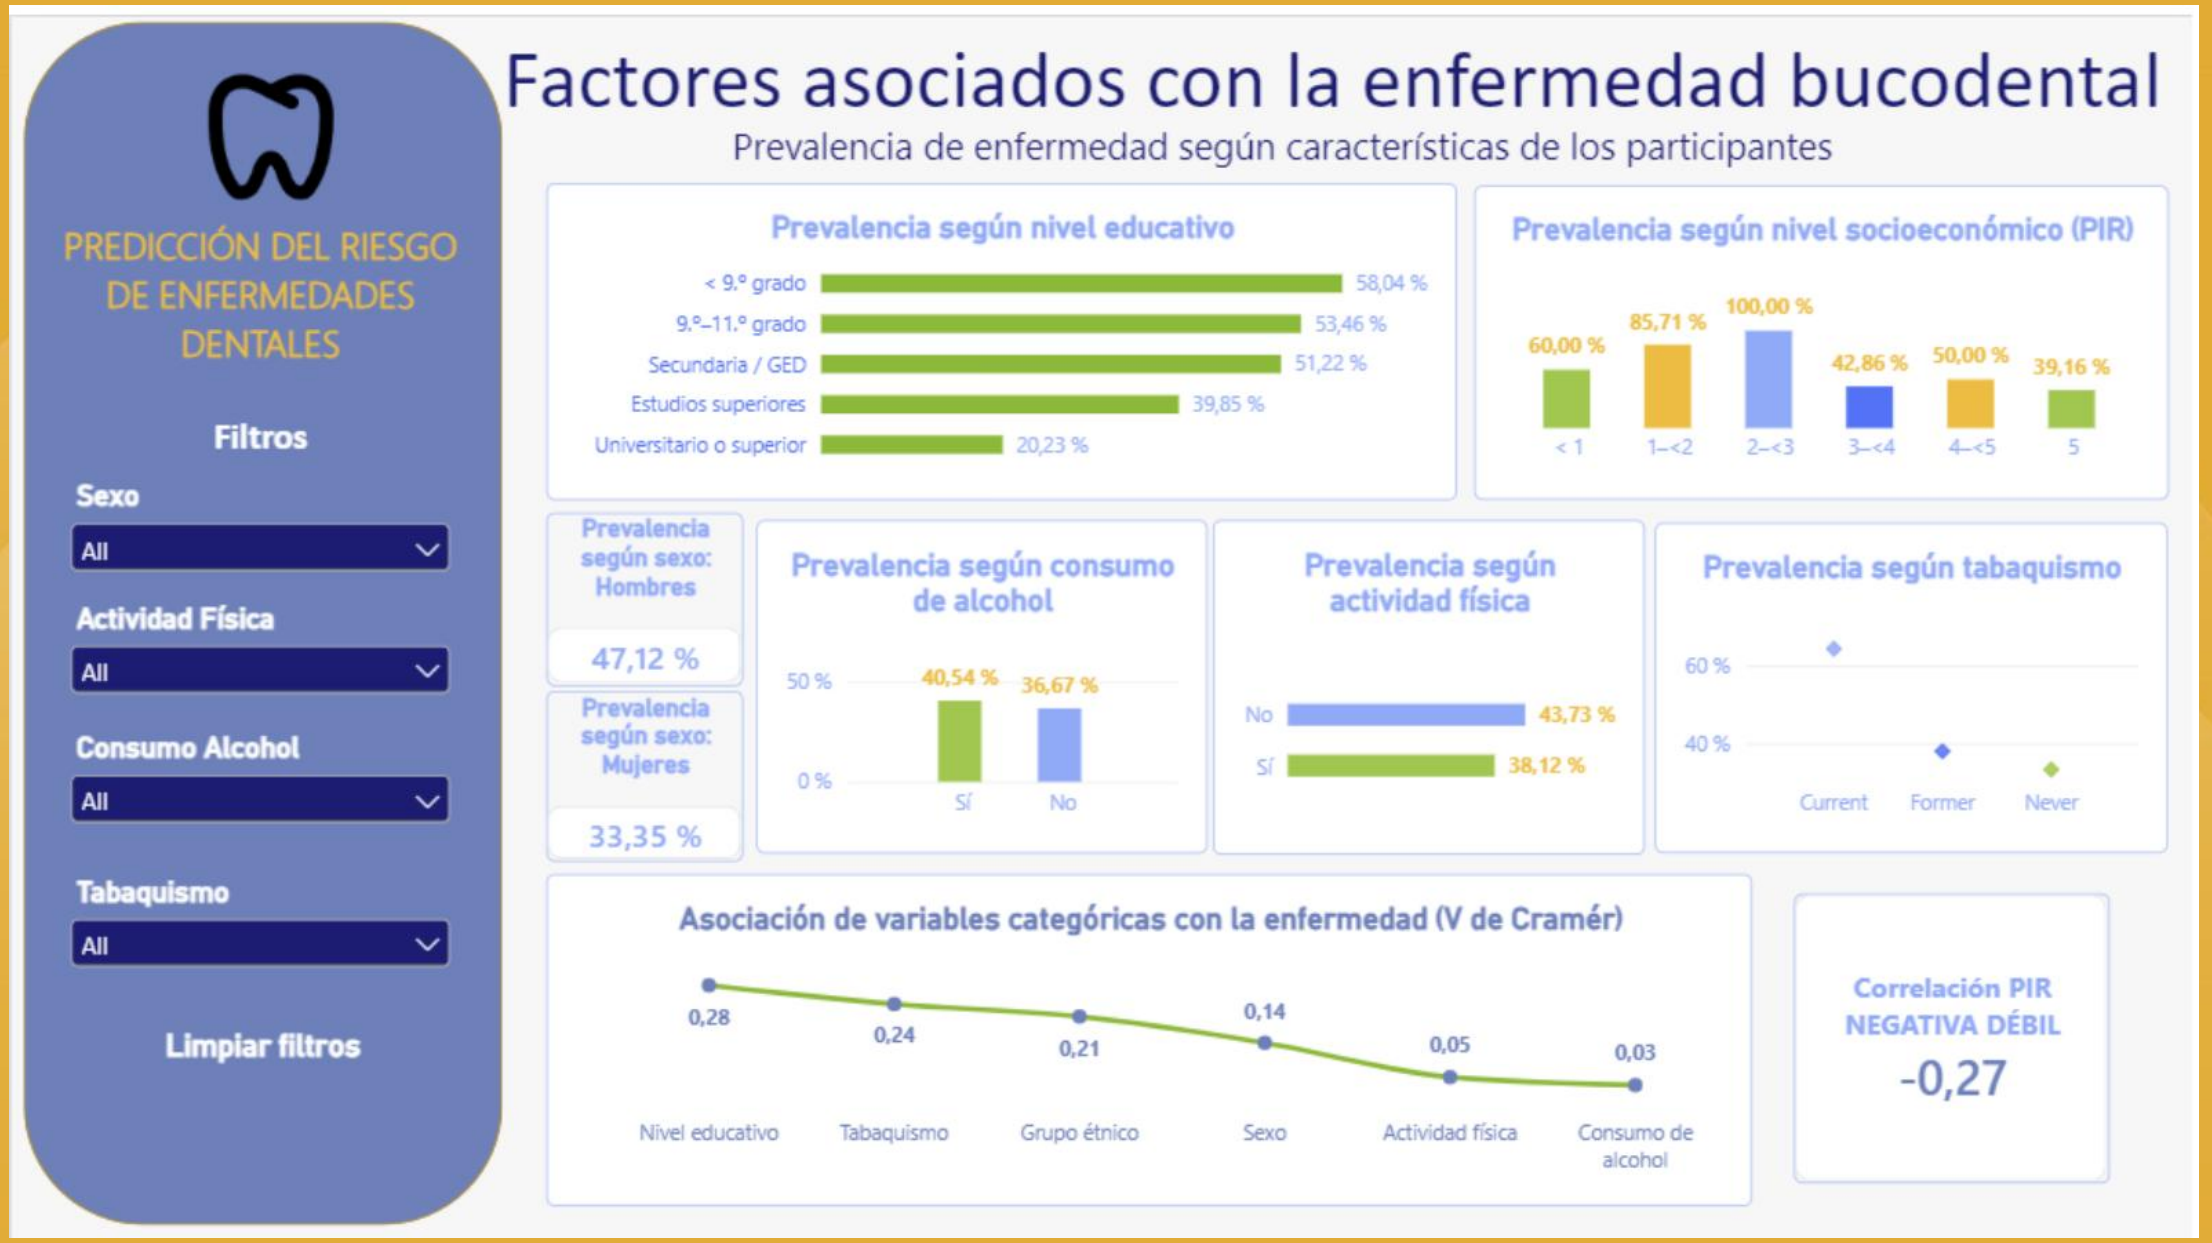
- Mejor desempeño global.
- Mayor **Recall y F1-score**, mejorando la detección de participantes con enfermedad.
- **ROC-AUC superior**, indicando mayor capacidad discriminativa.
- La ponderación de clases favoreció la identificación de la clase positiva.

Métrica	Regresión Logística Balanceada	Random Forest Base
Accuracy	0.684	0.651
Precisión	0.594	0.580
Recall	0.677	0.477
F1-Score	0.633	0.524
ROC-AUC	0.761	0.692

Figura 8.22. Matriz de confusión del modelo balanceado




PREDICCIÓN DEL RIESGO DE ENFERMEDADES DENTALES
Filtros
Sexo
All
Actividad Física
All
Consumo Alcohol
All
Tabaquismo
All
Limpiar filtros
Resumen General
N Participantes
3.306
% Enfermedad
40,14 %
N Variables Predictoras
8
Edad Media
51,8
Modelo Seleccionado
Regresión Logística Balanceada
Distribución de la enfermedad
1327 (40,1%)
3306
1979 (59,9%)
Sin enfermedad
Con enfermedad
Distribución por edad
1000
500
0
30–39
40–49
50–59
60–69
70–79
80+
Distribución por sexo
1630 (49,3%)
3306
1676 (50,7%)
Mujer
Hombre
COMPOSICIÓN ÉTNICA DE LA POBLACIÓN
NHANES 2011-2012 - Estados Unidos
Blanco no hispano
1223
Negro no hispano
831
Otra raza / multirracial
557
Mexicano-americano
354
Otro hispano
341
0
500
1000
Este Dashboard explorá la población, los factores asociados y el rendimiento del modelo predictivo.


PREDICCIÓN DEL RIESGO DE ENFERMEDADES DENTALES
Filtros
Sexo
All
Actividad Física
All
Consumo Alcohol
All
Tabaquismo
All
Limpiar filtros
Factores asociados con la enfermedad bucodental
Prevalencia de enfermedad según características de los participantes
Prevalencia según nivel educativo
< 9.° grado 58,04 %
9.°–11.° grado 53,46 %
Secundaria / GED 51,22 %
Estudios superiores 39,85 %
Universitario o superior 20,23 %
Prevalencia según nivel socioeconómico (PIR)
60,00 %
85,71 %
100,00 %
42,86 %
50,00 %
39,16 %
< 1
1–<2
2–<3
3–<4
4–<5
5
Prevalencia según sexo: Hombres
47,12 %
Prevalencia según sexo: Mujeres
33,35 %
Prevalencia según consumo de alcohol
50 %
0 %
40,54 %
36,67 %
Sí
No
Prevalencia según actividad física
No 43,73 %
Sí 38,12 %
Prevalencia según tabaquismo
60 %
40 %
Current
Former
Never
Asociación de variables categóricas con la enfermedad (V de Cramér)
0,28
0,24
0,21
0,14
0,05
0,03
Nivel educativo
Tabaquismo
Grupo étnico
Sexo
Actividad física
Consumo de alcohol
Correlación PIR
NEGATIVA DÉBIL
-0,27

PREDICCIÓN DEL RIESGO DE ENFERMEDADES DENTALES

Filtros

Sexo
All

Actividad Física
All

Consumo Alcohol
All

Tabaquismo
All

Limpiar filtros

Resultados del modelo predictivo

Rendimiento del modelo seleccionado: Regresión logística balanceada

Accuracy	Precisión	Recall	F1	ROC AUC
0,684	0,594	0,677	0,633	0,761

Matriz de confusión

Clase real	Con enfermedad	Sin enfermedad
Con enfermedad	180	86
Sin enfermedad	123	273

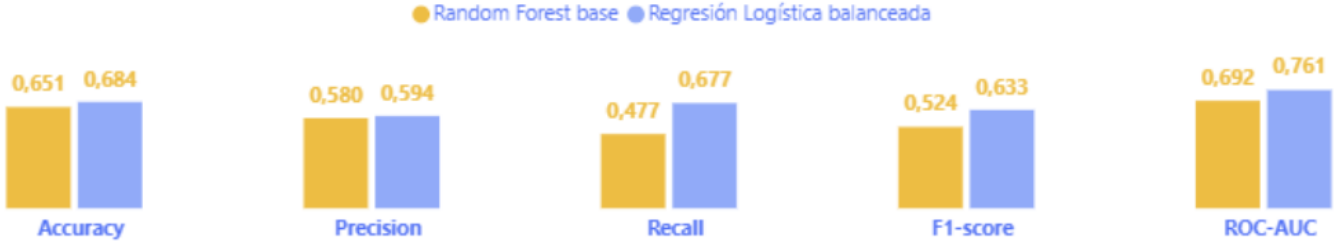
Regresión Logística balanceada

Presentó el mejor equilibrio entre las métricas evaluadas, destacándose especialmente por su capacidad para identificar participantes con enfermedad bucodental

Curva ROC del modelo seleccionado



Comparación del rendimiento de los modelos



CONCLUSIONES

Nazaret Basaldella

¿Son capaces los algoritmos de aprendizaje automático de predecir el riesgo de una persona a padecer una enfermedad bucal, utilizando factores socioeconómicos y de comportamiento?

Si es posible, pero en este trabajo existen limitaciones que se pueden mejorar en líneas futuras.

SEQN

Fue clave para la construcción de la base de datos, logrando que sea confiable y adecuado para la exploración y modelado.

VARIABLES Y ENFERMEDAD

El PIR, educación y tabaquismo son las variables con mayor correlación.

REGRESIÓN LOGÍSTICA BALANCEADA

Fue el modelo predictivo elegido, ya que se evidencio una mejoría en identificar casos positivos de enfermedad. Todavía presenta limitaciones.

DATOS ABIERTOS

Es posible utilizar datos abiertos para un proyecto de Ciencia de Datos. Y fue posible crear un flujo de trabajo completo.

LIMITACIONES	LÍNEAS FUTURAS
Un único ciclo NHANES 2011–2012.	Incorporar más ciclos NHANES y aumentar la muestra.
Caries + periodontitis agrupadas en una única variable objetivo.	Analizar caries y periodontitis por separado.
Solo 8 variables predictoras.	Incorporar dieta, enfermedades sistémicas, higiene oral e historia clínica.
Solo 2 algoritmos evaluados.	Evaluar otros algoritmos, por ejemplo, Gradient Boosting, XGBoost y SVM.
Sin validación externa.	Validar el modelo en muestras y poblaciones independientes.

UNIVERSITAT
Carlemany

De:
Planeta Formación y Universidades

De los datos a la prevención: la Ciencia de Datos permite identificar patrones de riesgo en salud bucodental y abre nuevas posibilidades para una prevención basada en datos.

GRACIAS

Nazaret Basaldella

